BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH

----------***----------

TIỂU LUẬN HỌC PHẦN

MÔN: KHAI PHÁ DỮ LIỆU NÂNG CAO

ĐỀ TÀI:

ỨNG DỤNG DATA WAREHOUSE VÀ KHAI PHÁ LUẬT KẾT HỢP TRONG PHÂN LỚP HỒ SƠ PHÊ DUYỆT KHOẢN VAY

Giảng viên hướng dẫn: TS.Đặng Ngọc Hoàng Thành

Mã lớp học phần: 26D1ADV60900402

Nhóm: 07

TP. HỒ CHÍ MINH, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH

----------***----------



TIỂU LUẬN HỌC PHẦN

MÔN: KHAI PHÁ DỮ LIỆU NÂNG CAO

ĐỀ TÀI:

ỨNG DỤNG DATA WAREHOUSE VÀ KHAI PHÁ LUẬT KẾT HỢP TRONG PHÂN LỚP HỒ SƠ PHÊ DUYỆT KHOẢN VAY

Giảng viên hướng dẫn: TS.Đặng Ngọc Hoàng Thành

Mã lớp học phần: 26D1ADV60900402

Học viên thực hiện:

MSHV: Nhóm: 07

TP. HỒ CHÍ MINH, NĂM 2026

MỤC LỤC

MỤC LỤC

DANH MỤC TỪ VIẾT TẮT

DANH MỤC BẢNG BIỂU

DANH MỤC HÌNH ẢNH

CHƯƠNG 1. GIỚI THIỆU VẤN ĐỀ NGHIÊN CỨU 1

1.1. Giới thiệu chung về bối cảnh 1

1.2. Vấn đề nghiên cứu và sự cần thiết 2

1.3. Mục tiêu của đề án 3

1.4. Đối tượng và phạm vi nghiên cứu 4

1.4.1. Đối tượng nghiên cứu 4

1.4.2. Phạm vi dữ liệu 4

1.4.3. Phạm vi nội dung 5

1.5. Ý nghĩa và đóng góp của đề tài 5

1.6. Phương pháp nghiên cứu đề án 5

1.7. Bố cục của đề án 6

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT 8

2.1. Định nghĩa các khái niệm chính 8

2.1.1. Dự đoán duyệt vay 8

2.1.2. F-beta và ma trận chi phí 9

2.1.3. Điểm tín dụng 10

2.1.4. Kho dữ liệu và mô hình hình sao 10

2.1.5. Chiều suy biến 11

2.1.6. Các phép tổng hợp OLAP: ROLLUP và CUBE 11

2.1.7. Khai phá luật kết hợp (Association Rule Mining) 12

2.1.8. Hệ số chắc chắn 12

2.1.9. Khai phá luật kết hợp dựa trên ràng buộc 13

2.1.10. Phân loại dựa trên luật kết hợp 14
2.1.11. Rời rạc hóa dữ liệu (Discretization) 14
2.1.12. Đa cộng tuyến 15
2.1.13. Đo lường mối liên hệ giữa các biến bằng Cramér's V 15
2.2. Các lý thuyết liên quan 16
2.2.1. Thuật toán Apriori 16
2.2.2. Thuật toán FP-Growth 16
2.2.3. Các thuật toán phân loại dựa trên luật kết hợp: CBA, CMAR, CPAR 17
2.2.3.1. CBA (Classification Based on Associations) của Liu, Hsu và Ma (1998) 17
2.2.3.2. CMAR (Classification based on Multiple Association Rules) của Li, Han và Pei (2001) 17
2.2.3.3. CPAR (Classification based on Predictive Association Rules) 18
2.2.4. Phương pháp luận Kimball trong thiết kế kho dữ liệu 19
2.3. Tổng quan các nghiên cứu liên quan 20
2.4. Cơ sở lựa chọn các đặc trưng phân tích 23
2.4.1. Lịch sử tín dụng (liên quan đến Character) 24
2.4.2. Năng lực tài chính và quy mô khoản vay (liên quan đến Capacity) 24
2.4.3. Nguồn lực, mục đích và điều kiện khoản vay (liên quan đến Capital và Conditions) 24
2.4.4. Đặc điểm nhân khẩu học 25
2.4.5. Tổng hợp các biến tham chiếu 25
2.4.6. Lưu ý khi diễn giải mối liên hệ 26
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU 27
3.1. Quy trình nghiên cứu 27
3.2. Phương pháp nghiên cứu 29
3.2.1. Nguồn và mô tả dữ liệu 29

3.2.2. Thiết kế biến và tiền xử lý 30
3.2.3. Mẫu nghiên cứu: 33
3.2.4. Thu thập dữ liệu và xây dựng Data Warehouse 34
3.2.5. Thước đo đánh giá và tiêu chí lựa chọn mô hình 35
3.2.6. Phương pháp phân tích dữ liệu 36
3.2.7. Môi trường thực nghiệm 40
CHƯƠNG 4. DỮ LIỆU VÀ KẾT QUẢ THỰC NGHIỆM 41
4.1. Kết quả phân tích thăm dò dữ liệu 41
4.1.1. Tổng quan bộ dữ liệu 41
4.1.2. Phân phối biến mục tiêu 43
4.1.3. Phân phối điểm tín dụng, tỉ lệ vay trên thu nhập và thu nhập theo lớp 44
4.1.4. Phát hiện then chốt 46
4.2. Kết quả tiền xử lý 47
4.2.1. Làm sạch dữ liệu 47
4.2.2. Xử lý đa cộng tuyến 47
4.2.3. Rời rạc hóa bằng ngưỡng nghiệp vụ 48
4.2.4. Kiểm tra phụ thuộc giữa các thuộc tính rời rạc 49
4.2.5. Chia tập huấn luyện, kiểm định và kiểm tra 50
4.3. Kết quả xây dựng kho dữ liệu 51
4.3.1. Thiết kế mô hình hình sao 51
4.3.2. Phép cắt lát: tỉ lệ duyệt theo lịch sử vỡ nợ 52
4.3.3. Phép gộp cấp (ROLLUP): khoản vay bình quân theo học vấn và sở hữu nhà 53
4.3.4. Phép khối (CUBE): tỉ lệ duyệt theo mục đích vay và giới tính 55
4.3.5. Bốn truy vấn nghiệp vụ 56
4.3.6. Vấn đề đặt ra từ kho dữ liệu 60
4.4. Kết quả khai phá luật kết hợp 60

4.4.1. So sánh Apriori và FP-Growth 60
4.4.2. Ràng buộc thống kê đồng bộ và hệ số chắc chắn 61
4.4.3. Luật minh họa 62
4.5. Kết quả phân loại dựa trên luật kết hợp (Associative Classification) 64
4.5.1. Tiêu chí điểm F0.5 và quy trình chọn hai bước 65
4.5.2. Xu hướng dự đoán của từng thuật toán qua ma trận nhầm lẫn 66
4.5.3. Phân tích độ nhạy chi phí 67
4.5.4. So sánh công bằng: cùng không gian luật 68
4.6. Tích hợp tri thức ngành vào lựa chọn luật 69
4.6.1. Vấn đề: luật đúng về thống kê chưa chắc đúng về nghiệp vụ 69
4.6.2. Tri thức ngành và khung nhìn chính sách v_policy 69
4.6.3. Cơ chế lọc luật 69
4.6.4. Tác dụng của bộ lọc 70
4.6.5. Ba luật được chọn và độ phủ 70
4.7. Kết quả phân loại với thuộc tính sinh từ luật 73
4.7.1. Thiết kế thực nghiệm 73
4.7.2. Kết quả trên tập kiểm tra 73
4.7.3. Ảnh hưởng của thuộc tính sinh từ luật 76
4.7.4. Ba nguyên nhân 78
4.8. Tổng hợp kết quả thực nghiệm 78
4.9. Minh họa ứng dụng: hệ thống xét duyệt hai lớp 80
CHƯƠNG 5. CHƯƠNG 5. KẾT LUẬN VÀ KHUYẾN NGHỊ 82
5.1. Kết quả đạt được 82
5.2. Hàm ý quản trị và khuyến nghị nghiệp vụ 85
5.3. Hạn chế của nghiên cứu 86
5.4. Hướng phát triển 86
DANH MỤC TÀI LIỆU THAM KHẢO

BẢNG ĐÁNH GIÁ MỨC ĐỘ HOÀN THÀNH NHIỆM VỤ CỦA TỪNG THÀNH VIÊN

KẾT QUẢ KIỂM TRA ĐẠO VĂN

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Nguyên nghĩa (tiếng Anh)	Nghĩa tiếng Việt
1	AC	Associative Classification	Phân loại dựa trên luật kết hợp
2	AI	Artificial Intelligence	Trí tuệ nhân tạo
3	ARM	Association Rule Mining	Khai phá luật kết hợp
4	CAR	Class Association Rule	Luật kết hợp lớp (luật có vế phải là nhãn lớp)
5	CBA	Classification Based on Associations	Phân loại dựa trên các luật kết hợp
6	CBA-CB	Classifier Builder (của CBA)	Bộ xây dựng bộ phân loại (của CBA)
7	CBA-RG	Rule Generator (của CBA)	Bộ sinh luật (của CBA)
8	CF	Certainty Factor	Hệ số chắc chắn
9	CMAR	Classification based on Multiple Association Rules	Phân loại dựa trên nhiều luật kết hợp
10	CPAR	Classification based on Predictive Association Rules	Phân loại dựa trên các luật kết hợp có tính dự báo
11	CPU	Central Processing Unit	Bộ xử lý trung tâm
12	CR-tree	Class Association Rule tree	Cây lưu trữ luật kết hợp lớp
13	CSV	Comma-Separated Values	Tệp giá trị phân tách bằng dấu phẩy
14	DTI	Debt-to-Income ratio	Tỷ lệ nghĩa vụ trả nợ trên thu nhập
15	DW	Data Warehouse	Kho dữ liệu
16	EDA	Exploratory Data Analysis	Phân tích thăm dò dữ liệu
17	ETL	Extract – Transform – Load	Quy trình trích xuất, biến đổi và nạp dữ liệu
18	F0.5	F-beta score ($\beta = 0.5$)	Điểm F với β bằng 0.5, ưu tiên precision hơn recall
19	F1	F1-score	Điểm F1, trung bình điều hòa của precision và recall

20	FICO	Fair Isaac Corporation	Công ty Fair Isaac; điểm FICO là hệ điểm tín dụng do công ty này xây dựng
21	FN	False Negative	Âm tính giả (dự đoán Rejected, thực tế Approved)
22	FOIL	First Order Inductive Learner	Thuật toán học luật quy nạp bậc nhất (dùng độ đo FOIL gain)
23	FP	False Positive	Dương tính giả (dự đoán Approved, thực tế Rejected)
24	FP-Growth	Frequent Pattern Growth	Thuật toán tăng trưởng mẫu thường xuyên
25	GB (1)	Gradient Boosting	Tăng cường độ dốc (mô hình phân loại)
26	GB (2)	Gigabyte	Đơn vị dung lượng bộ nhớ
27	GPU	Graphics Processing Unit	Bộ xử lý đồ họa
28	LR	Logistic Regression	Hồi quy logistic
29	Max	Maximum	Giá trị lớn nhất
30	Min	Minimum	Giá trị nhỏ nhất
31	NPL	Non-Performing Loan	Nợ xấu
32	OLAP	Online Analytical Processing	Xử lý phân tích trực tuyến
33	Q1	First Quartile	Tứ phân vị thứ nhất
34	Q3	Third Quartile	Tứ phân vị thứ ba
35	RAM	Random Access Memory	Bộ nhớ truy cập ngẫu nhiên
36	RF	Random Forest	Rừng ngẫu nhiên
37	SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật lấy mẫu quá mức tổng hợp lớp thiểu số
38	TH1, TH2, TH3	–	Trường hợp 1, 2 và 3: ba bộ dữ liệu dùng để phân loại (bộ dữ liệu gốc; gốc cộng ba thuộc tính từ luật của thuật toán thắng trong cặp CBA và CMAR; gốc cộng ba thuộc tính từ luật của CPAR)

39	TN	True Negative	Âm tính thật (dự đoán Rejected, thực tế Rejected)
40	TP	True Positive	Dương tính thật (dự đoán Approved, thực tế Approved)
41	USD	United States Dollar	Đô la Mỹ
42	XGBoost	eXtreme Gradient Boosting	Tăng cường độ dốc cực đại

DANH MỤC BẢNG BIỂU

Bảng 2.1. Các hạng điểm tín dụng theo FICO 10
Bảng 2.2. So sánh các phương pháp phân loại dựa trên luật kết hợp 19
Bảng 2.3. Tổng hợp các nghiên cứu liên quan 20
Bảng 2.4. Các biến đầu vào và khía cạnh tham chiếu 25
Bảng 3.1. Mô tả các biến trong tập dữ liệu 29
Bảng 3.2. Ngưỡng rời rạc hóa các biến số theo nghiệp vụ 31
Bảng 3.3. Tóm tắt các bước tiền xử lý 33
Bảng 3.4.Các bảng dimension 35
Bảng 3.5. Môi trường thực nghiệm 40
Bảng 4.1. Tổng quan bộ dữ liệu và kết quả làm sạch 41
Bảng 4.2. Thống kê mô tả các biến số (sau làm sạch) 42
Bảng 4.3. Mô tả các biến phân loại 43
Bảng 4.4. Phân phối biến mục tiêu loan_status 43
Bảng 4.5. Các cặp biến số có tương quan mạnh nhất 47
Bảng 4.6. Ngưỡng rời rạc hóa các biến số (ngưỡng nghiệp vụ) 49
Bảng 4.7. Các cặp thuộc tính rời rạc có Cramér's V cao nhất 49
Bảng 4.8. Kết quả chia dữ liệu 51
Bảng 4.9. Các bảng và khung nhìn trong kho dữ liệu 52
Bảng 4.10. Phép cắt lát (Slice) - tỉ lệ duyệt theo lịch sử vỡ nợ 53
Bảng 4.11. Phép gộp cấp (ROLLUP) học vấn rồi sở hữu nhà – khoản vay bình quân. 54
Bảng 4.12. Phép khối (CUBE) theo mục đích vay và giới tính – tỉ lệ được duyệt (%) 55
Bảng 4.13. Truy vấn 1 – Dư nợ đã duyệt theo mục đích vay 56
Bảng 4.14. Truy vấn 2 – Tỉ lệ được duyệt (%) theo điểm tín dụng và lịch sử vỡ nợ 57
Bảng 4.15. Truy vấn 3 – Năm nhóm (mục đích, sở hữu nhà) có tỉ lệ duyệt thấp nhất (n ≥ 500) 58
Bảng 4.16. Truy vấn 4 – Tỉ lệ được duyệt (%) của hồ sơ vi phạm và không vi phạm năng lực trả nợ (nhóm chưa từng vỡ nợ) 59
Bảng 4.17. So sánh Apriori và FP-Growth 61
Bảng 4.18. Ràng buộc khai phá và số luật lớp thu được 62
Bảng 4.19. Ví dụ minh họa – năm luật có lift cao nhất ở mỗi lớp 62
Bảng 4.20. So sánh CBA, CMAR và CPAR trên tập kiểm định 66

Bảng 4.21. Phân tích độ nhạy chi phí (chi phí = k × số dương tính giả + số âm tính giả, tập kiểm định) 68
Bảng 4.22. Kiểm chứng ba thuật toán dùng chung không gian luật Apriori 69
Bảng 4.23. Các luật được chọn làm thuộc tính mới 71
Bảng 4.24. Độ phủ của ba luật mỗi phương pháp trên toàn bộ dữ liệu 72
Bảng 4.25. Kết quả phân loại trên tập kiểm tra (lớp Approved) 73
Bảng 4.26. Ma trận nhầm lẫn trên tập kiểm tra 74
Bảng 4.27. Chênh lệch so với Bộ dữ liệu 1 (điểm phần trăm; dương tính giả tính theo số hồ sơ) 77
Bảng 4.28. Tổng hợp theo từng phần: làm gì, chọn gì, vì sao, kết quả chính 78
Bảng 4.29. Các điểm đưa tri thức ngành vào đề án 79
Bảng 5.1. Đối chiếu kết quả với mục tiêu nghiên cứu 83
Bảng 5.2. Hàm ý quản trị và khuyến nghị nghiệp vụ 85

DANH MỤC HÌNH ẢNH

Hình 3.1. Quy trình nghiên cứu 27
Hình 3.2. Phân phối tuổi 30
Hình 3.3. Mô hình Star Schema của Data Warehouse 34
Hình 4.1. Phân phối biến mục tiêu loan_status 44
Hình 4.2. Phân phối điểm tín dụng theo loan_status 44
Hình 4.3. Phân phối tỉ lệ khoản vay trên thu nhập theo loan_status 45
Hình 4.4. Phân phối thu nhập theo loan_status 45
Hình 4.5. Tỉ lệ duyệt theo lịch sử vỡ nợ, sở hữu nhà và mục đích vay 46
Hình 4.6. Ma trận tương quan Pearson giữa các biến số 48
Hình 4.7. Ma trận Cramér's V giữa các thuộc tính rời rạc 50
Hình 4.8. Mô hình hình sao (star schema) của kho dữ liệu hồ sơ vay 52
Hình 4.9. Phép cắt lát (Slice) – tỉ lệ duyệt theo lịch sử vỡ nợ 53
Hình 4.10. Phép gộp cấp (ROLLUP) – khoản vay bình quân theo học vấn và sở hữu nhà 55
Hình 4.11. Phép khối (CUBE) – tỉ lệ được duyệt theo mục đích vay và giới tính 56
Hình 4.12. Truy vấn 1 – Dư nợ đã duyệt theo mục đích vay 57
Hình 4.13. Truy vấn 2 – Tỉ lệ được duyệt theo điểm tín dụng và lịch sử vỡ nợ 58
Hình 4.14. Truy vấn 3 – Năm nhóm có tỉ lệ duyệt thấp nhất 59
Hình 4.15. Truy vấn 4 – Tỉ lệ được duyệt của hồ sơ vi phạm và không vi phạm năng lực trả nợ 60
Hình 4.16. Phân bố support, confidence và lift của các luật lớp 64
Hình 4.17. Ma trận nhầm lẫn của CBA, CMAR và CPAR trên tập kiểm định (A: Approved, R: Rejected) 67
Hình 4.18. So sánh điểm F0.5, precision và recall của CBA, CMAR, CPAR 67
Hình 4.19. Độ nhạy chi phí của CBA, CMAR và CPAR theo tỉ lệ k 68
Hình 4.20. Độ phủ dữ liệu và độ phủ lớp Approved của các luật được chọn 72
Hình 4.21. Điểm F0.5 lớp Approved trên tập kiểm tra theo bộ dữ liệu và mô hình 75
Hình 4.22. Precision lớp Approved trên tập kiểm tra theo bộ dữ liệu và mô hình 76
Hình 4.23. Ma trận nhầm lẫn của chín tổ hợp bộ dữ liệu và mô hình trên tập kiểm tra (A: Approved, R: Rejected) 76
Hình 5.1. Tóm tắt quy trình nghiên cứu và các kết quả chính 83

CHƯƠNG 1. GIỚI THIỆU VẤN ĐỀ NGHIÊN CỨU

1.1. Giới thiệu chung về bối cảnh

Trong hoạt động của các tổ chức tín dụng, quy trình duyệt vay (loan approval process) giữ vai trò trung tâm, vừa là cửa ngõ tạo ra doanh thu từ lãi vay, vừa là tuyến phòng thủ đầu tiên trong hệ thống quản trị rủi ro tín dụng. Mỗi quyết định phê duyệt hay từ chối một hồ sơ vay không chỉ ảnh hưởng trực tiếp đến chất lượng danh mục tín dụng (credit portfolio quality) mà còn tác động đến tỷ lệ nợ xấu (Non-Performing Loan - NPL), hệ số an toàn vốn và uy tín của tổ chức trên thị trường. Do đó, việc xây dựng một quy trình thẩm định và ra quyết định duyệt vay vừa chính xác, vừa nhất quán và có khả năng mở rộng theo quy mô hồ sơ là một yêu cầu mang tính sống còn đối với năng lực cạnh tranh của bất kỳ tổ chức tín dụng nào.

Xét theo tiến trình phát triển, phương thức ra quyết định duyệt vay tại các tổ chức tín dụng có thể được phân chia thành ba giai đoạn tiếp nối nhau. Giai đoạn thứ nhất là duyệt vay thủ công (manual underwriting), trong đó cán bộ tín dụng đánh giá hồ sơ dựa trên kinh nghiệm cá nhân và các tiêu chí định tính; phương thức này linh hoạt nhưng phụ thuộc nhiều vào chủ quan của người thẩm định và khó đảm bảo tính nhất quán khi số lượng hồ sơ tăng lên. Giai đoạn thứ hai là duyệt vay dựa trên quy tắc (rule-based scoring), trong đó tổ chức tín dụng thiết lập các ngưỡng và điều kiện cố định (ví dụ: điểm tín dụng tối thiểu, tỷ lệ nợ trên thu nhập tối đa) để tự động hoá một phần quyết định; cách tiếp cận này cải thiện tốc độ xử lý nhưng lại cứng nhắc, khó thích ứng với những mối quan hệ phi tuyến tính và tương tác phức tạp giữa các biến số tài chính. Giai đoạn thứ ba, đang diễn ra mạnh mẽ trong khoảng ba năm trở lại đây, là duyệt vay dựa trên mô hình học máy và trí tuệ nhân tạo (Machine Learning/AI-based underwriting), trong đó các thuật toán khai phá dữ liệu (data mining) được sử dụng để học các mẫu hình (pattern) ẩn trong dữ liệu lịch sử nhằm dự đoán khả năng trả nợ và phân loại rủi ro của khách hàng một cách có hệ thống (Hoàng et al., 2026).

Xu hướng ứng dụng data mining và học máy trong lĩnh vực tài chính - tín dụng đã trở nên phổ biến rõ rệt trong giai đoạn gần đây, khi các tổ chức tín dụng đẩy mạnh chuyển đổi số nhằm rút ngắn thời gian xử lý hồ sơ, tối ưu mô hình chấm điểm rủi ro (credit risk scoring) và cá nhân hoá quyết định tín dụng. Các kỹ thuật khai phá luật kết hợp (association rule mining) và phân lớp (classification) ngày càng được khai thác

không chỉ để dự đoán khả năng được duyệt vay của khách hàng, mà còn để phát hiện những mối quan hệ tiềm ẩn giữa các đặc điểm nhân khẩu học, tài chính và hành vi vay vốn - những tri thức mà các phương pháp thủ công hoặc rule-based truyền thống khó có thể khai thác một cách hệ thống và đầy đủ.

1.2. Vấn đề nghiên cứu và sự cần thiết

Mặc dù sự dịch chuyển công nghệ trong ngành tín dụng đã diễn ra mạnh mẽ, việc triển khai thực tế quy trình phê duyệt khoản vay tại các tổ chức tài chính vẫn đang vấp phải những bất cập nghiêm trọng. Các phương thức thẩm định truyền thống như phê duyệt thủ công vừa tốn kém thời gian, chi phí vận hành, vừa phụ thuộc vào cảm quan chủ quan, gây ra sự thiếu nhất quán giữa các hồ sơ có đặc điểm tương đồng. Trong khi đó, các hệ thống phê duyệt dựa trên quy tắc cố định lại bộc lộ tính cứng nhắc, không thể bắt trọn các mối quan hệ phi tuyến phức tạp giữa nhiều biến số tài chính. Đáng chú ý, khi các tổ chức tín dụng tiến lên ứng dụng các mô hình học máy và khai phá dữ liệu thuần túy dựa trên thống kê, một nguy cơ lớn xuất hiện là mô hình sẽ vô tình học thuộc và duy trì các quyết định xét duyệt sai lầm trong quá khứ, dẫn đến việc tiếp tục cấp tín dụng cho các hồ sơ ẩn chứa rủi ro cao.

Minh chứng thực nghiệm từ bộ dữ liệu Loan Approval Classification Data với 45,000 hồ sơ vay (44,990 hồ sơ sau khi làm sạch) đã phản ánh rõ nét thực trạng này. Phân tích khám phá dữ liệu cho thấy giá trị trung bình của điểm tín dụng giữa hai nhóm gần như trùng nhau (631.9 và 632.8), tức là biến này không đủ để phân tách khi xét đơn lẻ. Bên cạnh đó, kết quả truy vấn qua khung nhìn chính sách trong Kho dữ liệu theo mô hình hình sao chỉ ra rằng có đến 85.5% đến 100% hồ sơ vi phạm nghiêm trọng nguyên tắc an toàn năng lực trả nợ vẫn được phê duyệt trong lịch sử. Nếu khai phá luật kết hợp đơn thuần dựa trên các chỉ số thống kê mà không lọc qua tri thức ngành, những luật có độ tin cậy và độ nâng cao nhất ban đầu lại chứa tới 23.3% số hồ sơ vi phạm gánh nặng nợ. Từ thực trạng đó, vấn đề nghiên cứu cốt lõi được xác định là làm thế nào để khai phá hiệu quả các tổ hợp thuộc tính đa biến phức tạp trong dữ liệu duyệt vay, đồng thời tích hợp chặt chẽ tri thức ngành và chính sách tín dụng vào quy trình khai phá dữ liệu và phân loại dựa trên luật kết hợp, nhằm xây dựng một hệ thống hỗ trợ ra quyết định vừa đạt hiệu năng dự đoán cao, vừa đảm bảo tính diễn giải và tính tuân thủ quy định quản trị rủi ro.

Việc thực hiện đề tài là cực kỳ cấp thiết nhằm giải quyết triệt để vấn đề nghiên cứu nêu trên, xuất phát từ cả yêu cầu thực tiễn lẫn giá trị thực nghiệm vượt trội do bộ dữ liệu 45,000 hồ sơ mang lại. Dữ liệu phản ánh đúng thực trạng mất cân bằng lớp nghiêm trọng trong xét duyệt tín dụng thực tế với 77.77% hồ sơ bị từ chối và 22.23% hồ sơ được chấp thuận. Đặc điểm này củng cố tính cấp thiết phải thay đổi thước đo đánh giá sang điểm F0.5 nhằm ưu tiên độ chuẩn xác precision để giảm thiểu rủi ro duyệt nhầm. Bên cạnh đó, thuộc tính lịch sử vỡ nợ đóng vai trò là rào cản tuyệt đối khi toàn bộ hồ sơ từng vỡ nợ đều bị từ chối, nhưng nhóm chưa từng vỡ nợ vẫn có 54.8% hồ sơ bị từ chối, khẳng định chưa vỡ nợ chỉ là điều kiện cần chứ chưa đủ và đặt ra nhu cầu cấp thiết phải khai phá các tổ hợp thuộc tính đa biến như tỷ lệ khoản vay trên thu nhập, lãi suất, thu nhập, hình thức sở hữu nhà và mục đích vay.

Đề tài đáp ứng nhu cầu cấp thiết của các tổ chức tín dụng trong việc xây dựng một quy trình khai phá dữ liệu có kiểm soát tri thức, kết hợp sức mạnh của kho dữ liệu đa chiều với các thuật toán khai phá luật kết hợp như Apriori, FP-Growth và phân loại dựa trên luật kết hợp như CBA, CMAR, CPAR. Việc tích hợp khung nhìn chính sách v_policy để lọc luật giúp loại bỏ các luật đúng về thống kê nhưng sai về nghiệp vụ. Kết quả thực nghiệm chứng minh mô hình CPAR đạt điểm F0.5 bằng 75.74 trên tập kiểm định, đồng thời mô hình Random Forest trên bộ dữ liệu gốc đạt điểm F0.5 cao nhất là 80.08, trong khi việc bổ sung thuộc tính sinh từ luật không làm thay đổi đáng kể kết quả phân loại. Nếu tiếp tục duy trì quy trình thẩm định thiếu kiểm soát, các tổ chức tín dụng sẽ đối mặt với nguy cơ gia tăng tỷ lệ nợ xấu do chấp thuận nhầm hồ sơ rủi ro cao, chi phí vận hành kéo dài và suy giảm trải nghiệm khách hàng cũng như năng lực cạnh tranh. Việc xác lập vấn đề dựa trên dữ liệu thực chứng sẽ tạo tiền đề lý luận trực tiếp cho thiết kế kho dữ liệu, triển khai thực nghiệm OLAP, lọc luật chính sách và hướng tới ứng dụng hệ thống xét duyệt hai lớp trong thực tiễn.

1.3. Mục tiêu của đề án

Mục tiêu chung của đề án là xây dựng một quy trình phân tích dữ liệu duyệt vay toàn diện, đi từ phân tích thăm dò dữ liệu (EDA), mô hình hoá và lưu trữ dữ liệu dưới dạng kho dữ liệu (Data Warehouse), đến việc xây dựng các mô hình khai phá luật kết hợp và mô hình dự đoán, nhằm cung cấp cơ sở dữ liệu và tri thức hỗ trợ ra quyết định cho quy trình duyệt vay.

Để hiện thực hoá mục tiêu chung nêu trên, đề án xác định năm mục tiêu cụ thể như sau:

a. Phân tích đặc điểm, cấu trúc dữ liệu và thực hiện làm sạch, tiền xử lý bộ dữ liệu duyệt vay nhằm đảm bảo chất lượng dữ liệu đầu vào cho các bước phân tích tiếp theo.
b. Thiết kế và xây dựng kho dữ liệu (Data Warehouse) theo mô hình lược đồ hình sao (star schema), phục vụ việc lưu trữ và truy vấn đa chiều (OLAP) thông tin hồ sơ duyệt vay.
c. Khai phá các tập phổ biến (frequent itemsets) và luật kết hợp (association rules) nhằm phát hiện các mối quan hệ ẩn giữa các đặc điểm khách hàng và kết quả duyệt vay.
d. Xây dựng và đánh giá các mô hình phân lớp (classification) nhằm phục vụ dự đoán và phân loại rủi ro tín dụng của khách hàng.
e. Đề xuất các insight và khuyến nghị nghiệp vụ thiết thực nhằm hỗ trợ tổ chức tín dụng cải thiện quy trình duyệt vay.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu là các phương pháp và quy trình phân tích dữ liệu được áp dụng cho bài toán phê duyệt khoản vay, tập trung vào phân tích khám phá dữ liệu, thiết kế kho dữ liệu, khai phá luật kết hợp, phân loại.

1.4.2. Phạm vi dữ liệu

Nghiên cứu sử dụng bộ dữ liệu Loan Approval Classification Data được cung cấp dưới dạng tệp CSV, gồm 45,000 bản ghi và 14 biến. Các biến bao gồm thông tin cá nhân (tuổi, giới tính), trình độ học vấn, thu nhập, kinh nghiệm làm việc, hình thức sở hữu nhà ở, số tiền vay, mục đích vay, lãi suất, tỷ lệ khoản vay trên thu nhập, thời gian lịch sử tín dụng, điểm tín dụng, lịch sử vỡ nợ trước đây và trạng thái khoản vay.

Cụ thể, biến mục tiêu là loan_status; các biến còn lại được xem xét như những thuộc tính đầu vào phục vụ phân tích. Biến mục tiêu loan_status nhận giá trị 1 (được duyệt) và 0 (bị từ chối). Cần lưu ý đây là quyết định xét duyệt trong quá khứ, không phản ánh việc khách hàng có trả được nợ hay không.

1.4.3. Phạm vi nội dung

Nghiên cứu tập trung vào các nội dung sau:

- Phân tích khám phá và đánh giá chất lượng dữ liệu.
- Tiền xử lý dữ liệu và chuẩn bị dữ liệu cho các kỹ thuật khai phá.
- Thiết kế mô hình kho dữ liệu và thực hiện các truy vấn phân tích phù hợp.
- Khai phá tập mục phổ biến và luật kết hợp bằng Apriori và FP-Growth, có tích hợp ràng buộc chính sách tín dụng.
- So sánh các thuật toán phân lớp dựa trên luật kết hợp (CBA, CMAR, CPAR).
- Xây dựng thuộc tính mới từ luật kết hợp và đánh giá hiệu quả trên các mô hình phân lớp (Logistic Regression, Random Forest, Gradient Boosting).

Nghiên cứu được thực hiện trong phạm vi dữ liệu hiện có, không bao gồm việc tích hợp vào hệ thống vận hành của ngân hàng, triển khai thử nghiệm với khách hàng thực tế hoặc chứng minh hiệu quả kinh doanh sau triển khai.

1.5. Ý nghĩa và đóng góp của đề tài

Về mặt lý thuyết: Đề án góp phần minh hoạ một quy trình khai phá dữ liệu (data mining) chuẩn hoá và hoàn chỉnh theo hướng end-to-end, đi từ dữ liệu thô (raw data) qua các bước tiền xử lý, mô hình hoá dữ liệu đa chiều trong kho dữ liệu, đến khai phá luật kết hợp và xây dựng mô hình dự đoán, từ đó chuyển hoá dữ liệu thành tri thức nghiệp vụ có thể diễn giải được. Đây cũng là cơ hội để vận dụng đồng thời nhiều kỹ thuật đã học trong lĩnh vực khai phá dữ liệu và học máy thống kê vào một bài toán ứng dụng cụ thể trong lĩnh vực tài chính - tín dụng.

Về mặt thực tiễn: Các kết quả phân tích và insight rút ra từ đề án - bao gồm các luật kết hợp có ý nghĩa nghiệp vụ, các mô hình phân loại khách hàng theo mức độ rủi ro - có thể được các tổ chức tín dụng tham khảo nhằm hỗ trợ rút ngắn thời gian duyệt vay, nâng cao tính nhất quán trong việc ra quyết định và cải thiện chất lượng quản trị rủi ro tín dụng.

1.6. Phương pháp nghiên cứu đề án

Đề án thực hiện theo quy trình nghiên cứu gồm các bước tuần tự:

(1) Dữ liệu gốc (45,000 hồ sơ)

(2) EDA & làm sạch dữ liệu

(3) Tiền xử lý & kiểm tra đa cộng tuyến (Rời rạc hóa, Pearson, Cramér's V)

(4) Từ bước 3, quy trình chia làm 2 nhánh song song:

(a) Nhánh 1: Kho dữ liệu - Mô tả danh mục, cung cấp tiêu chí chính sách

(i) Xây dựng Data Warehouse (Star schema, view chính sách)

(ii) OLAP & truy vấn thực tế (Slice, ROLLUP, CUBE, biểu đồ)

(b) Nhánh 2: Khai phá luật và phân loại

(i) Chia dữ liệu train / val / test (Tỉ lệ 60 / 20 / 20)

(ii) Khai phá luật kết hợp (Apriori và FP-Growth)

(iii) Phân lớp dựa trên luật (CBA, CMAR vs CPAR (F0.5))

(iv) Chọn 3 luật -> 3 thuộc tính mới (lọc chính sách, tính độ phủ). Có sự kiểm tra chính sách từ bước "Xây dựng Data Warehouse".

(v) Phân lớp trên 3 bộ dữ liệu (TH1, TH2, TH3 x LR, RF, GB)

(5) Hai nhánh tổng hợp lại ở bước cuối: Đánh giá & kết luận

Về công cụ thực hiện, đề án sử dụng ngôn ngữ lập trình Python trên Google Colab với các thư viện pandas, scikit-learn và mlxtend cho các tác vụ xử lý, khai phá dữ liệu và xây dựng mô hình. Chi tiết môi trường thực nghiệm được trình bày ở mục 3.2.7. Khai thác trực tiếp bộ dữ liệu "Loan Approval Classification Data" đã được công bố sẵn trên nền tảng Kaggle.

Về phương pháp phân tích dữ liệu, đề án kết hợp thống kê mô tả và trực quan hóa dữ liệu trong giai đoạn EDA; thuật toán Apriori và FP-Growth trong giai đoạn khai phá luật kết hợp cùng các thuật toán CBA, CMAR và CPAR trong giai đoạn phân lớp dựa trên luật; và Logistic Regression, Random Forest, Gradient Boosting trong giai đoạn đánh giá thuộc tính sinh từ luật.

1.7. Bố cục của đề án

Đề án gồm năm chương như sau:

- Chương 1 - Giới thiệu vấn đề nghiên cứu: trình bày bối cảnh, vấn đề nghiên cứu, mục tiêu, đối tượng, phạm vi, ý nghĩa và phương pháp nghiên cứu tổng quát của đề án.
- Chương 2 - Cơ sở lý thuyết và tổng quan tài liệu: hệ thống hóa các khái niệm, lý thuyết nền tảng liên quan đến chấm điểm tín dụng, kho dữ liệu, khai phá luật kết hợp và các nghiên cứu trước có liên quan.
- Chương 3 - Phương pháp nghiên cứu: trình bày quy trình nghiên cứu chi tiết, thiết kế biến, thiết kế kho dữ liệu (star schema) và phương pháp phân tích dữ liệu áp dụng trong đề án.

- Chương 4 - Dữ liệu và kết quả thực nghiệm: trình bày và phân tích các kết quả thu được từ EDA, tiền xử lý, xây dựng kho dữ liệu, khai phá luật kết hợp và các mô hình phân lớp..
- Chương 5 - Kết luận và khuyến nghị: tổng hợp các kết quả đạt được so với mục tiêu đề ra, nêu rõ những hạn chế của đề án và đề xuất hướng phát triển trong tương lai.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Định nghĩa các khái niệm chính

2.1.1. Dự đoán duyệt vay

Dự đoán duyệt vay là bài toán phân loại nhị phân (binary classification), trong đó mục tiêu là xác định một hồ sơ vay thuộc lớp được chấp thuận (Approved) hay bị từ chối (Rejected) dựa trên các đặc trưng được cung cấp. Trong bài toán này, biến mục tiêu là trạng thái khoản vay (loan_status) với hai giá trị Approved và Rejected; các biến còn lại mô tả thông tin cá nhân, lịch sử tín dụng, nguồn lực tài chính và đặc điểm khoản vay. Dạng bài toán này được sử dụng rộng rãi trong chấm điểm tín dụng (Hand & Henley, 1997).

Xét tập dữ liệu gồm n quan sát:

$$D = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}, \quad y_i \in \{0, 1\}$$

Trong đó x_i là tập đặc trưng của hồ sơ thứ i và y_i là nhãn lớp. Lớp Approved được xem là lớp dương (positive). Mục tiêu là xây dựng hàm ánh xạ từ không gian đặc trưng sang không gian nhãn:

$$f: X \to Y$$

sao cho mô hình dự đoán được nhãn của hồ sơ mới. Kết quả dự đoán được tổng hợp trong ma trận nhầm lẫn (confusion matrix) với bốn trường hợp:

- True Positive (TP): dự đoán Approved, thực tế Approved.
- True Negative (TN): dự đoán Rejected, thực tế Rejected.
- False Positive (FP): dự đoán Approved, thực tế Rejected.
- False Negative (FN): dự đoán Rejected, thực tế Approved.

Từ đó tính các chỉ số đánh giá phổ biến:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}, F_1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

Trên tập dữ liệu có mất cân bằng lớp, một bộ phân loại luôn dự đoán lớp đa số vẫn có thể đạt độ chính xác ($Accuracy$) bằng đúng tỷ trọng của lớp đó mà không phân biệt được các đối tượng thuộc lớp thiểu số (He & Garcia, 2009). Giá trị này được gọi là đường cơ sở của lớp đa số (majority-class baseline). Do đó, độ chính xác đơn thuần không đủ để kết luận mô hình nhận diện tốt các lớp; $Accuracy$ cần được đánh giá cùng confusion matrix cũng như các chỉ số $Precision$, $Recall$ và F_1 của lớp thiểu số. Trong tín dụng, FP (duyệt nhầm) và FN (từ chối nhầm) có chi phí nghiệp vụ khác nhau, nên việc diễn giải các chỉ số phải gắn với mục tiêu quản trị rủi ro cụ thể.

2.1.2. F-beta và ma trận chi phí

Bên cạnh Accuracy, Precision, Recall và F1, chỉ số F-beta cho phép điều chỉnh mức độ ưu tiên giữa Precision và Recall thông qua tham số β. Công thức được xác định như sau (Sokolova & Lapalme, 2009):

$$F_\beta = (1 + \beta^2) \times Precision \times Recall \,/\, (\beta^2 \times Precision + Recall)$$

Khi β = 1, F-beta trở thành F1, cân bằng giữa Precision và Recall. Khi β < 1, chỉ số ưu tiên Precision hơn Recall; cụ thể, F0.5 phù hợp khi việc hạn chế dự đoán dương tính sai được đặt nặng hơn việc nhận diện toàn bộ trường hợp dương tính. Trong bài toán duyệt vay, nếu quy ước Approved là lớp dương, False Positive (FP) là hồ sơ thực tế thuộc lớp Rejected nhưng mô hình dự đoán Approved. Đây là loại sai số cần chú ý vì có thể khiến ngân hàng chấp thuận hồ sơ không đáp ứng tiêu chí được mô hình học từ dữ liệu.

Tuy nhiên, F0.5 không trực tiếp biểu thị tổn thất tài chính. Theo cách tiếp cận phân loại có xét chi phí, ma trận chi phí gán mức tổn thất khác nhau cho từng loại dự đoán sai; quyết định phân loại có thể được lựa chọn nhằm giảm chi phí kỳ vọng thay vì chỉ tối đa hóa một chỉ số thống kê (Elkan, 2001).

Nếu C_FP là chi phí của một trường hợp FP và C_FN là chi phí của một trường hợp FN, tổng chi phí sai phân loại có thể được tính như sau:

$$Cost = C_FP \times FP + C_FN \times FN$$

Trong đó, FN là hồ sơ thực tế thuộc lớp Approved nhưng bị mô hình dự đoán là Rejected. Giá trị C_FP và C_FN cần được xác định dựa trên dữ liệu hoặc giả định nghiệp vụ có giải thích rõ ràng; không nên mặc định một mức chi phí cụ thể khi chưa có căn cứ. F0.5 và ma trận chi phí bổ trợ cho nhau: F0.5 nhấn mạnh precision, còn ma trận chi phí thể hiện hậu quả tương đối của các loại sai số.

2.1.3. Điểm tín dụng

Điểm tín dụng (credit score) là chỉ số định lượng tóm lược mức độ tín nhiệm của người vay dựa trên lịch sử tín dụng; điểm cao hơn nhìn chung phản ánh hồ sơ thuận lợi hơn. Một hệ điểm phổ biến là FICO Score của Fair Isaac Corporation. Thang điểm này nằm trong khoảng 300–850 và được tính từ các yếu tố: lịch sử thanh toán, mức sử dụng hạn mức tín dụng, độ dài lịch sử tín dụng, số khoản tín dụng mới và cơ cấu các loại tín dụng (U.S. Bank, 2025).

FICO chia thang điểm thành năm hạng như Bảng 2.1. Đây là các ngưỡng do tổ chức chấm điểm công bố, nên mỗi hạng mang ý nghĩa nghiệp vụ xác định. Trong các mô hình chấm điểm (scorecard), một đặc trưng liên tục thường được chia thành các nhóm giá trị (binning) để thuận tiện cho diễn giải và phân tích (Siddiqi, 2006).

Bảng 2.1. Các hạng điểm tín dụng theo FICO

Hạng	Khoảng điểm (theo FICO)	Thực tế trong dữ liệu	Số hồ sơ	Tỉ trọng
Poor	< 580	390 – 579	6,901	15.3%
Fair	580 – 669	580 – 669	26,806	**59.6%**
Good	670 – 739	670 – 739	11,193	24.9%
VeryGood	≥ 740	740 – 784	90	0.2%

2.1.4. Kho dữ liệu và mô hình hình sao

Kho dữ liệu (Data Warehouse – DW) là hệ thống lưu trữ được tổ chức để phục vụ phân tích và hỗ trợ ra quyết định. Theo Inmon (2005), DW có bốn đặc tính: hướng

chủ đề (subject-oriented), tích hợp (integrated), biến đổi theo thời gian (time-variant) và tương đối ổn định (non-volatile).

Dữ liệu trong DW thường được khai thác bằng phân tích trực tuyến (Online Analytical Processing – OLAP) với các phép tổng hợp, drill-down, roll-up, slice và dice (Han et al., 2011).

Mô hình sao (Star Schema) là mô hình phổ biến của dimensional modeling, trong đó bảng dữ kiện (Fact Table) nằm ở trung tâm và liên kết trực tiếp với các bảng chiều (Dimension Tables) xung quanh (Kimball & Ross, 2013). Fact Table lưu các sự kiện ở một mức chi tiết (grain) xác định, gồm khóa ngoại đến các chiều và các đại lượng đo lường (measures). Dimension Tables chứa các thuộc tính mô tả ngữ cảnh, dùng để lọc, nhóm và phân tích measures. Star Schema có cấu trúc đơn giản, thuận lợi cho truy vấn tổng hợp đa chiều và phù hợp khi mục tiêu chính là phân tích thay vì xử lý giao dịch.

2.1.5. Chiều suy biến

Chiều suy biến (degenerate dimension) là một khóa chiều được lưu trực tiếp trong Fact Table nhưng không có bảng chiều tương ứng (Kimball & Ross, 2013). Trường hợp này thường gặp với các mã định danh giao dịch như số hóa đơn hay số đơn hàng. Các mã này không mang thêm thuộc tính mô tả nào ngoài chính giá trị của chúng, nên việc tách thành bảng chiều riêng không tạo thêm thông tin. Dù vậy, chúng vẫn hữu ích để nhóm các dòng dữ kiện thuộc cùng một giao dịch và truy ngược về hệ thống nguồn.

2.1.6. Các phép tổng hợp OLAP: ROLLUP và CUBE

Trong phân tích đa chiều, ROLLUP và CUBE là các phép tổng hợp hỗ trợ tạo các mức tổng phụ và tổng chung từ những chiều dữ liệu được chọn. ROLLUP tạo các mức tổng hợp theo thứ tự phân cấp của các cột, phù hợp với phân tích từ cấp chi tiết lên cấp tổng quát. CUBE tạo các tổ hợp tổng hợp trên các chiều được chỉ định, qua đó hỗ trợ so sánh dữ liệu theo nhiều tổ hợp chiều khác nhau (Microsoft, n.d.).

Kết quả tổng hợp bằng ROLLUP và CUBE giúp mô tả dữ liệu ở nhiều mức độ chi tiết khác nhau, nhưng tự nó không chứng minh quan hệ nhân quả giữa các biến; CUBE có thể hỗ trợ xem xét các tổ hợp như trạng thái duyệt vay, nhóm điểm tín dụng

và mục đích vay. Việc sử dụng các phép này phụ thuộc vào cấu trúc bảng và câu truy vấn thực tế. Kết quả tổng hợp giúp mô tả dữ liệu ở nhiều mức độ.

2.1.7. Khai phá luật kết hợp (Association Rule Mining)

Khai phá luật kết hợp (Association Rule Mining – ARM) là kỹ thuật phát hiện các mẫu xuất hiện đồng thời giữa các mục (items) trong dữ liệu. Khái niệm này được đề xuất bởi Agrawal, Imieliński và Swami (1993) và được phát triển thành thuật toán Apriori bởi Agrawal và Srikant (1994). Một luật kết hợp có dạng X ⇒ Y, trong đó X là tiền đề (antecedent), Y là hệ quả (consequent), X, Y ⊆ I và X ∩ Y = ∅. Chất lượng luật được đánh giá bằng ba độ đo, với N là tổng số bản ghi:

$$Support(X \Rightarrow Y) = \frac{\sigma(X \cup Y)}{N}$$

$$Confidence(X \Rightarrow Y) = Support(X \cup Y) \,/\, Support(X) = P(Y \mid X)$$

$$\begin{aligned} Lift(X \Rightarrow Y) &= Confidence(X \Rightarrow Y) \,/\, Support(Y) \\ &= P(X \cap Y) \,/\, [P(X) \cdot P(Y)] = P(Y \mid X) \,/\, P(Y) \end{aligned}$$

Support là tỷ lệ bản ghi chứa đồng thời X và Y; Confidence là xác suất bản ghi chứa Y khi đã chứa X; Lift so sánh mức xuất hiện đồng thời của X và Y với mức kỳ vọng khi hai vế độc lập. Lift > 1 cho thấy X và Y đi cùng nhau nhiều hơn kỳ vọng, Lift = 1 tương ứng với độc lập, Lift < 1 cho thấy đi cùng nhau ít hơn kỳ vọng.

Với dữ liệu mất cân bằng, hệ quả là lớp đa số dễ có Support và Confidence cao chỉ vì lớp đó vốn phổ biến. Do đó, Lift được dùng bổ sung để nhận biết luật thực sự làm thay đổi xác suất của lớp so với mức nền. Lift còn bị chặn trên bởi 1/P(Y), do đó chỉ nên so sánh trực tiếp chỉ số Lift giữa các luật có cùng vế hệ quả (cùng nhãn lớp).

2.1.8. Hệ số chắc chắn

Hệ số chắc chắn (Certainty Factor – CF) bắt nguồn từ hệ chuyên gia MYCIN. Trong hệ thống này, CF được dùng để biểu diễn mức độ mà một bằng chứng làm tăng hoặc giảm niềm tin vào một giả thuyết (Shortliffe & Buchanan, 1975). Berzal và cộng sự (2002) đề xuất dùng CF làm độ đo thay thế cho Confidence khi đánh giá luật kết hợp. CF đo mức thay đổi niềm tin vào Y khi biết X, có chuẩn hóa theo xác suất nền của Y:

- Nếu Confidence(X ⇒ Y) > Support(Y):
  CF(X ⇒ Y) = [Confidence(X ⇒ Y) − Support(Y)] / [1 − Support(Y)]
- Nếu Confidence(X ⇒ Y) < Support(Y):
  CF(X ⇒ Y) = [Confidence(X ⇒ Y) − Support(Y)] / Support(Y)
- Nếu Confidence(X ⇒ Y) = Support(Y):
  CF(X ⇒ Y) = 0

CF nhận giá trị trong đoạn [−1, 1]:

- CF > 0 cho thấy X làm tăng khả năng xảy ra Y so với mức nền. Khi CF = 1, mọi bản ghi chứa X đều chứa Y.
- CF = 0 tương ứng với X và Y độc lập.
- CF < 0 cho thấy X làm giảm khả năng xảy ra Y.

So với Lift, CF có miền giá trị cố định [−1, 1] và không bị chặn trên bởi 1/P(Y). Do đó, CF thuận lợi hơn khi cần so sánh các luật có hệ quả là những lớp có tỷ trọng khác nhau, đặc biệt trên dữ liệu mất cân bằng (Berzal et al., 2002). Tuy nhiên, CF chỉ phản ánh mối liên hệ quan sát được trong dữ liệu dùng để khai phá luật. Vì vậy, CF cần được xem xét cùng Support và khả năng khái quát hóa trên dữ liệu mới.

2.1.9. Khai phá luật kết hợp dựa trên ràng buộc

Khai phá luật kết hợp dựa trên ràng buộc (Constraint-based mining) là cách tiếp cận khai phá dữ liệu trong đó người phân tích xác định các điều kiện để tập trung quá trình tìm kiếm vào những mẫu phù hợp với mục tiêu nghiên cứu. Trong khai phá luật kết hợp, các ràng buộc có thể liên quan đến miền giá trị, thuộc tính, nhãn lớp hoặc điều kiện tổng hợp. Việc đưa ràng buộc vào quá trình khai phá có thể giúp giảm các kết quả không liên quan và tăng khả năng kiểm soát quá trình tìm kiếm (Ng et al., 1998).

Đối với bài toán phân loại duyệt vay, các ràng buộc có thể giới hạn nhãn lớp ở Approved hoặc Rejected, giới hạn số điều kiện trong tiền đề của luật, hoặc yêu cầu luật đáp ứng ngưỡng Support và Confidence đã xác định. Các điều kiện cụ thể phải phù hợp với thuật toán và công cụ thực tế được sử dụng. Ràng buộc quá chặt có thể loại bỏ những luật hữu ích; do đó, cần ghi rõ các ngưỡng và điều kiện đã áp dụng khi trình bày kết quả.

2.1.10. Phân loại dựa trên luật kết hợp

Phân loại dựa trên luật kết hợp (Associative Classification – AC) kết hợp khai phá luật kết hợp với phân loại. Khác với ARM tổng quát, AC giới hạn phần hệ quả của luật ở một nhãn lớp (Liu et al., 1998; Li et al., 2001; Thabtah, 2007). Các luật này gọi là Class Association Rules (CARs):

$$X \Rightarrow C_i, C_i \in C$$

Trong đó X là tập điều kiện trên thuộc tính của hồ sơ và C_i là một lớp trong tập nhãn C. CARs được khai phá từ dữ liệu huấn luyện, sau đó được chọn lọc, sắp xếp hoặc kết hợp theo một cơ chế phân loại để dự đoán lớp của hồ sơ mới. Ưu điểm của hướng này là mô hình ở dạng luật "nếu – thì", dễ diễn giải với người làm nghiệp vụ.

2.1.11. Rời rạc hóa dữ liệu (Discretization)

ARM và AC thường biểu diễn dữ liệu dưới dạng các item rời rạc, vì vậy các biến liên tục cần được chuyển thành các nhóm giá trị. Hai cách phổ biến là chia khoảng đều (equal-width) và chia theo phân vị (equal-frequency). Chia theo phân vị tạo các nhóm có số quan sát tương đối cân bằng và có thể hữu ích với các biến phân phối lệch như thu nhập; tuy nhiên, cách chia khoảng cần được lựa chọn theo phân phối dữ liệu và mục tiêu diễn giải (Han et al., 2011). Khi các điểm cắt được xác định từ tập huấn luyện, chúng cần được giữ nguyên khi áp dụng lên tập kiểm tra để hạn chế rò rỉ thông tin (data leakage).

Bên cạnh các phương pháp dựa trên phân phối dữ liệu, điểm cắt còn có thể được xác định từ tri thức chuyên môn hoặc từ ngưỡng nghiệp vụ đã được công nhận trong lĩnh vực ứng dụng. Cách tiếp cận này không sử dụng nhãn lớp khi xác định điểm cắt (Liu et al., 2002; García et al., 2013).

Ưu điểm chính là mỗi nhóm giá trị có ý nghĩa nghiệp vụ rõ ràng, nên các mẫu thu được dễ diễn giải và dễ đối chiếu với thực tiễn. Ngưỡng cũng được xác định độc lập với tập huấn luyện, nên không gây rò rỉ thông tin. Hạn chế là các nhóm có thể chênh lệch lớn về số quan sát; khi đó, một số nhóm khó đạt ngưỡng support tối thiểu trong khai phá luật kết hợp.

Ví dụ điển hình là điểm tín dụng FICO: thay vì chia theo phân vị, điểm được nhóm theo các ngưỡng 580, 670, 740 do FICO công bố (U.S. Bank, 2025). Một lưu ý là nhóm đã lược bỏ ngưỡng 800, bởi vì trong đề tài không có hồ sơ nào đạt 800 điểm (điểm cao nhất là 784), nên những hồ sơ từ 740 điểm trở lên được gộp chung vào ngưỡng từ 740 trở lên.

2.1.12. Đa cộng tuyến

Đa cộng tuyến (Multicollinearity) thường được bàn đến trong mô hình thống kê khi các biến giải thích có tương quan tuyến tính cao. Hệ số tương quan Pearson r có thể dùng để nhận diện các cặp biến số có quan hệ tuyến tính mạnh; ngưỡng $|r| \geq 0{,}8$ thường được sử dụng như một ngưỡng cảnh báo thực nghiệm. Với ARM, tương quan cao không vi phạm giả định toán học của thuật toán, nhưng các biến trùng lặp thông tin có thể tạo ra những luật dư thừa và làm giảm tính gọn nhẹ, rõ ràng của kết quả. Vì vậy, việc kiểm tra tương quan và xem xét loại hoặc thay thế các biến trùng lặp thông tin trước khi khai phá luật là cần thiết, tuy nhiên tương quan cao tự nó chưa đủ căn cứ để loại một biến nếu biến đó vẫn mang giá trị nghiệp vụ riêng.

2.1.13. Đo lường mối liên hệ giữa các biến bằng Cramér's V

Cramér's V là thước đo mức độ liên hệ giữa hai biến phân loại, được tính từ thống kê chi-bình phương của bảng chéo (Cramér, 1946; Bergsma, 2013):

$$V = \sqrt{[\chi^2 / (n \times min(r - 1, c - 1))]}$$

Trong đó, χ^2 là thống kê chi-bình phương của bảng chéo; n là số quan sát; r và c lần lượt là số nhóm của hai biến. Giá trị V nằm trong khoảng từ 0 đến 1, trong đó giá trị lớn hơn biểu thị mối liên hệ mạnh hơn theo thước đo này. Tuy nhiên, ước lượng Cramér's V truyền thống có thể bị chệch trong mẫu hữu hạn, đặc biệt với bảng chéo có nhiều nhóm và kích thước mẫu nhỏ; vì vậy, cần thận trọng khi diễn giải giá trị quan sát (Bergsma, 2013).

Trong khai phá luật kết hợp, Cramér's V có thể được sử dụng để khảo sát mối liên hệ giữa các biến phân loại hoặc các biến liên tục đã được rời rạc hóa. Kết quả có thể hỗ trợ nhận diện những biến có thông tin liên hệ mạnh và xem xét nguy cơ dư thừa

thông tin. Tuy nhiên, Cramér's V không trực tiếp đo đa cộng tuyến trong mô hình hồi quy, không xác định chiều tác động và không chứng minh quan hệ nhân quả. Do đó, không nên loại bỏ biến chỉ dựa trên một ngưỡng Cramér's V duy nhất.

2.2. Các lý thuyết liên quan

2.2.1. Thuật toán Apriori

Apriori (Agrawal & Srikant, 1994) khai phá các tập mục thường xuyên (frequent itemsets) dựa trên tính chất đóng xuống (Apriori property): nếu một tập mục là thường xuyên thì mọi tập con của nó cũng thường xuyên; ngược lại, nếu một tập mục không thường xuyên thì mọi tập cha của nó cũng không thể thường xuyên. Tính chất này cho phép loại sớm nhiều ứng viên. Thuật toán tìm kiếm theo từng mức kích thước itemset (theo chiều rộng) với ba bước lặp:

(1) **Sinh ứng viên:** tạo tập ứng viên k-itemset bằng cách nối các tập thường xuyên ở mức trước.
(2) **Tỉa cành:** loại ứng viên có ít nhất một tập con $(k-1)$ không thuộc L_{k-1}.
(3) **Đếm support:** quét dữ liệu, giữ các ứng viên thỏa ngưỡng support tối thiểu.

$$Ck = Lk-1 \bowtie Lk-1$$

$$Lk = \{c \in Ck : Support(c) \geq min_supp\}$$

Trong đó C_k là tập ứng viên k-itemset và L_k là tập k-itemset thường xuyên thỏa ngưỡng support; phép nối là bước đầu của việc sinh ứng viên và được theo sau bởi bước tỉa. Quá trình dừng khi không còn ứng viên mới. Từ các frequent itemsets, luật $X \Rightarrow Y$ được tạo ra và giữ lại nếu đạt ngưỡng confidence tối thiểu. Hạn chế của Apriori là phải quét dữ liệu nhiều lần và có thể sinh số lượng ứng viên rất lớn khi ngưỡng support thấp hoặc itemset dài.

2.2.2. Thuật toán FP-Growth

FP-Growth (Han et al., 2000) khai phá frequent itemsets mà không sinh ứng viên, theo chiến lược chia để trị. Thuật toán gồm hai bước:

(1) **Xây dựng FP-Tree:** quét dữ liệu lần một để đếm tần suất item và loại item dưới ngưỡng; sắp xếp item còn lại theo support giảm dần; quét lần hai để chèn

từng giao dịch vào cây. Các giao dịch chung tiền tố dùng chung nút, nên dữ liệu được nén.

(2) **Khai phá từ FP-Tree:** với mỗi item trong Header Table, xây dựng Conditional Pattern Base và Conditional FP-Tree rồi khai phá đệ quy, không cần quét lại dữ liệu gốc.

Về lý thuyết, FP-Growth tránh được việc sinh và kiểm tra số lượng lớn ứng viên. Tuy nhiên, thời gian chạy thực tế còn phụ thuộc vào kích thước dữ liệu, số item, ngưỡng support, giới hạn độ dài itemset và cấu trúc cài đặt thuật toán.

2.2.3. Các thuật toán phân loại dựa trên luật kết hợp: CBA, CMAR, CPAR

2.2.3.1. CBA (Classification Based on Associations) của Liu, Hsu và Ma (1998)

Thuật toán CBA (Classification Based on Associations) do Liu, Hsu và Ma (1998) đề xuất bao gồm 2 thành phần:

- **CBA-RG (Rule Generator):** dùng một biến thể của Apriori để khai phá các CARs $X \Rightarrow C_i$ thỏa ngưỡng support và confidence tối thiểu.
- **CBA-CB (Classifier Builder):** sắp xếp CARs theo độ ưu tiên: confidence cao hơn đứng trước; nếu bằng nhau thì support cao hơn đứng trước; nếu vẫn bằng nhau thì luật sinh ra trước đứng trước. Áp dụng database coverage pruning để bỏ các luật không đóng góp và dùng một lớp mặc định (default class) cho các hồ sơ không bị luật nào phủ. Khi phân loại, CBA dùng luật đầu tiên trong danh sách khớp với hồ sơ.

2.2.3.2. CMAR (Classification based on Multiple Association Rules) của Li, Han và Pei (2001)

CMAR (Classification based on Multiple Association Rules) do Li, Han và Pei (2001) đề xuất, khai thác đồng thời nhiều luật thay vì một luật đơn lẻ. Các thành phần chính:

- **CR-tree (Class Association Rule tree):** cấu trúc cây lưu các luật dùng chung tiền tố, giúp lưu trữ gọn và truy xuất nhanh.
- **Tỉa luật:** gồm ba bước: (1) general-rule pruning: loại luật cụ thể hơn khi đã có luật tổng quát hơn có thứ hạng cao hơn theo cơ chế xếp hạng luật của CMAR (confidence, rồi support, rồi độ dài tiền đề); (2) chỉ giữ các luật có tương quan

dương giữa tiền đề và lớp theo kiểm định chi-bình phương (χ^2); (3) database coverage: loại luật khi các hồ sơ huấn luyện đã được phủ đủ số lần quy định.

- **Phân loại:** với hồ sơ mới, CMAR lấy các luật khớp. Nếu tất cả cùng một lớp thì chọn lớp đó; nếu khác lớp, các luật được nhóm theo lớp và mỗi nhóm được chấm bằng weighted χ^2; lớp có điểm cao nhất được chọn:

$$weighted\ \chi^2 = \sum r \in G\ [\ (\chi^2(r))^2 / max\ \chi^2(r)\ ]$$

Trong đó G là nhóm luật khớp thuộc cùng một lớp và $max\chi^2(r)$ là cận trên của χ^2 của luật r. Công thức trên mô tả nguyên lý chấm điểm của CMAR. Việc tổng hợp nhiều luật giúp CMAR dùng nhiều bằng chứng cùng lúc.

Cơ chế phân loại dựa trên weighted χ^2

Một đặc điểm quan trọng của CMAR là kết hợp nhiều luật kết hợp phân lớp (*class-association rules*) thay vì dựa vào một luật riêng lẻ. Li, Han và Pei (2001) sử dụng phân tích χ^2 có trọng số để đánh giá tập luật hỗ trợ cho các lớp dự đoán. Về mặt ý tưởng, mức độ đóng góp của các luật được tổng hợp trong từng nhóm lớp, dựa trên độ mạnh của mối liên hệ giữa điều kiện của luật và lớp kết luận. Cách tiếp cận này giúp CMAR xem xét bằng chứng từ nhiều luật, thay vì chỉ lựa chọn luật có độ tin cậy cao nhất.

Trong cơ chế này, χ^2 được dùng để đánh giá mức độ liên hệ giữa việc một bản ghi thỏa mãn điều kiện của luật và việc bản ghi thuộc lớp tương ứng. Đại lượng $max\chi^2$ đóng vai trò giới hạn trên của thống kê χ^2 trong điều kiện các tần suất biên được giữ cố định; từ đó, CMAR chuẩn hóa đóng góp của luật khi tổng hợp mức hỗ trợ cho một lớp. Do cách tính phụ thuộc vào tần suất xuất hiện của điều kiện luật và lớp trong tập huấn luyện, không nên xem weighted χ^2 là một chỉ số độc lập với dữ liệu. Chi tiết công thức và quy trình phân loại được trình bày trong công trình gốc của Li và cộng sự (2001).

2.2.3.3. CPAR (Classification based on Predictive Association Rules)

CPAR (Classification based on Predictive Association Rules) là phương pháp phân loại dựa trên các luật kết hợp dự báo, được đề xuất bởi Yin và Han (2003) nhằm kết hợp ưu điểm của associative classification với các phương pháp phân loại dựa trên

luật truyền thống. Thay vì sinh một số lượng lớn luật ứng viên rồi mới lựa chọn, CPAR sử dụng chiến lược tham lam (*greedy strategy*) để trực tiếp xây dựng các luật từ dữ liệu huấn luyện. Phương pháp đánh giá luật bằng độ chính xác kỳ vọng (*expected accuracy*) nhằm hạn chế hiện tượng quá khớp, đồng thời sử dụng (k) luật tốt nhất để dự đoán lớp của một bản ghi mới. Nhờ đó, CPAR hướng đến sự cân bằng giữa khả năng dự báo và chi phí xử lý. Tuy nhiên, hiệu quả của phương pháp vẫn phụ thuộc vào dữ liệu, cách thiết lập tham số và tiêu chí đánh giá; vì vậy, không thể mặc định CPAR luôn vượt trội so với CBA hoặc CMAR trong mọi bài toán (Yin & Han, 2003).

Bảng 2.2. So sánh các phương pháp phân loại dựa trên luật kết hợp

Tiêu chí	CBA	CMAR	CPAR
Cơ sở phương pháp	Khai thác luật kết hợp phân lớp (CAR) và xây dựng bộ phân loại từ các luật này	Khai thác nhiều luật kết hợp phân lớp và tổng hợp bằng chứng từ nhiều luật	Xây dựng trực tiếp các luật dự báo bằng chiến lược tham lam
Cách xử lý luật	Sắp xếp và lựa chọn luật theo tiêu chí phân loại, sau đó xây dựng bộ phân loại	Sử dụng cấu trúc CR-tree để quản lý luật, kết hợp các bước tỉa luật và đánh giá bằng weighted χ^2	Đánh giá luật bằng độ chính xác kỳ vọng và dùng (k) luật tốt nhất khi dự đoán
Định hướng chính	Tích hợp khai thác luật kết hợp với phân loại	Nâng cao hiệu quả khai thác, quản lý và kết hợp nhiều luật	Hạn chế chi phí do sinh quá nhiều luật ứng viên và giảm nguy cơ quá khớp do chỉ dựa vào confidence
Điểm cần cân nhắc	Hiệu quả phụ thuộc vào số lượng và thứ tự ưu tiên của luật được khai thác	Việc quản lý và tổng hợp nhiều luật có thể làm tăng độ phức tạp triển khai	Kết quả phụ thuộc vào quá trình xây dựng luật, tham số và số lượng (k) luật sử dụng
Nguồn chính	Liu, Hsu và Ma (1998)	Li, Han và Pei (2001)	Yin và Han (2003)

Nguồn: Tổng hợp từ Liu et al. (1998), Li et al. (2001) và Yin và Han (2003).

2.2.4. Phương pháp luận Kimball trong thiết kế kho dữ liệu

Kimball tiếp cận theo hướng từ dưới lên (bottom-up): xây các mô hình đa chiều cho từng quy trình nghiệp vụ, rồi tích hợp thành hệ thống phân tích (Kimball & Ross, 2013). Quy trình thiết kế gồm bốn bước:

1. Chọn quy trình nghiệp vụ cần phân tích.
2. Khai báo grain: xác định chính xác một dòng trong Fact Table đại diện cho điều gì, trước khi chọn chiều và measure.
3. Xác định các chiều (dimensions): các đối tượng mô tả ngữ cảnh để lọc và nhóm dữ liệu.
4. Xác định các fact (measures): các đại lượng định lượng, phân loại thành additive, semi-additive và non-additive theo khả năng cộng gộp.

2.3. Tổng quan các nghiên cứu liên quan

Các tài liệu được xem xét theo hai nhóm: (1) nghiên cứu về chấm điểm tín dụng và dự đoán duyệt vay; (2) công trình nền tảng về khai phá luật kết hợp, phân loại dựa trên luật và Data Warehouse. Bảng 2.3 bên dưới được sắp xếp theo năm công bố.

Bảng 2.3. Tổng hợp các nghiên cứu liên quan

Tác giả, năm	Chủ đề và phương pháp	Kết quả / đóng góp chính	Liên hệ và lưu ý nghiên cứu
Agrawal & Srikant (1994)	Khai phá luật kết hợp trong cơ sở dữ liệu lớn; thuật toán Apriori.	Đặt nền tảng cho việc tìm tập mục thường xuyên và sinh luật kết hợp.	Cơ sở lý thuyết của ARM. Luật kết hợp thông thường không tự động trở thành mô hình dự đoán nhãn duyệt vay.
Hand & Henley (1997)	Tổng quan các phương pháp phân loại thống kê trong chấm điểm tín dụng tiêu dùng.	Hệ thống hóa các phương pháp phân loại dùng trong credit scoring.	Cơ sở cho việc chọn biến và diễn giải bài toán tín dụng.

Liu, Hsu & Ma (1998)	Kết hợp khai phá luật kết hợp với phân loại; thuật toán CBA, dùng CARs.	Đề xuất cách xây bộ phân loại từ luật có hệ quả là nhãn lớp và đánh giá trên các bộ dữ liệu thực nghiệm.	Nền tảng trực tiếp cho luật có hệ quả nhãn lớp.
Li, Han & Pei (2001)	Phân loại dựa trên nhiều luật kết hợp; CMAR với CR-tree và thống kê χ^2.	Báo cáo độ chính xác trung bình cao hơn CBA và C4.5 trên các bộ dữ liệu được khảo sát.	Cơ sở cho hướng phân loại bằng nhiều luật.
Baesens và cộng sự (2003)	So sánh nhiều bộ phân loại trên nhiều tập dữ liệu chấm điểm tín dụng.	Nhiều phương pháp phi tuyến cho kết quả tốt, nhưng các bộ phân loại tuyến tính đơn giản như logistic regression vẫn rất cạnh tranh.	Cho thấy không nên mặc định mô hình phức tạp luôn tốt hơn.
Sen & Sinha (2005)	So sánh các phương pháp luận xây dựng Data Warehouse.	Phân tích việc chọn phương pháp luận theo yêu cầu tổ chức và khai thác dữ liệu.	Tham khảo cho khâu tổ chức dữ liệu.
Thabtah (2007)	Tổng quan về khai phá phân loại dựa trên luật kết hợp.	Hệ thống hóa các bước sinh luật, xếp hạng, tỉa luật và dự đoán của nhóm phương pháp AC, trong đó có CBA và CMAR.	Khung đối chiếu để so sánh CBA và CMAR.
Khandani, Kim & Lo (2010)	Dự báo rủi ro tín dụng cá nhân từ dữ liệu giao dịch và thông tin tín dụng bằng học máy.	Dữ liệu giao dịch có thể dùng để dự báo chậm trả và vỡ nợ.	Ví dụ ứng dụng học máy trong dữ liệu tín dụng. Dự báo vỡ nợ khác với phân loại trạng thái duyệt vay.

Lessmann và cộng sự (2015)	So sánh 41 bộ phân loại trên tám bộ dữ liệu chấm điểm tín dụng.	Một số phương pháp vượt Logistic Regression, trong đó các mô hình ensemble nổi bật.	Cho thấy ensemble là nhóm mô hình thường được dùng để đối chiếu trong lĩnh vực.
Abellán & Castellano (2017)	So sánh các bộ phân loại cơ sở trong phương pháp ensemble cho chấm điểm tín dụng.	Việc chọn bộ phân loại cơ sở ảnh hưởng đến hiệu quả của ensemble.	Hiệu quả phụ thuộc thuật toán và cách kết hợp.
Uddin và cộng sự (2023)	Hệ thống dự đoán duyệt vay bằng ensemble; so sánh nhiều mô hình học máy và học sâu, dùng SMOTE xử lý mất cân bằng.	Mô hình ensemble dựa trên voting đạt accuracy 87.26% trong thí nghiệm.	Tham khảo cho xử lý mất cân bằng và đánh giá mô hình.
Sinap (2024)	So sánh các phương pháp học máy trong dự đoán duyệt vay.	Random Forest đạt accuracy 97.71% với Recursive Feature Elimination và cross-validation.	Ví dụ về vai trò chọn đặc trưng và quy trình đánh giá.
Hota, Jain & Kumar (2025)	Đánh giá so sánh các phương pháp dự đoán duyệt vay trong ngân hàng.	Logistic Regression nổi bật trong nhóm mô hình cơ sở và Random Forest tốt nhất trong nhóm ensemble.	Phân biệt mô hình cơ sở với mô hình kết hợp khi đối chiếu với phân loại bằng luật.

Nguồn: Tổng hợp từ các công trình được trích dẫn.

Nhận xét tổng hợp:

- *Thứ nhất, dự đoán duyệt vay và chấm điểm tín dụng:* Các nghiên cứu cho thấy học máy được dùng rộng rãi để phân loại hồ sơ hoặc dự báo rủi ro tín dụng (Khandani et al., 2010; Lessmann et al., 2015; Uddin et al., 2023; Sinap, 2024; Hota et al., 2025). Tuy nhiên, Baesens et al. (2003) cho thấy mô hình tuyến tính

đơn giản vẫn rất cạnh tranh. Cần phân biệt dự đoán Approved/Rejected với dự báo chậm trả hoặc vỡ nợ vì đây là các biến mục tiêu khác nhau. Độ chính xác giữa các nghiên cứu cũng không so sánh trực tiếp được khi bộ dữ liệu, cách tiền xử lý và thiết lập đánh giá khác nhau.

- *Thứ hai, phân loại dựa trên luật:* Từ nền tảng ARM (Agrawal & Srikant, 1994), CBA (Liu et al., 1998) và CMAR (Li et al., 2001) xây dựng bộ phân loại từ các luật có hệ quả là nhãn lớp; Thabtah (2007) hệ thống hóa nhóm phương pháp này. Hướng tiếp cận phù hợp để khảo sát mối liên hệ giữa thuộc tính hồ sơ và nhãn duyệt vay, cho ra mô hình dễ diễn giải. Tuy vậy, luật có support hoặc confidence cao không đồng nghĩa với khả năng dự đoán tốt; cần xem thêm lift và hiệu quả trên tập kiểm tra.
- *Thứ ba, tổ chức dữ liệu:* Data Warehouse tạo nền tảng lưu trữ và tổng hợp dữ liệu theo các chiều phân tích (Sen & Sinha, 2005; Kimball & Ross, 2013).

Khoảng trống nghiên cứu và định hướng: Trong phạm vi các tài liệu đã khảo sát, các nghiên cứu về duyệt vay chủ yếu sử dụng học máy truyền thống hoặc ensemble và tập trung vào hiệu quả phân loại. Chưa ghi nhận trong phạm vi này nghiên cứu áp dụng trực tiếp CBA hoặc CMAR cho dự đoán duyệt vay, hoặc kết hợp Data Warehouse với khai phá luật trên dữ liệu hồ sơ vay, cũng như việc so sánh CBA, CMAR với CPAR và lọc luật bằng tri thức nghiệp vụ tín dụng thông qua kho dữ liệu. Đây là khoảng trống trong phạm vi tài liệu đã rà soát, không phải khẳng định rằng chưa từng có nghiên cứu tương tự. Đề tài hướng tới kết hợp Data Warehouse, ARM và Associative Classification trên bộ dữ liệu hồ sơ vay, trong đó mỗi kỹ thuật giữ một vai trò riêng.

2.4. Cơ sở lựa chọn các đặc trưng phân tích

Trong phân tích tín dụng, hồ sơ vay thường được đánh giá qua mô hình 5Cs of Credit: Character (uy tín tín dụng), Capacity (năng lực trả nợ), Capital (nguồn lực tài chính), Collateral (tài sản bảo đảm) và Conditions (điều kiện khoản vay và môi trường kinh tế) (Peterdy, 2019). Song song đó, chấm điểm tín dụng cung cấp cơ sở thống kê cho việc chọn và phân tích các đặc trưng của hồ sơ (Hand & Henley, 1997; Siddiqi, 2006). Tuy nhiên, bộ dữ liệu không đo lường đủ cả năm khía cạnh, nên việc liên hệ các biến với 5Cs chỉ mang tính tham chiếu. Các biến dưới đây đại diện cho các nhóm thuộc tính đầu vào phổ biến được rà soát từ bộ dữ liệu và các nghiên cứu liên quan.

Việc lựa chọn đặc trưng trong nghiên cứu được xem xét ở hai cấp độ: ý nghĩa nghiệp vụ của các biến gốc và khả năng sử dụng của chúng sau tiền xử lý. Khi một số biến có mức liên hệ cao với nhau, chúng có thể mang thông tin trùng lặp. Trong khai phá luật kết hợp, việc giữ đồng thời các biến này có thể tạo ra nhiều luật dư thừa (mục 2.1.7). Một cách xử lý phổ biến là giữ lại một biến đại diện cho nhóm biến có liên hệ chặt chẽ. Việc chọn biến đại diện nên dựa trên ý nghĩa chuyên môn, thay vì chỉ dựa vào chỉ số thống kê (Dormann et al., 2013). Vì vậy, việc một biến được trình bày trong cơ sở lý thuyết không đồng nghĩa với việc biến đó được sử dụng nguyên trạng trong Association Rule Mining.

2.4.1. Lịch sử tín dụng (liên quan đến Character)

Các biến: previous_loan_defaults_on_file, credit_score, cb_person_cred_hist_length. Lịch sử vỡ nợ trước đây, điểm tín dụng và độ dài lịch sử tín dụng là các chỉ báo trực tiếp nhất về hành vi trả nợ của người vay. Điểm tín dụng chỉ là một chỉ báo hỗ trợ, không đại diện hoàn toàn cho uy tín hay toàn bộ rủi ro của một cá nhân (Hand & Henley, 1997).

2.4.2. Năng lực tài chính và quy mô khoản vay (liên quan đến Capacity)

Các biến: person_income, person_emp_exp, loan_amnt, loan_percent_income. Thu nhập và kinh nghiệm làm việc phản ánh nguồn thu và mức ổn định của người vay; loan_amnt là quy mô khoản vay; loan_percent_income là tỷ lệ khoản vay trên thu nhập, mô tả quy mô khoản vay tương đối so với thu nhập. Tỷ lệ này không tương đương tỷ lệ nghĩa vụ trả nợ trên thu nhập (DTI) dùng trong thẩm định thực tế, vì dữ liệu không có số tiền trả nợ định kỳ và các nghĩa vụ khác (Siddiqi, 2006).

2.4.3. Nguồn lực, mục đích và điều kiện khoản vay (liên quan đến Capital và Conditions)

Các biến: person_home_ownership, loan_intent, loan_int_rate. Hình thức sở hữu nhà (person_home_ownership) là chỉ báo gián tiếp về nguồn lực của người vay; biến này không cho biết tài sản nào được dùng làm bảo đảm nên không đại diện trực tiếp cho Collateral. Mục đích vay (loan_intent) và lãi suất (loan_int_rate) thuộc nhóm điều kiện khoản vay. Cần lưu ý rằng lãi suất trong thực tế thường được ấn định sau khi ngân hàng

đánh giá rủi ro. Nếu biến này chỉ xuất hiện sau bước thẩm định thì việc dùng nó làm đầu vào trong mô hình dự đoán có nguy cơ rò rỉ thông tin (target leakage).

2.4.4. Đặc điểm nhân khẩu học

Các biến: person_age, person_gender, person_education. Các biến này mô tả thông tin chung về người vay. Đối với thuộc tính nhạy cảm như giới tính, các luật thu được chỉ mô tả mối liên hệ quan sát được trong dữ liệu, không được dùng làm căn cứ cho quyết định tín dụng mang tính định kiến đối với từng nhóm.

2.4.5. Tổng hợp các biến tham chiếu

Bảng 2.4 tổng hợp các biến đầu vào và khía cạnh tham chiếu theo mô hình 5Cs.

Bảng 2.4. Các biến đầu vào và khía cạnh tham chiếu

Biến	**Kiểu dữ liệu**	**Khía cạnh tham chiếu**
previous_loan_defaults_on_file	Nhị phân (Yes/No)	Character
credit_score	Định lượng	Character
cb_person_cred_hist_length	Định lượng	Character
person_income	Định lượng	Capacity
person_emp_exp	Định lượng	Capacity
loan_amnt	Định lượng	Capacity
loan_percent_income	Định lượng	Capacity
person_home_ownership	Phân loại	Capital (gián tiếp)
loan_intent	Phân loại	Conditions
loan_int_rate	Định lượng	Conditions

person_age	Định lượng	Đặc điểm người vay
person_gender	Phân loại	Đặc điểm người vay
person_education	Phân loại	Đặc điểm người vay

Nguồn: Tổng hợp từ lý thuyết chấm điểm tín dụng.

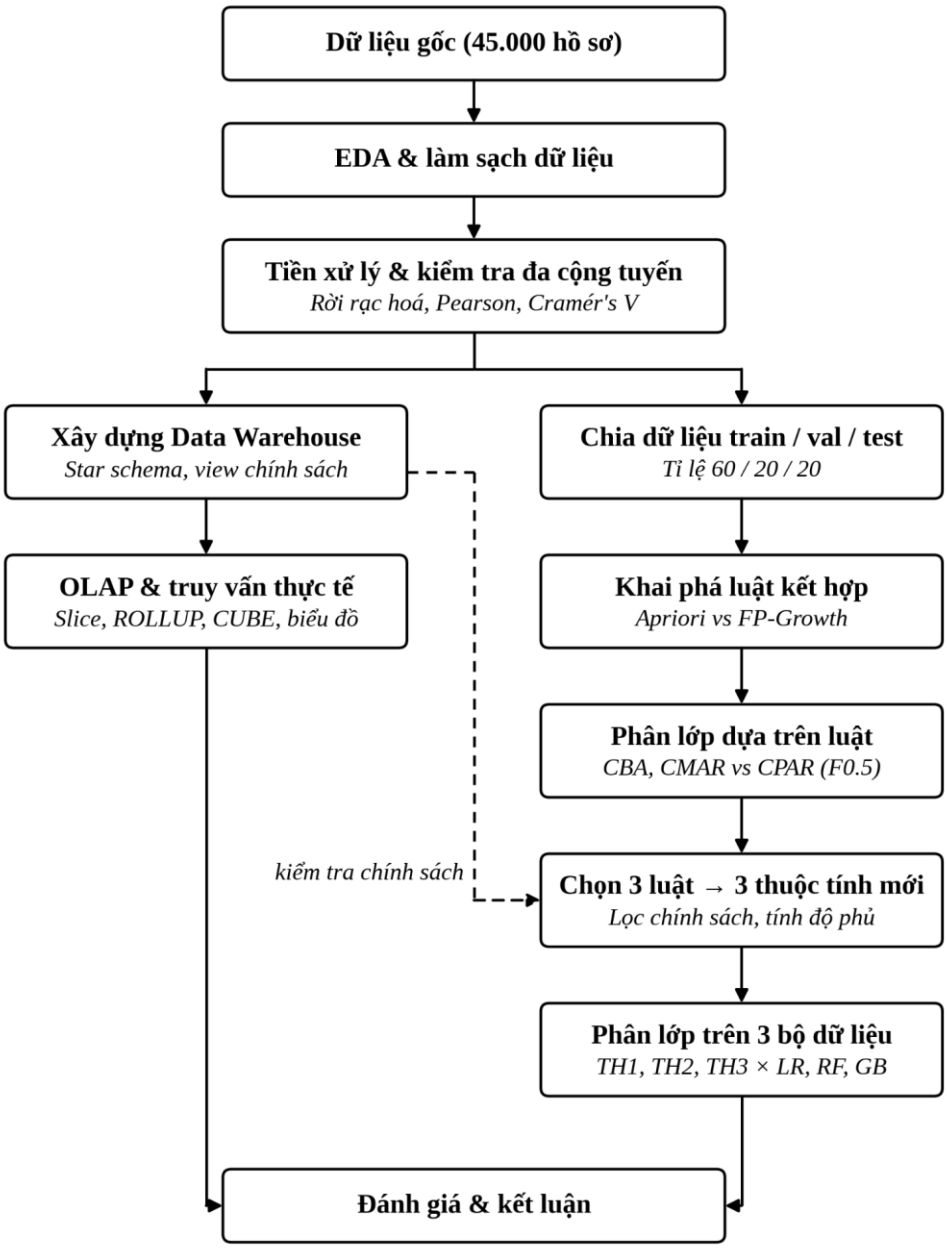
2.4.6. Lưu ý khi diễn giải mối liên hệ

Cơ sở lý thuyết giúp xác định các biến cần khảo sát. Các mối liên hệ giữa biến và nhãn duyệt vay được kiểm chứng bằng thực nghiệm và chỉ được diễn giải như mối liên hệ quan sát được, không phải quan hệ nhân quả. Với các biến có thể phản ánh trực tiếp quy trình tạo nhãn hoặc xuất hiện sau bước thẩm định, cần cân nhắc nguy cơ rò rỉ nhãn (target leakage) khi diễn giải.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Quy trình nghiên cứu

Nghiên cứu được thực hiện theo một quy trình khai phá dữ liệu gồm nhiều bước nối tiếp nhau, trong đó phần đầu dùng chung cho toàn bộ dữ liệu và phần sau tách làm hai nhánh chạy song song (Hình 3.1). Mục tiêu của quy trình là tìm ra những tổ hợp đặc điểm thường đi cùng với một khoản vay được duyệt hoặc bị từ chối, rồi xem các tổ hợp đó có giúp ích gì cho việc phân loại hay không.



Hình 3.1. Quy trình nghiên cứu

Quy trình bắt đầu từ tập dữ liệu gốc gồm 45.000 hồ sơ vay. Bước đầu tiên là phân tích khám phá dữ liệu (EDA) và làm sạch dữ liệu. Bước này, dữ liệu được kiểm tra về kích thước, kiểu dữ liệu, giá trị thiếu, phân phối của biến mục tiêu và các giá trị bất thường. Những hồ sơ có giá trị không hợp lý về mặt nghiệp vụ sẽ bị loại bỏ. Kết quả EDA cũng cho biết cần xử lý vấn đề nào trước khi được khai phá.

Tiếp theo là tiền xử lý và kiểm tra đa cộng tuyến. Các biến số được rời rạc hóa thành những nhóm định tính để phù hợp với khai phá luật kết hợp. Mức độ tương quan giữa các biến số được đo bằng hệ số Pearson và Cramér's V . Biến nào dư thừa thông tin thì được xử lý ngay tại bước này, trước khi dữ liệu đi tiếp.

Sau tiền xử lý, quy trình chia làm hai nhánh. Nhánh thứ nhất là kho dữ liệu. Dữ liệu được tổ chức thành Data Warehouse theo mô hình Star Schema. Kho dữ liệu sau đó được khai thác bằng các truy vấn nhiều chiều (JOIN, GROUP BY, HAVING), cùng với biểu đồ minh họa. Nhánh này trả lời câu hỏi dữ liệu nhìn từ nhiều chiều trông như thế nào, và nó cho góc nhìn nghiệp vụ để đọc các luật ở chương 4. Nhánh thứ hai là khai phá và phân loại, và đây là nhánh dài hơn. Dữ liệu được chia thành các tập train/test/validation theo tỷ lệ 60/20/20. Tập train dùng để khai phá luật kết hợp bằng hai thuật toán Apriori và FP-Growth, chạy trên cùng dữ liệu với cùng ngưỡng min_support. Các luật sinh ra được đánh giá bằng support, confidence và lift, rồi chỉ giữ lại những luật có vế phải là trạng thái khoản vay. Từ tập luật này, ba phương pháp phân lớp dựa trên luật là CBA, CMAR và CPAR được xây dựng và so sánh với nhau, chủ yếu theo F0.5.

Sau đó, với mỗi phương pháp gồm thuật toán thắng trong cặp CBA–CMAR và CPAR, nghiên cứu chọn ra ba luật dẫn tới Approved theo cùng một quy trình: luật được xếp theo độ đo gốc của thuật toán, phải qua bước kiểm tra chính sách trên kho dữ liệu và ít chồng lấn với các luật đã chọn. Độ phủ của từng luật được tính trên toàn bộ dữ liệu, rồi mỗi luật được chuyển thành một thuộc tính nhị phân. Từ đó có ba bộ dữ liệu: TH1 chỉ gồm các thuộc tính gốc, TH2 thêm ba thuộc tính sinh từ luật của thuật toán thắng trong cặp CBA–CMAR, TH3 thêm ba thuộc tính sinh từ luật của CPAR. Trên mỗi bộ, ba mô hình Logistic Regression, Random Forest và Gradient Boosting được huấn luyện, tức là có chín kết hợp cần so sánh.

Cuối cùng, kết quả của cả hai nhánh được tổng hợp ở bước đánh giá và kết luận. Nhánh kho dữ liệu cho thấy khả năng phân tích đa chiều và nhận diện nhóm rủi ro. Nhánh khai phá cho thấy các thuộc tính sinh từ luật có cải thiện kết quả phân loại so với dữ liệu không dùng chúng hay không. Tập test dùng để đánh giá cuối, và tập validation so sánh các phương pháp và mô hình.

3.2. Phương pháp nghiên cứu

3.2.1. Nguồn và mô tả dữ liệu

Dữ liệu là tập hồ sơ vay lấy từ Kaggle (bộ Loan Approval Classification Data), lưu trong file loan_data.csv. Tập dữ liệu có 45.000 hồ sơ và 14 biến, gồm 13 biến giải thích và một biến mục tiêu loan_status. Kiểm tra ban đầu cho thấy cả 14 biến đều không có giá trị thiếu, nên nghiên cứu không cần bước xử lý hay điền khuyết. Các biến chia thành hai nhóm, được tóm tắt ở Bảng 3.1.

Bảng 3.1. Mô tả các biến trong tập dữ liệu

Nhóm	Biến	Ý nghĩa
Biến số	person_age	Tuổi khách hàng
Biến số	person_income	Thu nhập
Biến số	person_emp_exp	Số năm kinh nghiệm
Biến số	loan_amnt	Số tiền vay
Biến số	loan_int_rate	Lãi suất khoản vay
Biến số	loan_percent_income	Tỷ lệ khoản vay trên thu nhập
Biến số	cb_person_cred_hist_length	Độ dài lịch sử tín dụng
Biến số	credit_score	Điểm tín dụng
Biến phân loại	person_gender	Giới tính
Biến phân loại	person_education	Trình độ học vấn
Biến phân loại	person_home_ownership	Hình thức sở hữu nhà
Biến phân loại	loan_intent	Mục đích vay
Biến phân loại	previous_loan_defaults_on_file	Lịch sử vỡ nợ

Biến mục tiêu	loan_status	Kết quả xét duyệt: Approved / Rejected

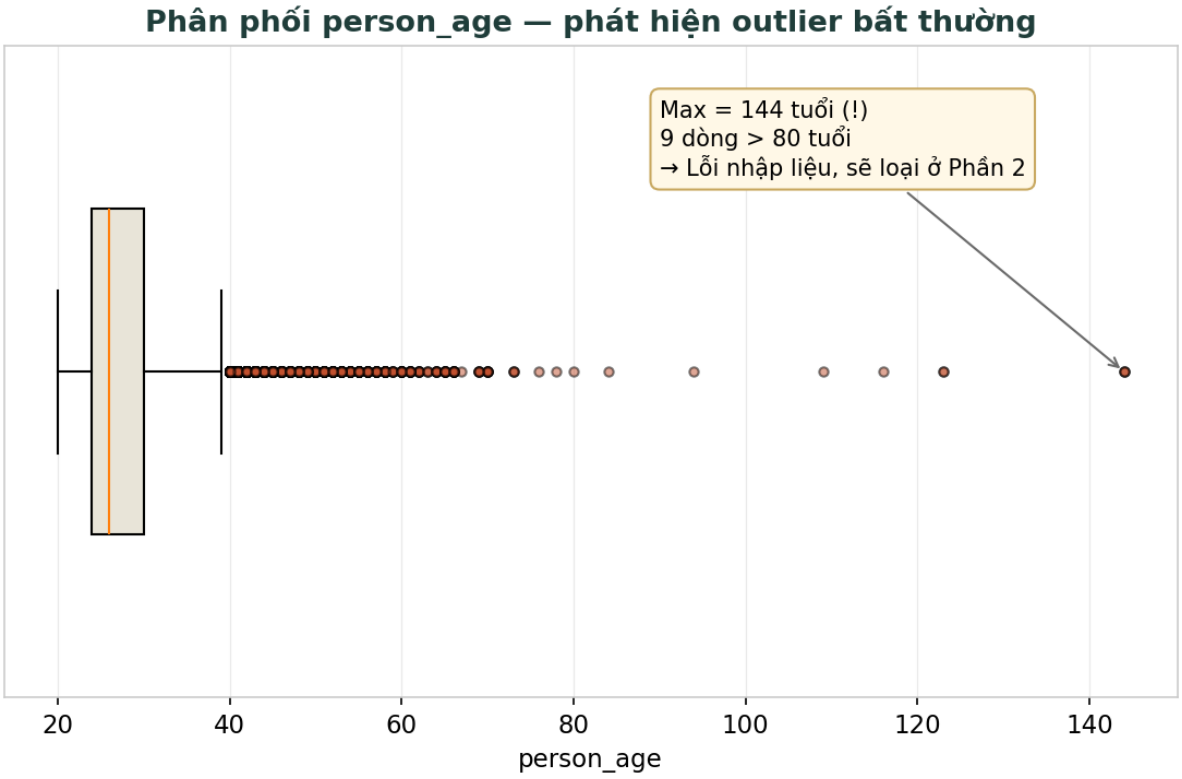
Biến loan_status có hai vai trò. Với bài toán phân loại, nó là biến đích. Với khai phá luật kết hợp, nó là một item đặc biệt nằm trong giao dịch cùng các item khác. Cách thiết kế này đổi câu hỏi phân tích. Thay vì chỉ mô tả "khách hàng có đặc điểm gì", đề án hỏi "tổ hợp đặc điểm nào thường đi kèm với một khoản vay được duyệt hoặc bị từ chối".

3.2.2. Thiết kế biến và tiền xử lý

Tiền xử lý dựa trên hai tiêu chí: kỹ thuật và tính hợp lý về nghiệp vụ.

Bước 1: Loại quan sát không hợp lý.

Có 9 hồ sơ với person_age > 80 (lớn nhất là 144) và 10 hồ sơ với person_emp_exp > 60 (lớn nhất là 125). Tổng cộng 10 hồ sơ bị loại, chiếm khoảng 0.02%. Đây là lỗi nhập liệu rõ ràng, nên nghiên cứu xóa hẳn thay vì cắt ngưỡng hay thay giá trị. Cả 10 hồ sơ đều thuộc lớp Rejected. Dữ liệu còn 44.990 hồ sơ và không có bản ghi trùng lặp. Boxplot tuổi (Hình 3.2) cho thấy các giá trị này nằm tách hẳn khỏi phần còn lại.



Hình 3.2. Phân phối tuổi

Bước 2: Rời rạc hóa theo ngưỡng nghiệp vụ.

ARM chỉ làm việc với item rời rạc. Sáu biến person_age, person_income, loan_amnt, credit_score, loan_percent_income và loan_int_rate được chuyển thành person_age_band, person_income_band, loan_amnt_band, credit_score_band, loan_percent_income_band và loan_int_rate_band (đúng tên các chiều suy biến trong Hình 3.3). Mốc cắt dựa trên ngưỡng nghiệp vụ của hoạt động cho vay tiêu dùng, không chia theo phân vị, để mỗi nhóm có ý nghĩa diễn giải và các luật khai phá được có thể đối chiếu trực tiếp với chính sách tín dụng (Bảng 3.2). Mỗi nhóm đóng ở mốc dưới và mở ở mốc trên, ví dụ điểm tín dụng 580 thuộc nhóm Fair.

Bảng 3.2. Ngưỡng rời rạc hóa các biến số theo nghiệp vụ

Biến	Mốc cắt	Nhãn	Cơ sở
credit_score	580 | 670 | 740	Poor, Fair, Good, VeryGood	Thang FICO
person_income	30.000 | 60.000 | 100.000	<30k, 30–60k, 60–100k, ≥100k	Mốc tròn do nhóm chọn; mốc 100.000 xấp xỉ phân vị 75% thu nhập
loan_amnt	5.000 | 10.000 | 20.000	<5k, 5–10k, 10–20k, ≥20k	Số dư vay cá nhân bình quân
loan_int_rate	10 | 13 | 16 (%)	<10%, 10–13%, 13–16%, ≥16%	Lãi suất bình quân (Fed G.19)
loan_percent_income	0,10 | 0,20 | 0,30	<10%, 10–20%, 20–30%, ≥30%	Tương tự DTI
person_age	25 | 35	<25, 25–34, ≥35	Mốc tròn do nhóm chọn theo giai đoạn nghề nghiệp

Điểm tín dụng**.** Các mốc 580, 670 và 740 là ranh giới giữa các hạng Poor, Fair, Good và Very Good của thang FICO 300–850 (Experian, n.d.). Điểm dưới 580 nằm trong vùng subprime (Chase, n.d.). Hạng Very Good và Exceptional được gộp thành nhóm VeryGood (từ 740 trở lên).

Tỷ lệ khoản vay trên thu nhập**.** Biến này gần với tỷ lệ nợ trên thu nhập (DTI). Các tổ chức cho vay thường muốn DTI dưới 36%, và mức 43% là giới hạn của khoản vay thế chấp đủ điều kiện (Cornell LII, n.d.). Dallas Fed (2020) cũng chia DTI thành ba nhóm ≤36%, 36–43% và ≥43% khi phân tích vỡ nợ. Tuy nhiên, loan_percent_income chỉ đo riêng khoản vay đang xét, chưa tính nợ khác, nên các mốc 10%, 20% và 30% là lựa chọn của nghiên cứu, đặt dưới vùng 36%.

Lãi suất và số tiền vay**.** Lãi suất bình quân của khoản vay cá nhân 24 tháng tại ngân hàng thương mại theo Federal Reserve (G.19, 2026) vào khoảng 11,4% đến 11,9%, nên các mốc 10%, 13% và 16% chia khoản vay thành nhóm dưới, quanh và trên mức thị trường. Số dư vay cá nhân bình quân theo TransUnion vào khoảng 11.700 USD mỗi người và khoảng 6.500 USD cho tài khoản mới mở (Bankrate, 2026), nên các mốc 5.000, 10.000 và 20.000 USD bao quanh các mức này.

Vì mốc cắt cố định theo nghiệp vụ và không tính từ dữ liệu, việc rời rạc hóa trước khi chia tập không làm lộ thông tin của tập test. Nhóm credit_score_band=VeryGood chỉ chiếm 0,20% hồ sơ (90 hồ sơ) nên không thể đạt min_support = 0.02 và sẽ không xuất hiện trong luật.

Bước 3: Kiểm tra đa cộng tuyến.

Bước này chạy trên toàn bộ dữ liệu đã làm sạch, trước khi chia tập (Hình 3.1). Với 8 biến số, nghiên cứu dùng hệ số Pearson với ngưỡng cảnh báo $|r| \geq 0{,}8$. Ba cặp vượt ngưỡng, đều thuộc nhóm person_age, person_emp_exp và cb_person_cred_hist_length: person_age và person_emp_exp là 0,95; person_age và cb_person_cred_hist_length là 0,88; person_emp_exp và cb_person_cred_hist_length là 0,84. Các cặp biến số còn lại đều dưới 0,8. Với 11 thuộc tính đưa vào khai phá (gồm các band), nghiên cứu dùng Cramér's V với ngưỡng cảnh báo $V \geq 0{,}5$, và không có cặp nào vượt ngưỡng.

Ba biến tuổi, số năm kinh nghiệm và độ dài lịch sử tín dụng gần như đo cùng một thứ là thâm niên, nên nghiên cứu chỉ giữ person_age và loại person_emp_exp cùng cb_person_cred_hist_length. Tuổi được giữ làm đại diện vì dễ diễn giải về nghiệp vụ, và là một trong sáu độ đo của bảng fact (Hình 3.3). person_age_band vì vậy được đưa vào khai phá.

Bộ thuộc tính đưa vào khai phá gồm 11 thuộc tính: 6 band số, cộng với 5 biến phân loại là giới tính, học vấn, sở hữu nhà, mục đích vay và lịch sử vỡ nợ. Cộng hai item của lớp, giao dịch có tổng cộng 44 item khác nhau (23 item từ band số, 19 item từ biến phân loại và 2 item lớp).

Bảng 3.3. Tóm tắt các bước tiền xử lý

Bước	Thao tác	Kết quả
0	Dữ liệu gốc	45.000 hồ sơ
1	Loại person_age > 80 hoặc person_emp_exp > 60	44.990 hồ sơ
2	Kiểm tra trùng lặp	0 bản ghi trùng
3	Rời rạc hóa 6 biến theo ngưỡng nghiệp vụ	6 band
4	Kiểm tra đa cộng tuyến (Pearson, Cramér's V)	Loại 2 biến gốc
5	Chia train/validation/test 60:20:20 phân tầng	26.994 / 8.998 / 8.998 hồ sơ
	Bộ thuộc tính khai phá	11 thuộc tính, 44 item

3.2.3. Mẫu nghiên cứu:

Sau tiền xử lý, dữ liệu còn 44,990 hồ sơ. Chia 60:20:20 cho 26,994 hồ sơ huấn luyện, 8,998 hồ sơ validation và 8,998 hồ sơ kiểm tra.

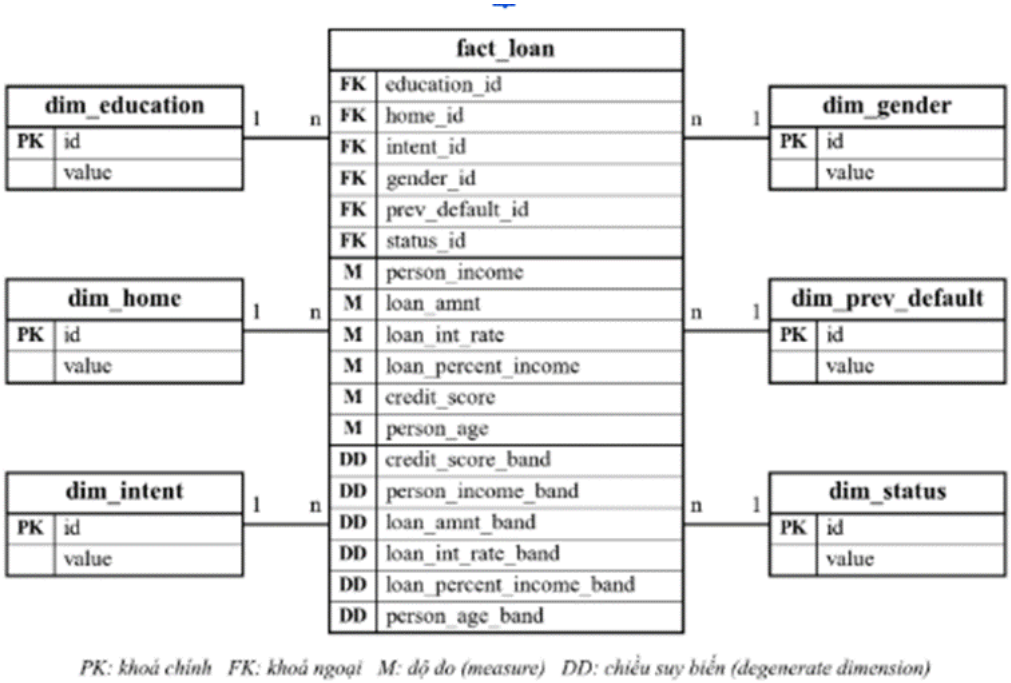
Biến loan_status mất cân bằng rõ. Rejected chiếm 77.8%, Approved chiếm 22.2%. Hệ quả có hai mặt. Chia ngẫu nhiên thường có thể làm lệch tỷ lệ lớp giữa các tập. Và accuracy đơn thuần không đủ tin cậy, vì mô hình đoán toàn bộ là Rejected đã đạt 77.8%.

Vì vậy, nghiên cứu dùng stratified split theo loan_status. Việc chia gồm hai bước với random_state = 42: tách 20% làm tập test, rồi tách 25% phần còn lại làm tập validation, cả hai bước đều phân tầng. Tập train dùng để khai phá luật và huấn luyện mô hình; tập validation dùng để chọn phương pháp phân lớp dựa trên luật (CBA, CMAR, CPAR); tập test chỉ dùng một lần để báo cáo kết quả cuối, không tham gia vào bất kỳ

lựa chọn nào. Tiêu chí chính là điểm F0.5 của lớp Approved (mục 3.2.5); nghiên cứu báo cáo thêm precision, recall, F1, accuracy và ma trận nhầm lẫn.

3.2.4. Thu thập dữ liệu và xây dựng Data Warehouse

Dữ liệu được tải từ Kaggle, làm sạch theo quy trình mô tả ở mục 3.2.2, rồi nạp vào Data Warehouse bằng quy trình ETL. Kho dữ liệu dùng mô hình Star Schema, cài đặt trên SQLite (Hình 3.3).



Hình 3.3. Mô hình Star Schema của Data Warehouse

Bảng fact trung tâm là fact_loan, mỗi hồ sơ vay là một dòng, tổng cộng 44.990 dòng. Bảng fact gồm ba nhóm cột. Sáu khóa ngoại tới các dimension là education_id, home_id, intent_id, gender_id, prev_default_id và status_id. Sáu độ đo (measure) là person_income, loan_amnt, loan_int_rate, loan_percent_income, credit_score và person_age. Sáu chiều suy biến (degenerate dimensions) là các band ở mục 3.2.2: credit_score_band, person_income_band, loan_amnt_band, loan_int_rate_band, loan_percent_income_band và person_age_band. Việc đặt thuộc tính số và band ở bảng fact giúp các phép tổng hợp chạy trực tiếp mà không cần nối thêm bảng.

Có sáu bảng dimension được mô tả ở Bảng 3.4. Mỗi bảng gồm khóa chính id và cột value.

Bảng 3.4.Các bảng dimension

Dimension	Thuộc tính mô tả
dim_education	Trình độ học vấn
dim_home	Hình thức sở hữu nhà
dim_intent	Mục đích vay
dim_gender	Giới tính
dim_prev_default	Lịch sử vỡ nợ
dim_status	Trạng thái khoản vay

Sau khi xây dựng, các truy vấn OLAP được chạy để kiểm tra xem kho dữ liệu có hỗ trợ phân tích đa chiều hay không. Kho dữ liệu có hai view: v_loan nối bảng fact với sáu dimension, và v_policy thêm cờ vi phạm năng lực trả nợ. SQLite không có GROUP BY ROLLUP và CUBE, nên hai phép này được ghép từ các truy vấn GROUP BY bằng UNION ALL, với giá trị ALL đánh dấu dòng tổng phụ (Gray và cộng sự, 1997). Ba truy vấn OLAP gồm Slice tỷ lệ duyệt theo lịch sử vỡ nợ, ROLLUP khoản vay bình quân theo học vấn rồi hình thức sở hữu nhà, và CUBE tỷ lệ duyệt theo mục đích vay và giới tính. Bốn truy vấn thực tế gồm dư nợ đã duyệt theo mục đích vay, ma trận tỷ lệ duyệt theo điểm tín dụng và lịch sử vỡ nợ, năm tổ hợp (mục đích, sở hữu nhà) có từ 500 hồ sơ trở lên mà tỷ lệ duyệt thấp nhất (dùng HAVING), và kiểm tra xem hồ sơ vi phạm năng lực trả nợ có đang được duyệt hay không.

Cờ vi phạm của v_policy bằng 1 khi thu nhập dưới 25.000 hoặc loan_percent_income lớn hơn 0,4. Hai ngưỡng này là giả định nghiệp vụ do nhóm đặt, không học từ dữ liệu. Ở bước chọn luật, một luật bị loại nếu hơn 10% hồ sơ mà nó phủ vi phạm chính sách.

3.2.5. Thước đo đánh giá và tiêu chí lựa chọn mô hình

Việc lựa chọn thước đo đánh giá xuất phát từ hai đặc điểm của bài toán. Thứ nhất, dữ liệu mất cân bằng: lớp Approved chỉ chiếm 22.23%, nên một bộ phân loại luôn dự đoán Rejected đã đạt độ chính xác tổng thể khoảng 77.77% mà không khai thác thông tin nào từ hồ sơ. Vì vậy, độ chính xác tổng thể không được dùng làm tiêu chí chính; đề

án đánh giá trên lớp Approved (lớp dương) bằng precision, recall và các thước đo tổng hợp từ hai chỉ số này (Sokolova & Lapalme, 2009).

Thứ hai, hai loại sai số trong xét duyệt tín dụng có hậu quả không cân xứng. Dương tính giả (duyệt một hồ sơ lẽ ra bị từ chối) có thể dẫn đến tổn thất cả phần nợ gốc khi khoản vay không được hoàn trả, trong khi âm tính giả (từ chối một hồ sơ đủ điều kiện) chủ yếu gây mất phần thu nhập lãi tiềm năng. Do đó, precision, tức tỉ lệ hồ sơ được dự đoán là Approved đúng, cần được coi trọng hơn recall.

Thước đo F-beta cho phép điều chỉnh mức coi trọng tương đối giữa hai chỉ số: $F_\beta = (1 + \beta^2) \times \text{Precision} \times \text{Recall} / (\beta^2 \times \text{Precision} + \text{Recall})$. Với $\beta = 1$ (điểm F1), precision và recall có trọng số ngang nhau; với $\beta < 1$, precision được ưu tiên. Đề án chọn $\beta = 0.5$, tương ứng với việc coi precision quan trọng gấp đôi recall, phản ánh khẩu vị rủi ro thận trọng "thà từ chối nhầm còn hơn duyệt nhầm".

Đề án không dùng riêng precision làm tiêu chí vì một mô hình chỉ duyệt rất ít hồ sơ chắc chắn có thể đạt precision cao nhưng bỏ sót gần hết khách hàng đủ điều kiện. Điểm F0.5 khắc phục điều này: khi recall tiến về 0, điểm F0.5 cũng tiến về 0, nên mô hình bỏ quên lớp Approved vẫn bị phạt.

Cách tiếp cận trực tiếp hơn là phân loại có xét chi phí, gán mức tổn thất cụ thể cho từng loại sai số (Elkan, 2001). Tuy nhiên, bộ dữ liệu không cung cấp thông tin để ước lượng tổn thất thực tế, nên việc gán một tỉ lệ chi phí cố định sẽ thiếu căn cứ. Vì vậy, đề án dùng điểm F0.5 làm tiêu chí chính và sử dụng phân tích độ nhạy chi phí với tỉ lệ k giữa chi phí dương tính giả và âm tính giả thay đổi từ 0.5 đến 5, để kiểm tra mức độ bền vững của kết quả lựa chọn.

Cần lưu ý rằng giá trị $\beta = 0.5$ là một lựa chọn quy ước phản ánh tránh rủi ro, không phải giá trị tối ưu duy nhất. Với một tổ chức ưu tiên mở rộng tiếp cận tín dụng, tiêu chí phù hợp có thể là điểm F1 hoặc $\beta > 1$, và kết quả lựa chọn thuật toán có thể thay đổi tương ứng (mục 4.5.1).

3.2.6. Phương pháp phân tích dữ liệu

Nghiên cứu kết hợp năm nhóm phương pháp.

(1) Exploratory Data Analysis: EDA mô tả dữ liệu, phát hiện giá trị bất thường và đánh giá phân phối biến mục tiêu. EDA cũng so sánh nhóm Approved với Rejected và kiểm tra tương quan giữa các biến số. Kết quả chi tiết ở chương 4.

(2) Association Rule Mining. Mỗi hồ sơ trong tập train là một giao dịch gồm các item dạng tên_biến=nhóm, ví dụ credit_score_band=Fair, cộng với một item class=Approved hoặc class=Rejected. Hai thuật toán được thử nghiệm:

- Apriori sinh tập phổ biến theo từng mức kích thước. Nếu một tập item không phổ biến thì mọi tập chứa nó cũng không phổ biến, nên nhiều ứng viên bị loại sớm. Thuật toán vẫn phải quét dữ liệu nhiều lần.
- FP-Growth nén dữ liệu vào cây FP-tree và khai phá trực tiếp trên cây. Thuật toán không sinh tập ứng viên và chỉ quét dữ liệu hai lần.

Cả hai chạy với min_support = 0.02 (tương ứng khoảng 540 giao dịch trên tập train) và độ dài itemset tối đa là 4, gồm tối đa ba điều kiện ở vế trái cộng một item lớp. Luật chỉ được giữ khi vế phải là đúng một item class và certainty factor (CF) đạt ít nhất 0,3. Hai thuật toán là thuật toán chính xác, cho cùng tập itemset khi cùng ngưỡng, và điều này được kiểm tra bằng cách so sánh hai tập kết quả. Vì vậy, tiêu chí chọn thuật toán là thời gian chạy, không phải chất lượng luật. Các bước sau dùng tập itemset của Apriori.

Mỗi luật $X \rightarrow Y$ được đánh giá bằng bốn chỉ số:

(1) $\text{Support}(X \rightarrow Y) = P(X \cup Y)$

(2) $\text{Confidence}(X \rightarrow Y) = P(Y \mid X)$

(3) $\text{Lift}(X \rightarrow Y) = P(Y \mid X) / P(Y)$

(4) Certainty factor: $CF(X \rightarrow Y) = (\text{Confidence} - P(Y)) / (1 - P(Y))$

Support cho biết luật phổ biến đến đâu. Confidence cho biết xác suất vế phải xuất hiện khi vế trái đã xuất hiện. Lift so sánh mức liên kết thực tế với trường hợp hai tập item độc lập, và lift > 1 nghĩa là chúng đi cùng nhau nhiều hơn mức ngẫu nhiên. CF so sánh confidence với tỉ lệ nền P(Y) của chính lớp ở vế phải.

Với dữ liệu mất cân bằng, lift đáng tin hơn confidence. Luật dẫn tới Rejected có thể đạt confidence cao chỉ vì Rejected vốn chiếm 77.8%. Lift cũng bị chặn theo

lớp: với Rejected, lift tối đa là 1/0.778 ≈ 1.29, còn với Approved có thể lên tới khoảng 4.5. Vì vậy, lift chỉ so sánh trực tiếp được giữa các luật cùng lớp.

Ngưỡng confidence chung (ví dụ 0.6) gần như loại hết luật Approved vì lớp này chỉ chiếm khoảng 22%. CF đo mức luật cải thiện so với tỉ lệ nền của chính lớp, nên công bằng cho cả hai lớp. Với CF ≥ 0.3, luật Approved cần confidence từ khoảng 0.46 trở lên, còn luật Rejected cần từ khoảng 0.84 trở lên.

(3) Associative Classification. Phương pháp này chuyển tập luật thành bộ phân loại. Cả ba phương pháp dùng cùng tập item và cùng ràng buộc (support ≥ 2%, CF ≥ 0,3, vế trái tối đa ba điều kiện). CBA và CMAR nhận trực tiếp tập luật Apriori. CPAR tự xây luật, nhưng vì bị lọc bằng cùng ràng buộc nên mọi luật giữ lại đều phải nằm trong tập luật Apriori. Vì vậy, sự khác biệt về kết quả đến từ cách chọn và áp dụng luật. Khi không có luật nào khớp, CMAR và CPAR dùng lớp đa số của tập train (Rejected), còn CBA dùng lớp đa số của phần hồ sơ chưa được luật nào phủ.

- CBA (Liu, Hsu & Ma, 1998) xếp luật theo confidence, rồi support, rồi số item ít hơn. Các luật được duyệt theo thứ hạng: luật nào phân loại đúng ít nhất một hồ sơ còn lại thì được chọn và lấy đi các hồ sơ nó phủ. Danh sách được cắt tại điểm có tổng số lỗi nhỏ nhất. Khi phân loại, hồ sơ nhận nhãn của luật khớp đầu tiên.
- CMAR (Li, Han & Pei, 2001) lọc luật qua ba tầng. Tầng một loại luật cụ thể khi đã có luật tổng quát hơn (vế trái là tập con) xếp hạng cao hơn. Tầng hai giữ luật có chi-square lớn hơn 3,841 ($p < 0,05$) và lift lớn hơn 1. Tầng ba là database coverage với $\delta = 4$: một hồ sơ huấn luyện bị loại khỏi xét khi đã được bốn luật được chọn bao phủ. Khi phân loại, các luật khớp được nhóm theo lớp, điểm của mỗi lớp là tổng weighted chi-square ($\chi^2 \times \chi^2 / \max\chi^2$) của các luật trong nhóm, và lớp có điểm cao nhất được chọn.
- CPAR (Yin & Han, 2003) khác CBA và CMAR ở chỗ xây từng luật thay vì khai phá hết rồi lọc. Mỗi luật bắt đầu từ vế trái rỗng, mỗi bước thêm điều kiện có FOIL gain lớn nhất (tối thiểu 0,7, mỗi thuộc tính dùng một lần, tối đa ba điều kiện). Sau khi sinh một luật, các hồ sơ dương được phủ không bị xóa mà bị giảm trọng số còn 2/3, và quá trình dừng khi tổng trọng số dương còn dưới 5%. Luật sinh ra được lọc bằng cùng ràng buộc với CBA và CMAR. Khi phân

loại, điểm của mỗi lớp là trung bình Laplace accuracy của tối đa năm luật tốt nhất mà hồ sơ khớp. Bản cài đặt đơn giản hóa so với bài báo ở chỗ mỗi bước chỉ chọn một điều kiện tốt nhất, không tách nhánh khi nhiều điều kiện có gain gần bằng nhau.

Ba phương pháp được so sánh trên tập validation theo F0.5, precision, recall, F1 và accuracy của lớp Approved, cùng số luật cuối. Việc chọn gồm hai bước: CBA và CMAR (hai thuật toán trong chương trình môn học) được so sánh trước và phương pháp có F0.5 cao hơn được chọn, sau đó phương pháp này được so với CPAR. Để kiểm tra độ bền của kết quả, nghiên cứu tính thêm chi phí k × FP + FN theo các giá trị k ở mục 3.2.5. Tập test không tham gia vào việc chọn này.

(4) Chọn luật và tạo thuộc tính mới. Với phương pháp thắng trong cặp CBA và CMAR và với CPAR, ba luật được chọn theo cùng quy trình: vế phải là Approved (lớp thiểu số); vế trái có ít nhất hai điều kiện, vì một điều kiện chỉ lặp lại cột gốc; luật qua kiểm tra chính sách trên Data Warehouse (không quá 10% hồ sơ phủ vi phạm); và ít chồng lấn với luật đã chọn (hệ số Jaccard giữa hai tập hồ sơ được phủ nhỏ hơn 0,5). Luật được xếp theo độ đo gốc của từng thuật toán: confidence cho CBA, weighted chi-square cho CMAR, Laplace accuracy cho CPAR. Với CBA và CMAR, nếu tập luật cuối không đủ luật hợp lệ thì lấy tiếp từ tập luật Apriori theo thứ hạng chung. Mỗi luật được chuyển thành một thuộc tính nhị phân, bằng 1 khi hồ sơ khớp mọi điều kiện ở vế trái. Độ phủ, support, confidence của từng luật và phần hồ sơ Approved mà ba luật bắt được (hợp ba luật, không đếm trùng) được tính trên toàn bộ dữ liệu để mô tả.

(5) Phân loại trên ba bộ dữ liệu. TH1 gồm các item của 11 thuộc tính ở dạng one-hot; TH2 và TH3 thêm ba thuộc tính luật như trên. Ba mô hình dùng cùng siêu tham số cho mọi bộ dữ liệu: Logistic Regression (max_iter = 2000), Random Forest (300 cây, min_samples_leaf = 5, random_state = 42) và Gradient Boosting (random_state = 42, các tham số còn lại mặc định). Nghiên cứu không dùng class_weight = "balanced" vì tùy chọn này đẩy mô hình duyệt nhiều hơn, làm recall cao và precision thấp, ngược với khẩu vị thận trọng. Mô hình được huấn luyện trên train và đánh giá trên test. Vì kết quả dựa trên một lần chia dữ liệu, chênh lệch dưới khoảng 0,5 điểm phần trăm có thể chỉ là nhiễu.

Ngoài ra, đề án xây dựng một ứng dụng minh họa hai lớp (luật chuyên gia rồi mô hình thắng), mô tả ở mục 4.9.

3.2.7. Môi trường thực nghiệm

Toàn bộ thực nghiệm được thực hiện trên nền tảng Google Colab, sử dụng môi trường thực thi CPU tiêu chuẩn. Đề án không sử dụng GPU do các thuật toán khai phá luật kết hợp, phân loại dựa trên luật và các mô hình học máy được áp dụng đều thực thi trên CPU. Cấu hình phần cứng và phiên bản phần mềm được trình bày ở Bảng 3.5.

Bảng 3.5. Môi trường thực nghiệm

Thành phần	Cấu hình
Nền tảng	Google Colab, môi trường thực thi CPU
Bộ xử lý	Intel Xeon CPU @ 2.20GHz, 2 nhân (x86_64)
Bộ nhớ RAM	13.6 GB
Ngôn ngữ lập trình	Python 3.13.18
Xử lý và phân tích dữ liệu	pandas 2.2.3, NumPy 2.1.3, SciPy 1.16.3
Khai phá luật kết hợp	mlxtend 0.23.4
Học máy và đánh giá mô hình	scikit-learn 1.6.1
Trực quan hóa	Matplotlib 3.10.0
Kho dữ liệu	SQLite 3.45.1 (thông qua thư viện sqlite3 của Python)
Ứng dụng minh họa	Gradio 6.30.0

Các thuật toán CBA, CMAR và CPAR được nhóm tự cài đặt bằng Python dựa trên mô tả trong các bài báo gốc (Liu et al., 1998; Li et al., 2001; Yin & Han, 2003), do các thư viện phổ biến không cung cấp sẵn. Mọi bước có yếu tố ngẫu nhiên, gồm chia dữ liệu và huấn luyện mô hình, đều cố định hạt giống ngẫu nhiên random_state = 42 để kết quả có thể tái lập.

Cần lưu ý rằng cấu hình phần cứng của Google Colab được cấp phát theo từng phiên làm việc và có thể thay đổi giữa các lần chạy. Do đó, thời gian thực thi báo cáo ở mục 4.4.1 chỉ có ý nghĩa so sánh tương đối giữa các thuật toán trong cùng một phiên, không phản ánh hiệu năng tuyệt đối của thuật toán.

CHƯƠNG 4. DỮ LIỆU VÀ KẾT QUẢ THỰC NGHIỆM

Chương này trình bày kết quả thực nghiệm theo quy trình nghiên cứu đã mô tả ở Chương 3 và đối chiếu từng kết quả với các mục tiêu (a) đến (e) ở mục 1.3. Nội dung gồm chín phần: phân tích thăm dò dữ liệu (mục 4.1) và tiền xử lý (mục 4.2) ứng với mục tiêu (a); xây dựng kho dữ liệu (Data Warehouse, mục 4.3) ứng với mục tiêu (b); khai phá luật kết hợp (mục 4.4) ứng với mục tiêu (c); phân loại dựa trên luật kết hợp (mục 4.5), tích hợp tri thức ngành vào lựa chọn luật (mục 4.6) và phân loại với thuộc tính sinh từ luật (mục 4.7) cùng ứng với mục tiêu (d); tổng hợp kết quả, minh họa ứng dụng và rút ra nhận định nghiệp vụ (mục 4.8 và 4.9) ứng với mục tiêu (e). Nhánh kho dữ liệu và nhánh khai phá luật được liên kết ở mục 4.6 thông qua bước kiểm tra chính sách (Hình 3.1). Xuyên suốt chương, đề án trả lời hai câu hỏi: thứ nhất, những tổ hợp thuộc tính nào gắn với kết quả xét duyệt; thứ hai, việc đưa các tổ hợp đó vào mô hình phân loại cải thiện hiệu năng dự đoán, hay chỉ cải thiện khả năng diễn giải và kiểm soát chính sách.

4.1. Kết quả phân tích thăm dò dữ liệu

Đề án thực hiện phân tích thăm dò dữ liệu nhằm trả lời ba câu hỏi: thứ nhất, chất lượng và phân phối của dữ liệu có đáp ứng điều kiện để xây dựng mô hình hay không; thứ hai, biến độc lập nào, khi xét riêng lẻ, phân biệt được lớp được duyệt (Approved) và lớp bị từ chối (Rejected); thứ ba, những đặc điểm nào của dữ liệu cần được xử lý ở bước tiền xử lý. Từ các số liệu và biểu đồ thu được, đề án rút ra các quyết định tiền xử lý ở mục 4.2.

4.1.1. Tổng quan bộ dữ liệu

Bộ dữ liệu gồm 45,000 hồ sơ vay và 14 cột, không có giá trị thiếu. Quá trình làm sạch loại 10 dòng có giá trị phi lý (tuổi lớn hơn 80 hoặc số năm kinh nghiệm lớn hơn 60) và không phát hiện dòng trùng lặp, còn lại 44,990 hồ sơ (Bảng 4.1).

Bảng 4.1. Tổng quan bộ dữ liệu và kết quả làm sạch

Chỉ tiêu	Giá trị
Số dòng ban đầu	45,000
Số cột	14
Số giá trị thiếu	0

Dòng phi lý bị loại (tuổi > 80 hoặc kinh nghiệm > 60)	10
Dòng trùng lặp bị loại	0
Số dòng sau làm sạch	44,990

Bảng 4.2 trình bày thống kê mô tả của tám biến số sau làm sạch. Thang đo của các biến chênh lệch lớn (thu nhập trung bình khoảng 79,909; số tiền vay khoảng 9,583; lãi suất khoảng 11%). Thu nhập có trung bình (79,908.83) lớn hơn trung vị (67,045.50) và giá trị lớn nhất là 2,448,661, nên phân phối thu nhập lệch phải; số tiền vay cũng có đuôi phải (trung bình 9,583.30; trung vị 8,000; tối đa 35,000). Điểm tín dụng nằm trong khoảng 390–784 với trung bình 632.58 và độ lệch chuẩn 50.39.

Bảng 4.2. Thống kê mô tả các biến số (sau làm sạch)

Biến	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
person_age	27.74	5.89	20.00	24.00	26.00	30.00	78.00
person_income	79,908.83	63,323.59	8,000.00	47,195.75	67,045.50	95,777.00	2,448,661
person_emp_exp	5.39	5.91	0.00	1.00	4.00	8.00	58.00
loan_amnt	9,583.30	6,314.98	500.00	5,000.00	8,000.00	12,237.75	35,000.00
loan_int_rate	11.01	2.98	5.42	8.59	11.01	12.99	20.00
loan_percent_income	0.14	0.09	0.00	0.07	0.12	0.19	0.66
cb_person_cred_hist_length	5.87	3.87	2.00	3.00	4.00	8.00	30.00
credit_score	632.58	50.39	390.00	601.00	640.00	670.00	784.00

Bảng 4.3 mô tả các biến phân loại, mỗi biến có từ 2 đến 6 giá trị. Giá trị phổ biến nhất của person_home_ownership là RENT (52.10%), của person_education là Bachelor (29.78%) và của loan_intent là EDUCATION (20.34%). Biến previous_loan_defaults_on_file nhận giá trị Yes ở 50.80% hồ sơ, tức là hơn một nửa dữ liệu thuộc nhóm từng vỡ nợ; đặc điểm này có hệ quả quan trọng ở mục 4.1.4.

Bảng 4.3. Mô tả các biến phân loại

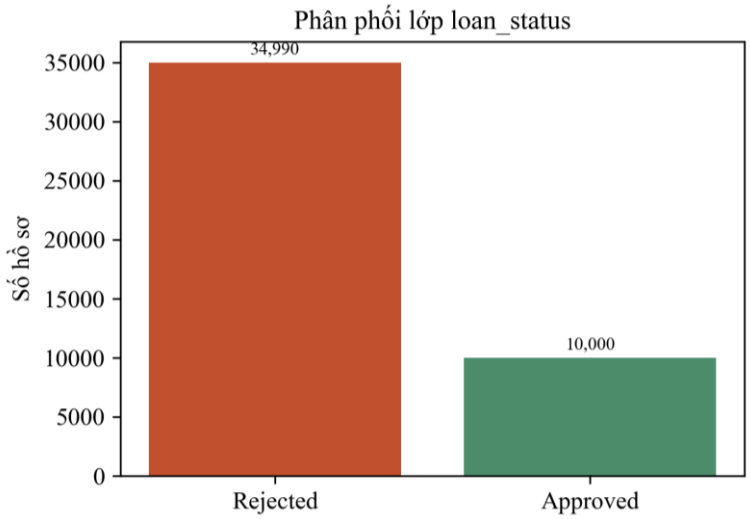
Biến	Số giá trị	Giá trị phổ biến nhất	Tỉ lệ (%)
person_gender	2	male	55.20
person_education	5	Bachelor	29.78
person_home_ownership	4	RENT	52.10
loan_intent	6	EDUCATION	20.34
previous_loan_defaults_on_file	2	Yes	50.80

4.1.2. Phân phối biến mục tiêu

Biến mục tiêu mất cân bằng: lớp Rejected có 34,990 hồ sơ (77.77%) và lớp Approved có 10,000 hồ sơ (22.23%) (Bảng 4.4, Hình 4.1). Hệ quả đối với thiết kế đánh giá như sau. Một bộ phân loại luôn dự đoán lớp đa số đạt độ chính xác tổng thể (accuracy) xấp xỉ 77.77% mà không sử dụng thông tin nào của các biến độc lập, nên độ chính xác tổng thể không được dùng làm tiêu chí đánh giá chính. Thay vào đó, đề án đánh giá các mô hình bằng ma trận nhầm lẫn và ba thước đo của lớp Approved: precision (tỉ lệ hồ sơ được dự đoán là Approved mà thực sự thuộc lớp Approved), recall (tỉ lệ hồ sơ thực sự thuộc lớp Approved mà mô hình nhận diện được) và điểm F0.5. Cơ sở của việc chọn điểm F0.5 được trình bày ở mục 4.5.1.

Bảng 4.4. Phân phối biến mục tiêu loan_status

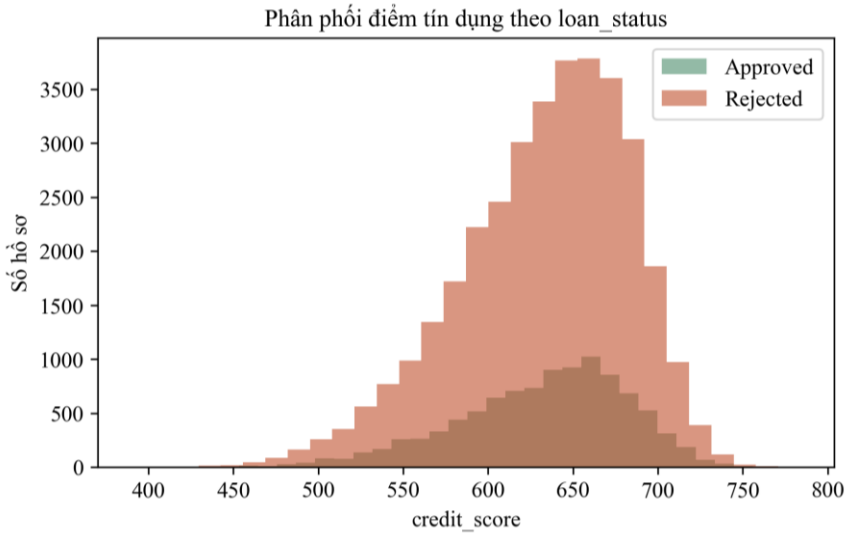
Lớp	Số hồ sơ	Tỉ lệ (%)
Rejected	34,990	77.77
Approved	10,000	22.23



Hình 4.1. Phân phối biến mục tiêu loan_status

4.1.3. Phân phối điểm tín dụng, tỉ lệ vay trên thu nhập và thu nhập theo lớp

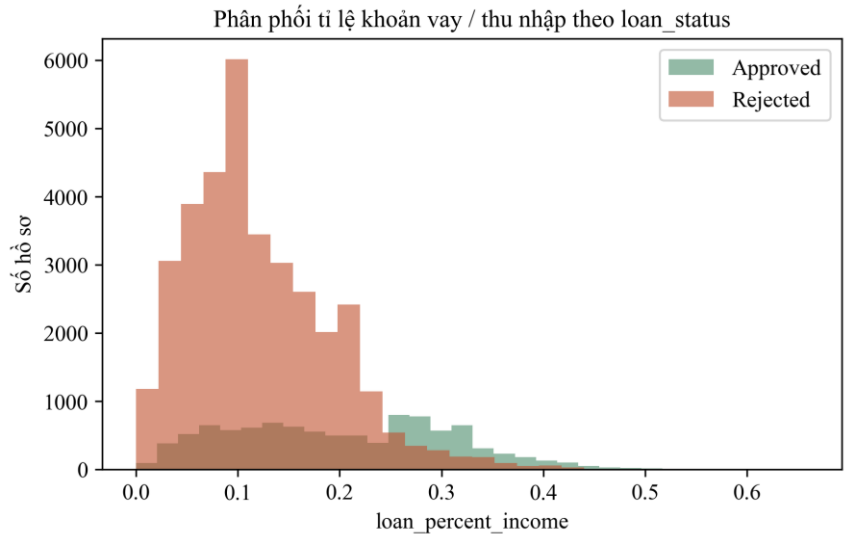
Điểm tín dụng (Hình 4.2). Biểu đồ cho thấy phân phối credit_score của hai lớp gần như chồng khít (giá trị trung bình khoảng 632.8 ở lớp Rejected và 631.9 ở lớp Approved). Trong lý thuyết chấm điểm tín dụng, điểm tín dụng được kỳ vọng là chỉ báo quan trọng của khả năng được duyệt; tuy nhiên, dữ liệu không cho thấy sự phân tách giữa hai lớp theo biến này. Vì vậy, đề án không giả định trước vai trò của credit_score mà kiểm chứng vai trò đó qua các tổ hợp thuộc tính ở mục 4.4.



Hình 4.2. Phân phối điểm tín dụng theo loan_status

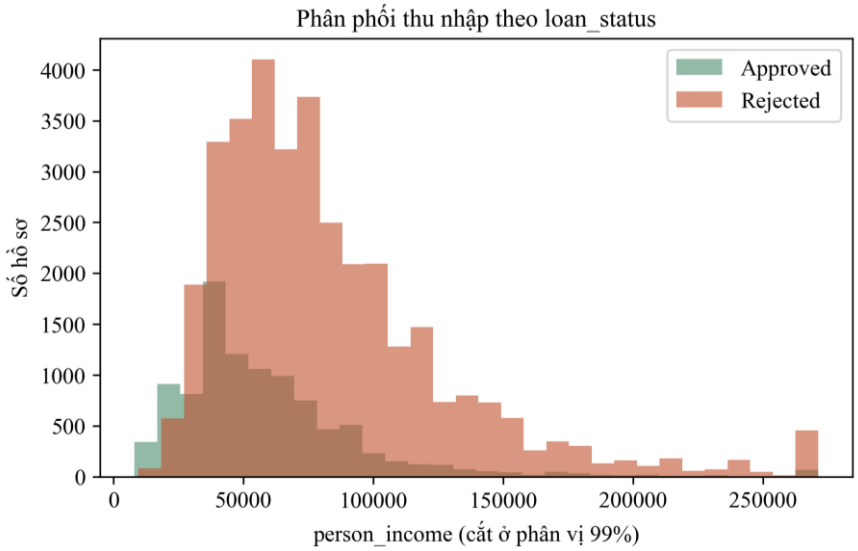
Tỉ lệ khoản vay trên thu nhập (Hình 4.3). Biểu đồ cho thấy lớp Approved có tỉ lệ khoản vay trên thu nhập cao hơn lớp Rejected (trung bình khoảng 0.203 so với 0.122), ngược với kỳ vọng tài chính rằng tỉ lệ này thấp gắn với khả năng trả nợ tốt hơn. Do phân tích thăm dò đơn biến không xác lập được quan hệ nhân quả, kết quả này không cho

phép kết luận rằng tỉ lệ cao làm tăng khả năng được duyệt; cách diễn giải phù hợp là biến này tương tác với các đặc điểm khác của hồ sơ.



Hình 4.3. Phân phối tỉ lệ khoản vay trên thu nhập theo loan_status

Thu nhập (Hình 4.4). Biểu đồ cho thấy phân phối thu nhập (cắt ở phân vị 99% để thuận tiện quan sát) lệch phải ở cả hai lớp. Lớp Approved tập trung ở vùng thu nhập thấp hơn (chủ yếu dưới khoảng 100,000, đỉnh quanh 40,000–60,000), trong khi lớp Rejected trải rộng hơn và có đỉnh ở mức cao hơn. Như vậy thu nhập cao không đi kèm xác suất được duyệt cao hơn trong dữ liệu này, một kết quả cũng ngược với kỳ vọng.



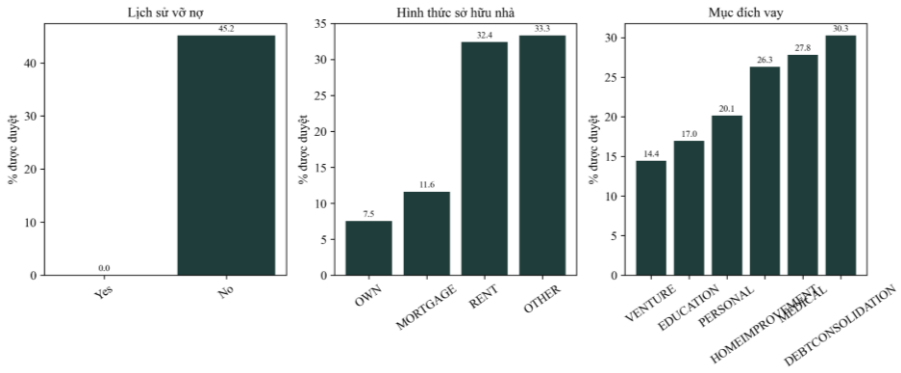
Hình 4.4. Phân phối thu nhập theo loan_status

Ba kết quả trên cùng cho thấy các biến tài chính đơn lẻ không giải thích được kết quả xét duyệt theo chiều hướng mà nghiệp vụ kỳ vọng, và là cơ sở để chuyển sang khai phá tổ hợp thuộc tính.

4.1.4. Phát hiện then chốt

Hình 4.5 trình bày tỉ lệ duyệt theo ba biến phân loại. Biến có khả năng phân biệt mạnh nhất là lịch sử vỡ nợ (previous_loan_defaults_on_file): nhóm từng vỡ nợ gồm 22,855 hồ sơ với tỉ lệ duyệt 0.0%, nghĩa là toàn bộ bị từ chối; nhóm chưa từng vỡ nợ gồm 22,135 hồ sơ với tỉ lệ duyệt 45.2% (Bảng 4.10). Như vậy xác suất bị từ chối của nhóm từng vỡ nợ bằng 1, và quan hệ này xuất hiện trực tiếp dưới dạng luật "từng vỡ nợ thì bị từ chối" ở mục 4.4, với confidence (độ tin cậy) 100% và support (độ hỗ trợ) 50.8%. Kết quả này cần được diễn giải thận trọng ở hai điểm. Thứ nhất, confidence 100% chỉ phản ánh tính nhất quán trong tập dữ liệu nghiên cứu, không suy rộng được thành quy tắc quyết định của mọi hệ thống xét duyệt. Thứ hai, nhóm chưa từng vỡ nợ vẫn có 54.8% hồ sơ bị từ chối (suy ra từ Bảng 4.10), nên chưa từng vỡ nợ là điều kiện cần chứ chưa đủ để được duyệt.

Hai biến còn lại cho kết quả ngược với kỳ vọng. Về hình thức sở hữu nhà, nhóm sở hữu hoàn toàn (OWN, khoảng 7.5%) và nhóm đang thế chấp (MORTGAGE, khoảng 11.6%) có tỉ lệ duyệt thấp hơn hẳn nhóm thuê nhà (RENT, khoảng 32.4%) và nhóm khác (OTHER, khoảng 33.3%); các giá trị này được đọc từ Hình 4.5 và được đối chiếu bằng truy vấn xử lý phân tích trực tuyến ở mục 4.3. Về mục đích vay, tỉ lệ duyệt thấp nhất ở kinh doanh mạo hiểm (VENTURE, 14.4%) và giáo dục (EDUCATION, 17.0%), tiếp theo là vay cá nhân (PERSONAL, 20.1%), cải tạo nhà (HOMEIMPROVEMENT, 26.3%), y tế (MEDICAL, 27.8%) và cao nhất ở hợp nhất nợ (DEBTCONSOLIDATION, 30.3%).



Hình 4.5. Tỉ lệ duyệt theo lịch sử vỡ nợ, sở hữu nhà và mục đích vay

Tóm lại, phân tích thăm dò dữ liệu cho thấy bốn đặc điểm: thứ nhất, lớp mất cân bằng; thứ hai, lịch sử vỡ nợ quyết định gần như tuyệt đối lớp Rejected; thứ ba, nhiều biến (điểm tín dụng, tỉ lệ vay trên thu nhập, thu nhập, hình thức sở hữu nhà) cho kết quả

ngược với kỳ vọng nghiệp vụ; thứ tư, nhóm biến tuổi, kinh nghiệm và lịch sử tín dụng có dấu hiệu đa cộng tuyến (mục 4.2.2). Các đặc điểm này định hướng các quyết định tiền xử lý và thiết kế đánh giá ở các phần sau.

4.2. Kết quả tiền xử lý

4.2.1. Làm sạch dữ liệu

Dữ liệu chỉ bị loại các giá trị phi lý về nghiệp vụ (tuổi lớn hơn 80 hoặc số năm kinh nghiệm lớn hơn 60; 10 dòng) và các bản ghi trùng lặp (không có), còn lại 44,990 hồ sơ (Bảng 4.1). Đề án không dùng quy tắc khoảng tứ phân vị để loại giá trị ngoại lai. Thu nhập và số tiền vay có phân phối lệch phải một cách tự nhiên, nên quy tắc này sẽ xếp một tỉ lệ đáng kể các hồ sơ hợp lệ (thu nhập cao hoặc khoản vay lớn) vào nhóm ngoại lai và làm mất thông tin. Chỉ các giá trị vi phạm ràng buộc thực tế (như tuổi 144) được xử lý, và phương án loại bỏ được chọn thay cho cắt ngưỡng hoặc thay thế vì đây là các lỗi nhập liệu rõ ràng.

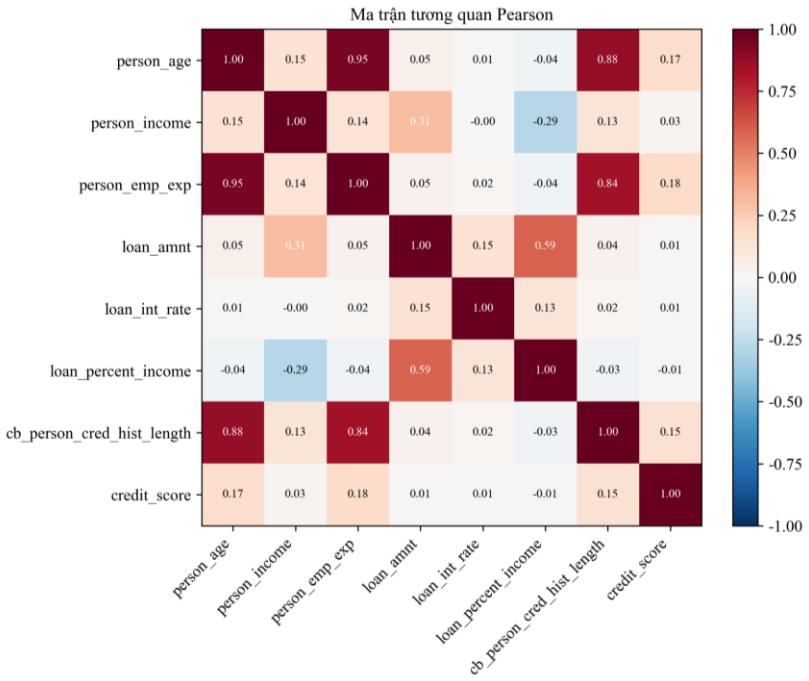
4.2.2. Xử lý đa cộng tuyến

Ma trận tương quan Pearson (Hình 4.6, Bảng 4.5) cho thấy ba biến person_age, person_emp_exp và cb_person_cred_hist_length tạo thành một cụm đa cộng tuyến: hệ số tương quan giữa tuổi và kinh nghiệm là 0.95; giữa tuổi và độ dài lịch sử tín dụng là 0.88; giữa kinh nghiệm và độ dài lịch sử tín dụng là 0.84, đều vượt ngưỡng cảnh báo 0.8. Mối tương quan này hợp lý về nghiệp vụ (tuổi cao thường đi cùng nhiều năm kinh nghiệm và lịch sử tín dụng dài hơn) nhưng làm ba biến mang thông tin trùng lặp. Do đó, đề án chỉ giữ person_age làm biến đại diện và loại hai biến person_emp_exp và cb_person_cred_hist_length. Các cặp còn lại ở mức chấp nhận được: tương quan giữa số tiền vay và tỉ lệ khoản vay trên thu nhập là 0.59; giữa thu nhập và số tiền vay là 0.31; giữa thu nhập và tỉ lệ khoản vay trên thu nhập là −0.29.

Bảng 4.5. Các cặp biến số có tương quan mạnh nhất

Biến 1	Biến 2	Hệ số r	Đánh giá
person_age	person_emp_exp	0.95	Đa cộng tuyến cao, giữ một biến

person_age	cb_person_cred_hist_length	0.88	Đa cộng tuyến cao, giữ một biến
person_emp_exp	cb_person_cred_hist_length	0.84	Đa cộng tuyến cao, giữ một biến
loan_amnt	loan_percent_income	0.59	Chấp nhận được
person_income	loan_amnt	0.31	Chấp nhận được
person_income	loan_percent_income	-0.29	Chấp nhận được



Hình 4.6. Ma trận tương quan Pearson giữa các biến số

4.2.3. Rời rạc hóa bằng ngưỡng nghiệp vụ

Đề án rời rạc hóa các biến số theo ngưỡng nghiệp vụ thay vì theo phân vị (Bảng 4.6): điểm tín dụng theo các mốc 580, 670 và 740 thành bốn nhóm Poor, Fair, Good và VeryGood (theo chuẩn điểm tín dụng của công ty Fair Isaac); thu nhập theo các mốc 30,000, 60,000 và 100,000; số tiền vay theo các mốc 5,000, 10,000 và 20,000; lãi suất theo các mốc 10%, 13% và 16%; tỉ lệ vay trên thu nhập theo các mốc 10%, 20% và 30%; tuổi theo các mốc 25 và 35. Đây là điểm đầu tiên đề án đưa tri thức ngành vào quy trình, với hai lợi ích: các nhóm có ý nghĩa nghiệp vụ trực tiếp nên luật dễ diễn giải; và vì mốc cắt không phụ thuộc vào phân phối của dữ liệu nên không gây rò rỉ thông tin từ tập kiểm tra sang bước rời rạc hóa.

Bảng 4.6. Ngưỡng rời rạc hóa các biến số (ngưỡng nghiệp vụ)

Biến	Mốc cắt	Nhãn	Phân bố (%)
credit_score	580 | 670 | 740	Poor, Fair, Good, VeryGood	15.34; 59.58; 24.88; 0.20
person_income	30,000 | 60,000 | 100,000	<30k, 30-60k, 60-100k, >=100k	6.45; 34.19; 37.09; 22.27
loan_amnt	5,000 | 10,000 | 20,000	<5k, 5-10k, 10-20k, >=20k	22.99; 35.06; 32.22; 9.72
loan_int_rate	10 | 13 | 16	<10%, 10-13%, 13-16%, >=16%	35.15; 39.85; 19.79; 5.21
loan_percent_income	0.10 | 0.20 | 0.30	<10%, 10-20%, 20-30%, >=30%	36.54; 40.34; 16.90; 6.22
person_age	25 | 35	<25, 25-34, >=35	35.42; 52.75; 11.83

Đổi lại, ngưỡng nghiệp vụ tạo ra các nhóm có kích thước không đồng đều: nhóm VeryGood chỉ chiếm 0.20% (điểm tín dụng tối đa là 784), nhóm Fair chiếm 59.58% và nhóm lãi suất từ 16% trở lên chiếm 5.21%. Với ngưỡng support tối thiểu 2% ở bước khai phá, nhóm VeryGood không thể xuất hiện trong luật; đây là một hạn chế được nêu ở mục 5.3.

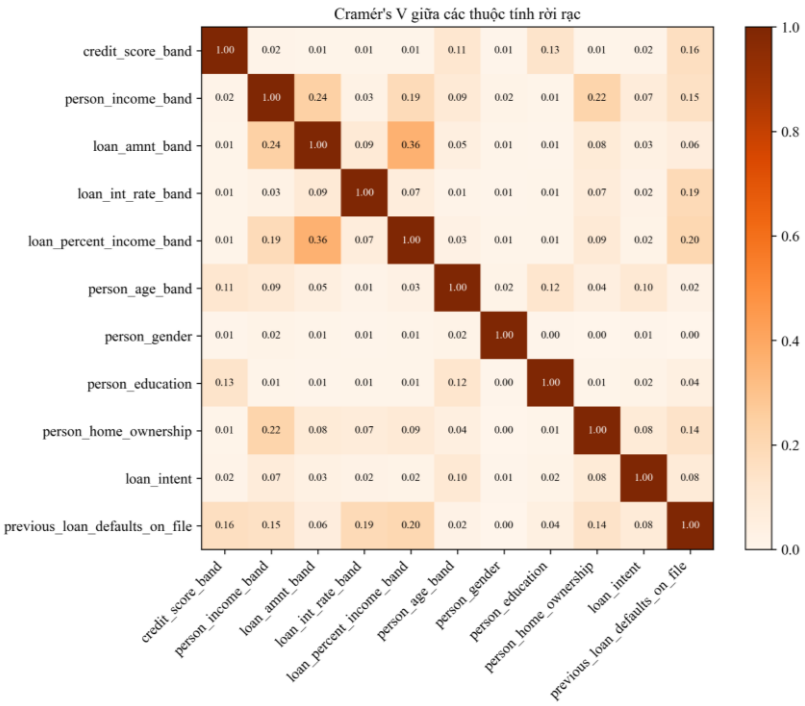
4.2.4. Kiểm tra phụ thuộc giữa các thuộc tính rời rạc

Sau khi rời rạc hóa, đề án đo mức độ phụ thuộc giữa các thuộc tính rời rạc bằng hệ số Cramér's V (Hình 4.7, Bảng 4.7). Cặp có V cao nhất là loan_amnt_band – loan_percent_income_band (V = 0.36), phù hợp vì tỉ lệ vay trên thu nhập được tính trực tiếp từ số tiền vay; các cặp còn lại có V từ 0.19 đến 0.24. Tất cả đều thấp hơn ngưỡng cảnh báo $V \geq 0.5$, nên các thuộc tính rời rạc không phụ thuộc nhau mạnh đến mức gây dư thừa luật và bộ thuộc tính được giữ nguyên.

Bảng 4.7. Các cặp thuộc tính rời rạc có Cramér's V cao nhất

Thuộc tính 1	Thuộc tính 2	Cramér's V
loan_amnt_band	loan_percent_income_band	0.36
person_income_band	loan_amnt_band	0.24

person_income_band	person_home_ownership	0.22
loan_percent_income_band	previous_loan_defaults_on_file	0.20
loan_int_rate_band	previous_loan_defaults_on_file	0.19
person_income_band	loan_percent_income_band	0.19



Hình 4.7. Ma trận Cramér's V giữa các thuộc tính rời rạc

4.2.5. Chia tập huấn luyện, kiểm định và kiểm tra

Đề án chia dữ liệu theo tỉ lệ 60/20/20 có phân tầng theo trạng thái khoản vay, giữ tỉ lệ Approved ở mức 22.23% trên cả ba tập (Bảng 4.8). Phép chia dùng hạt giống ngẫu nhiên cố định bằng 42 (random_state = 42) nên kết quả có thể tái lập. Vai trò của từng tập được tách bạch: tập huấn luyện dùng để khai phá luật và huấn luyện mô hình; tập kiểm định dùng dùng để chọn thuật toán (mục 4.5) ; tập kiểm tra chỉ dùng cho đánh giá cuối cùng ở mục 4.7. Việc tách riêng tập kiểm định tránh dùng tập kiểm tra cho lựa chọn mô hình, qua đó hạn chế ước lượng hiệu năng lạc quan.

Bảng 4.8. Kết quả chia dữ liệu

Tập	Số hồ sơ	Tỉ trọng (%)	Tỉ lệ Approved (%)
Tập huấn luyện	26,994	60.00	22.23
Tập kiểm định	8,998	20.00	22.23
Tập kiểm tra	8,998	20.00	22.23

4.3. Kết quả xây dựng kho dữ liệu

Đề án xây dựng kho dữ liệu (Data Warehouse) để tổ chức dữ liệu đã làm sạch theo cấu trúc đa chiều, phục vụ truy vấn phân tích và kiểm tra chính sách. Kho dữ liệu được xây dựng từ dữ liệu sau khi làm sạch và hoạt động độc lập với bước chia tập và khai phá luật (Hình 3.1).

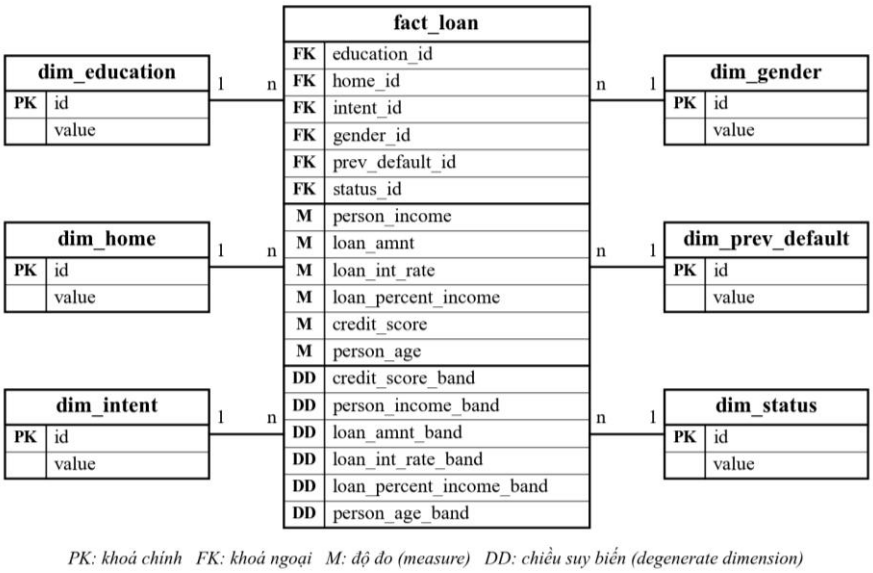
4.3.1. Thiết kế mô hình hình sao

Đề án thiết kế kho dữ liệu theo mô hình hình sao (star schema) (Hình 4.8) và bốn bước thiết kế mô hình đa chiều của Kimball: quy trình nghiệp vụ là xét duyệt hồ sơ vay; mức độ chi tiết (grain) là một hồ sơ vay trên một dòng; các chiều phân tích là sáu bảng chiều (dimension); các độ đo là thuộc tính số của hồ sơ. Bảng sự kiện fact_loan có 44,990 dòng và 18 cột thuộc ba nhóm: sáu khóa ngoại (education_id, home_id, intent_id, gender_id, prev_default_id, status_id); sáu độ đo (person_income, loan_amnt, loan_int_rate, loan_percent_income, credit_score, person_age); và sáu chiều suy biến (degenerate dimensions) là các nhóm đã rời rạc hóa (credit_score_band, person_income_band, loan_amnt_band, loan_int_rate_band, loan_percent_income_band, person_age_band). Các nhóm này được đặt trực tiếp trong bảng sự kiện vì chỉ là nhãn nhóm, không có thuộc tính mô tả bổ sung, nên không cần tách thành bảng chiều riêng; cách làm này giữ lược đồ gọn và giảm số phép nối.

Sáu bảng chiều (dim_education, dim_gender, dim_home, dim_intent, dim_prev_default, dim_status) có cấu trúc gồm mã (id) và giá trị (value). Ngoài các bảng, kho dữ liệu có hai khung nhìn (view) (Bảng 4.9): v_loan hợp nhất bảng sự kiện với giá trị mô tả của các bảng chiều để thuận tiện truy vấn; v_policy mở rộng v_loan bằng một cột đánh dấu vi phạm chính sách tín dụng, được sử dụng ở mục 4.6. Kho dữ liệu được lưu bằng hệ quản trị cơ sở dữ liệu SQLite.

Bảng 4.9. Các bảng và khung nhìn trong kho dữ liệu

Tên	Loại	Số dòng	Số cột
dim_education	Bảng	5	2
dim_gender	Bảng	2	2
dim_home	Bảng	4	2
dim_intent	Bảng	6	2
dim_prev_default	Bảng	2	2
dim_status	Bảng	2	2
fact_loan	Bảng	44,990	18
v_loan	Khung nhìn	44,990	24
v_policy	Khung nhìn	44,990	25



Hình 4.8. Mô hình hình sao (star schema) của kho dữ liệu hồ sơ vay

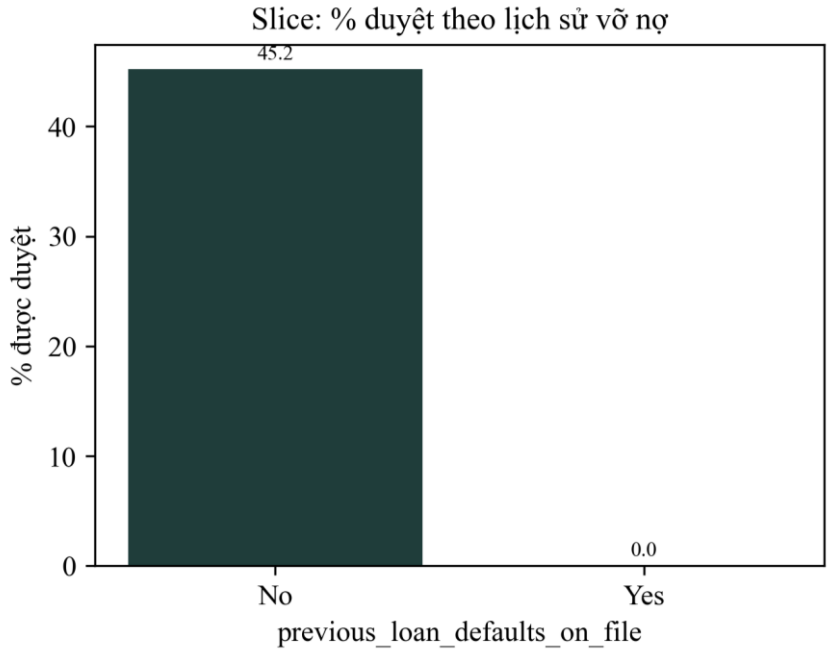
Do dữ liệu gốc không có trường thời gian, kho dữ liệu không có chiều thời gian; đặc tính biến đổi theo thời gian (time-variant) của kho dữ liệu chưa được hiện thực trong phạm vi nghiên cứu.

4.3.2. Phép cắt lát: tỉ lệ duyệt theo lịch sử vỡ nợ

Phép cắt lát theo lịch sử vỡ nợ cho kết quả trùng khớp hoàn toàn với phân tích thăm dò dữ liệu (Bảng 4.10, Hình 4.9): nhóm chưa từng vỡ nợ gồm 22,135 hồ sơ với tỉ lệ duyệt 45.20%; nhóm từng vỡ nợ gồm 22,855 hồ sơ với tỉ lệ duyệt 0.00%. Sự trùng khớp cho thấy quy trình nạp dữ liệu vào kho dữ liệu không làm sai lệch dữ liệu.

Bảng 4.10. Phép cắt lát (Slice) - tỉ lệ duyệt theo lịch sử vỡ nợ

prev_default	n	pct_approved
No	22,135	45.20
Yes	22,855	0.00



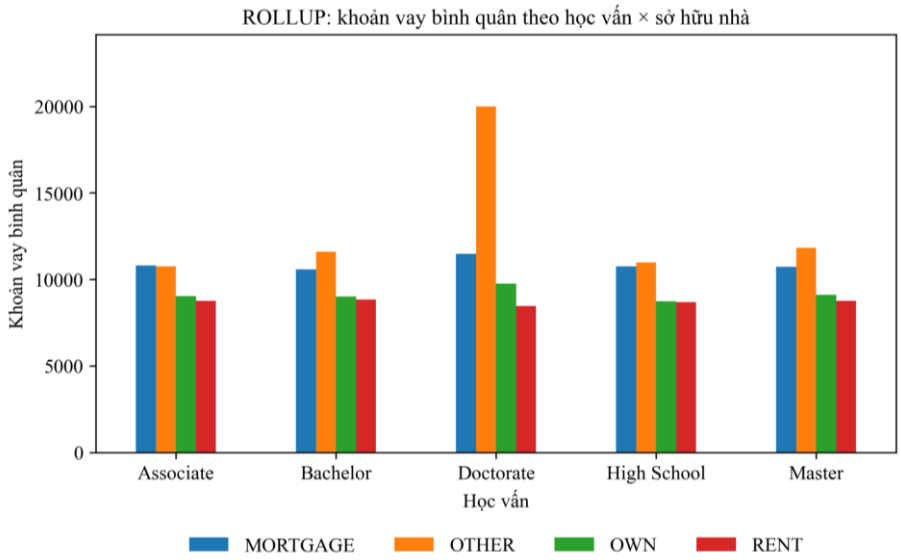
Hình 4.9. Phép cắt lát (Slice) – tỉ lệ duyệt theo lịch sử vỡ nợ

4.3.3. Phép gộp cấp (ROLLUP): khoản vay bình quân theo học vấn và sở hữu nhà

Phép gộp cấp hai tầng (học vấn, rồi hình thức sở hữu nhà) cho thấy khoản vay bình quân phụ thuộc vào hình thức sở hữu nhà một cách nhất quán ở mọi nhóm học vấn (Bảng 4.11, Hình 4.10). Nhóm đang thế chấp (MORTGAGE) có khoản vay bình quân cao nhất (khoảng 10,571–11,482); nhóm sở hữu hoàn toàn (OWN) và nhóm thuê nhà (RENT) thấp hơn (khoảng 8,456–9,753); khoản vay bình quân theo học vấn gần như không đổi (9,543–9,931). Như vậy hình thức sở hữu nhà tạo khác biệt về quy mô khoản vay mạnh hơn trình độ học vấn. Nhóm khác (OTHER) có quy mô rất nhỏ (từ 1 đến 41 hồ sơ mỗi nhóm học vấn; nhóm trình độ tiến sĩ chỉ có một hồ sơ) nên giá trị trung bình của nhóm này không đủ tin cậy. Kết hợp với Hình 4.5, nhóm đang thế chấp có khoản vay lớn hơn nhưng tỉ lệ duyệt thấp hơn nhóm thuê nhà; do đó khoản vay lớn hơn không đi kèm xác suất được duyệt cao hơn.

Bảng 4.11. Phép gộp cấp (ROLLUP) học vấn rồi sở hữu nhà – khoản vay bình quân

edu	home	n	avg_loan
Associate	MORTGAGE	4,967	10,800
Associate	OTHER	35	10,747
Associate	OWN	804	9,040
Associate	RENT	6,220	8,763
Bachelor	MORTGAGE	5,441	10,571
Bachelor	OTHER	41	11,591
Bachelor	OWN	854	9,023
Bachelor	RENT	7,060	8,827
Doctorate	MORTGAGE	280	11,482
Doctorate	OTHER	1	20,000
Doctorate	OWN	44	9,753
Doctorate	RENT	296	8,456
High School	MORTGAGE	4,931	10,753
High School	OTHER	29	10,988
High School	OWN	756	8,742
High School	RENT	6,251	8,679
Master	MORTGAGE	2,865	10,720
Master	OTHER	11	11,818
Master	OWN	493	9,105
Master	RENT	3,611	8,763
Associate	ALL	12,026	9,629
Bachelor	ALL	13,396	9,556
Doctorate	ALL	621	9,931
High School	ALL	11,967	9,543
Master	ALL	6,980	9,595
ALL	ALL	44,990	9,583



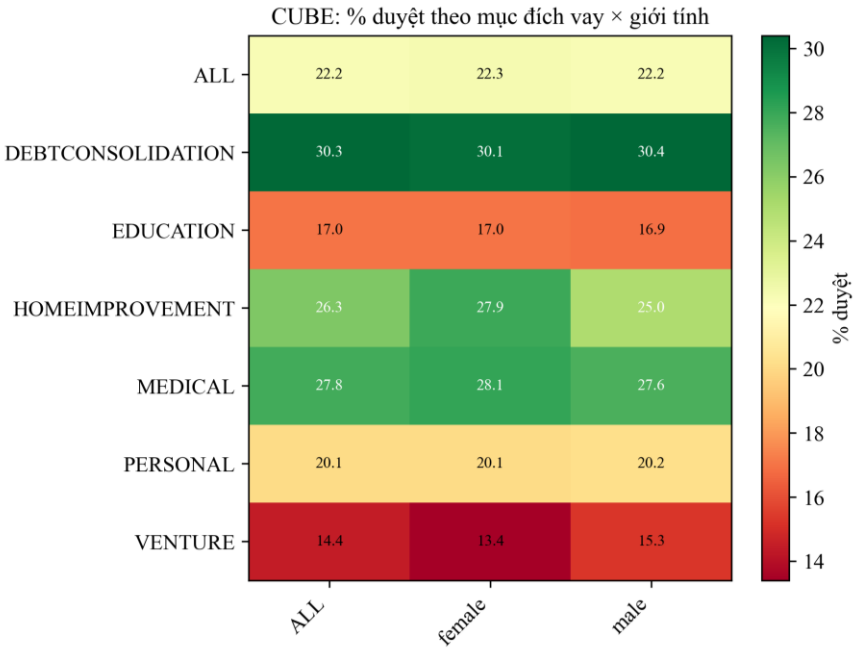
Hình 4.10. Phép gộp cấp (ROLLUP) – khoản vay bình quân theo học vấn và sở hữu nhà

4.3.4. Phép khối (CUBE): tỉ lệ duyệt theo mục đích vay và giới tính

Phép khối theo mục đích vay và giới tính (Bảng 4.12, Hình 4.11) xác nhận sự khác biệt giữa các mục đích vay: tỉ lệ duyệt dao động từ 14.40% (kinh doanh mạo hiểm) đến 30.30% (hợp nhất nợ), trong khi tỉ lệ duyệt chung của hai giới gần như bằng nhau (nữ 22.30%; nam 22.20%). Trong cùng một mục đích vay, chênh lệch giữa nữ và nam không quá 0.5 điểm phần trăm ở bốn trong sáu nhóm, ngoại trừ cải tạo nhà (27.90% so với 25.00%) và kinh doanh mạo hiểm (13.40% so với 15.30%). Các chênh lệch này nhỏ hơn nhiều so với chênh lệch giữa các mục đích vay. Đây là mô tả tổng hợp, chưa phải là đánh giá công bằng tín dụng.

Bảng 4.12. Phép khối (CUBE) theo mục đích vay và giới tính – tỉ lệ được duyệt (%)

Mục đích vay	ALL	female	male
ALL	22.20	22.30	22.20
DEBTCONSOLIDATION	30.30	30.10	30.40
EDUCATION	17.00	17.00	16.90
HOMEIMPROVEMENT	26.30	27.90	25.00
MEDICAL	27.80	28.10	27.60
PERSONAL	20.10	20.10	20.20
VENTURE	14.40	13.40	15.30



Hình 4.11. Phép khối (CUBE) – tỉ lệ được duyệt theo mục đích vay và giới tính

4.3.5. Bốn truy vấn nghiệp vụ

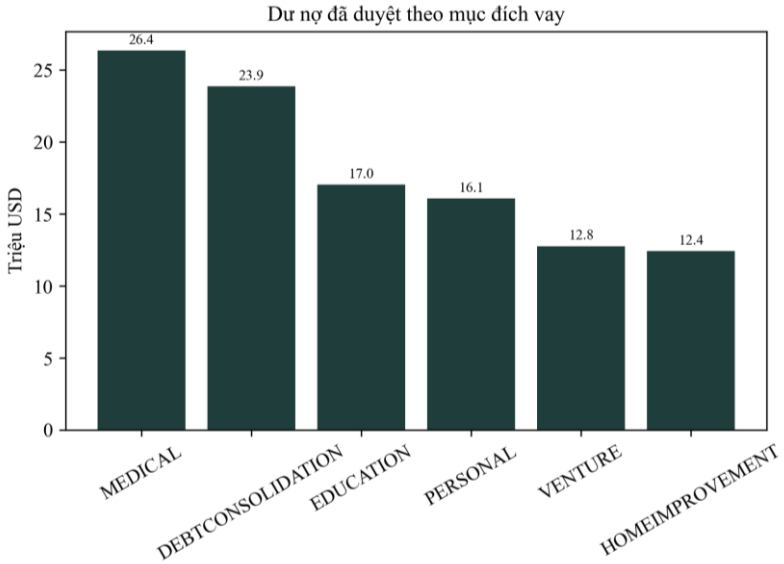
Để minh họa khả năng của kho dữ liệu trong việc trả lời các câu hỏi nghiệp vụ, đề án xây dựng bốn truy vấn, mỗi truy vấn tương ứng với nhu cầu thông tin của một bộ phận.

Truy vấn 1 – Quản lý danh mục tín dụng: dư nợ đã duyệt theo mục đích vay. Tổng dư nợ của 10,000 hồ sơ đã duyệt là 108,556,898 (tổng các giá trị ở **Bảng 4.13**), trong đó MEDICAL chiếm 24.28% và DEBTCONSOLIDATION chiếm 21.98%, cộng lại 46.26%; VENTURE và HOMEIMPROVEMENT mỗi nhóm khoảng 11.5–11.8%. MEDICAL có dư nợ lớn nhất dù DEBTCONSOLIDATION có tỉ lệ duyệt cao nhất (30.3%), vì MEDICAL có nhiều hồ sơ được duyệt hơn (2,378 so với 2,163). Kết quả cho thấy cơ cấu danh mục tập trung vào hai mục đích này (đơn vị tiền theo Hình 4.12là triệu USD).

Bảng 4.13. Truy vấn 1 – Dư nợ đã duyệt theo mục đích vay

loan_intent	Số hồ sơ	Dư nợ	Tỉ trọng (%)
MEDICAL	2,378	26,360,100	24.28
DEBTCONSOLIDATION	2,163	23,864,853	21.98
EDUCATION	1,552	17,044,874	15.70
PERSONAL	1,521	16,085,453	14.82

VENTURE	1.128	12.766.166	11,76
HOMEIMPROVEMENT	1.258	12.435.452	11,46

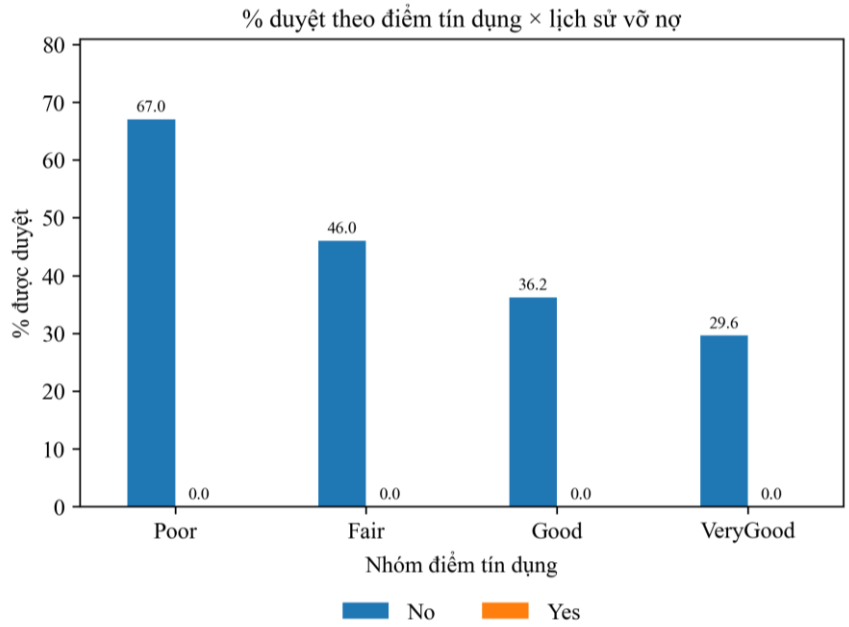


Hình 4.12. Truy vấn 1 – Dư nợ đã duyệt theo mục đích vay

Truy vấn 2 – Quản trị rủi ro tín dụng: tỉ lệ duyệt theo điểm tín dụng và lịch sử vỡ nợ. Trong nhóm từng vỡ nợ, tỉ lệ duyệt bằng 0.00% ở mọi nhóm điểm. Trong nhóm chưa từng vỡ nợ, tỉ lệ duyệt giảm dần khi điểm tín dụng tăng: Poor 67.00%, Fair 46.00%, Good 36.20%, Very Good 29.60% (Bảng 4.14, Hình 4.13). Quan hệ nghịch này trái với lý thuyết chấm điểm tín dụng, và nhất quán với kết quả phân tích thăm dò dữ liệu rằng điểm tín dụng không phân biệt hai lớp theo chiều hướng kỳ vọng. Quan hệ chỉ bộc lộ khi điều kiện hóa theo lịch sử vỡ nợ, và điều này cho thấy phân tích từng biến riêng lẻ có thể che khuất cấu trúc của dữ liệu.

Bảng 4.14. Truy vấn 2 – Tỉ lệ được duyệt (%) theo điểm tín dụng và lịch sử vỡ nợ

Điểm tín dụng	No	Yes
Poor	67.00	0.00
Fair	46.00	0.00
Good	36.20	0.00
VeryGood	29.60	0.00

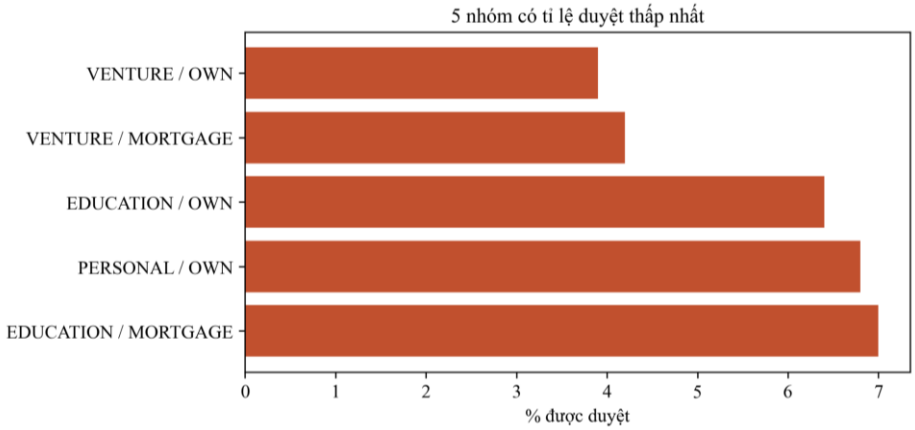


Hình 4.13. Truy vấn 2 – Tỉ lệ được duyệt theo điểm tín dụng và lịch sử vỡ nợ

Truy vấn 3 – Phát triển sản phẩm và kinh doanh: các phân khúc có tỉ lệ duyệt thấp nhất. Để hạn chế nhiễu do nhóm nhỏ, truy vấn chỉ xét các tổ hợp (mục đích vay, sở hữu nhà) có ít nhất 500 hồ sơ. Năm nhóm có tỉ lệ duyệt thấp nhất nằm trong khoảng 3.90–7.00%, thấp hơn nhiều so với mức chung 22.2%: VENTURE/OWN (3.90%), VENTURE/MORTGAGE (4.20%), EDUCATION/OWN (6.40%), PERSONAL/OWN (6.80%) và EDUCATION/MORTGAGE (7.00%) (Bảng 4.15, Hình 4.14). Như vậy tổ hợp của hình thức sở hữu nhà OWN hoặc MORTGAGE với các mục đích VENTURE, EDUCATION, PERSONAL tạo ra các phân khúc rất ít được duyệt, và là đối tượng để bộ phận kinh doanh rà soát chính sách sản phẩm.

Bảng 4.15. Truy vấn 3 – Năm nhóm (mục đích, sở hữu nhà) có tỉ lệ duyệt thấp nhất (n ≥ 500)

Nhóm	n	Tỉ lệ duyệt (%)
VENTURE / OWN	897	3,90
VENTURE / MORTGAGE	3.140	4,20
EDUCATION / OWN	614	6,40
PERSONAL / OWN	516	6,80
EDUCATION / MORTGAGE	3.729	7,00



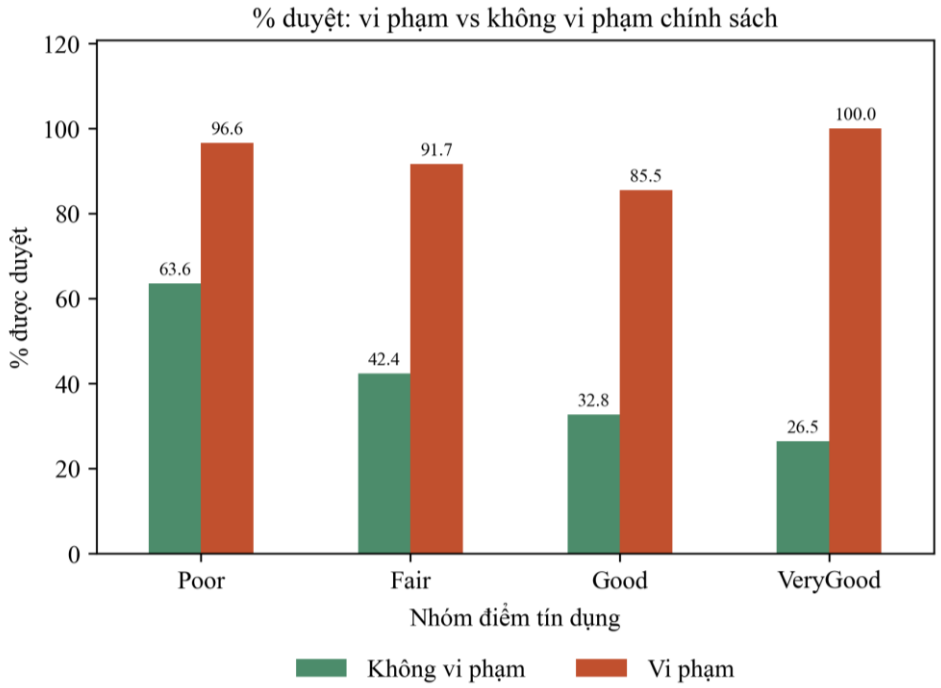
Hình 4.14. Truy vấn 3 – Năm nhóm có tỉ lệ duyệt thấp nhất

Truy vấn 4 – Kiểm soát chính sách tín dụng: tỉ lệ duyệt của hồ sơ vi phạm và không vi phạm năng lực trả nợ. Truy vấn áp dụng tri thức ngành về năng lực trả nợ: một hồ sơ được coi là vi phạm nếu thu nhập dưới 25,000 hoặc khoản vay vượt 40% thu nhập. Do không có chuẩn quy định trực tiếp cho tỉ lệ khoản vay trên thu nhập năm (các chuẩn thẩm định phổ biến áp dụng cho tỉ lệ nợ trên thu nhập – DTI, vốn không tính được từ dữ liệu), đề án đặt ngưỡng gánh nặng nợ tối đa là 40%, tương ứng với khoảng 1% hồ sơ có gánh nặng nợ cao nhất. Giả định này được ghi nhận ở mục 5.3. Trong nhóm chưa từng vỡ nợ, hồ sơ vi phạm có tỉ lệ duyệt cao hơn hẳn hồ sơ không vi phạm ở mọi nhóm điểm tín dụng: Poor 96.60% so với 63.60%; Fair 91.70% so với 42.40%; Good 85.50% so với 32.80%; VeryGood 100.00% (tuy nhiên, nhóm này chỉ có 3 hồ sơ vi phạm nên tỉ lệ không có ý nghĩa thống kê) so với 26.50% (Bảng 4.16, Hình 4.15).

Bảng 4.16. Truy vấn 4 – Tỉ lệ được duyệt (%) của hồ sơ vi phạm và không vi phạm năng lực trả nợ (nhóm chưa từng vỡ nợ)

Điểm tín dụng	Không vi phạm	Vi phạm
Poor	63.60	96.60
Fair	42.40	91.70
Good	32.80	85.50
VeryGood	26.50	100.00

Ghi chú: vi phạm là thu nhập dưới 25,000 hoặc khoản vay trên 40% thu nhập.



Hình 4.15. Truy vấn 4 – Tỉ lệ được duyệt của hồ sơ vi phạm và không vi phạm năng lực trả nợ

4.3.6. Vấn đề đặt ra từ kho dữ liệu

Truy vấn 4 chỉ ra một vấn đề: hồ sơ vi phạm năng lực trả nợ vẫn được duyệt với tỉ lệ 85.5–100%, nghĩa là dữ liệu lịch sử chứa các quyết định không phù hợp với tri thức ngành. Một thuật toán khai phá chỉ tối ưu theo tiêu chí thống kê có nguy cơ học lại các quyết định đó dưới dạng luật. Vấn đề này là cơ sở của mục 4.6, nơi tri thức ngành được dùng để lọc luật sau khai phá.

4.4. Kết quả khai phá luật kết hợp

Kết quả phân tích thăm dò dữ liệu và kho dữ liệu cho thấy các biến đơn lẻ không giải thích được kết quả xét duyệt. Do đó, đề án khai phá các tổ hợp thuộc tính đi cùng trạng thái được duyệt hoặc bị từ chối, trên các thuộc tính rời rạc ở mục 4.2.3, với ba độ đo (mục 2.1.4): support (độ hỗ trợ, tỉ lệ hồ sơ thỏa đồng thời vế trái và vế phải của luật), confidence (độ tin cậy, xác suất vế phải xảy ra khi vế trái đã xảy ra) và lift (độ nâng, tỉ số giữa confidence và xác suất nền của vế phải).

4.4.1. So sánh Apriori và FP-Growth

Đề án chạy hai thuật toán Apriori và FP-Growth trên cùng dữ liệu và cùng ngưỡng. Cả hai thuật toán sinh ra đúng 10,478 tập mục thường xuyên (frequent itemset)

(Bảng 4.17), phù hợp với bản chất của các thuật toán chính xác: với cùng ngưỡng, không gian tập mục thường xuyên phải như nhau, nên tiêu chí chọn thuật toán là thời gian thực thi chứ không phải chất lượng luật. Apriori mất 2.11 giây, FP-Growth mất 1,043.22 giây; đề án chọn Apriori và dùng chung cho các bước sau, bảo đảm ba thuật toán phân loại ở mục 4.5 làm việc trên cùng một không gian luật (mục 4.5.4). Kết quả này chỉ có giá trị trong cấu hình thực nghiệm, vì hiệu năng phụ thuộc vào kích thước dữ liệu, số lượng mục, ngưỡng support và cách cài đặt. Mức chênh lệch khoảng 494 lần (1,043.22 chia 2.11) lớn hơn nhiều so với kỳ vọng lý thuyết rằng FP-Growth tránh sinh ứng viên, nên cần được kiểm tra lại bằng nhiều lần đo trên cùng định dạng đầu vào.

Bảng 4.17. So sánh Apriori và FP-Growth

Thuật toán	Số tập mục thường xuyên	Thời gian (giây)
Apriori	10,478	2.11
FP-Growth	10,478	1,043.22

Ghi chú: hai thuật toán cho cùng tập mục thường xuyên: có.

4.4.2. Ràng buộc thống kê đồng bộ và hệ số chắc chắn

Đề án áp dụng một bộ ràng buộc thống nhất cho mọi thuật toán khai phá: support tối thiểu 0.02; hệ số chắc chắn (certainty factor) tối thiểu 0.30; tối đa 3 điều kiện ở vế trái (Bảng 4.18). Đề án dùng hệ số chắc chắn thay cho confidence vì dữ liệu mất cân bằng: một ngưỡng confidence cố định có ý nghĩa khác nhau ở hai lớp. Với lớp Rejected chiếm 77.77%, một luật dự đoán Rejected đã đạt confidence khoảng 0.78 ngay cả khi vế trái không mang thông tin, còn với lớp Approved chỉ chiếm 22.23%, confidence 0.60 đã là mức cao. Hệ số chắc chắn chuẩn hóa confidence theo xác suất nền P(Y) của lớp, theo công thức (confidence − P(Y)) / (1 − P(Y)) khi confidence lớn hơn P(Y), nên cùng một ngưỡng tương ứng cùng một mức cải thiện tương đối so với xác suất nền ở cả hai lớp. Với ngưỡng 0.30, confidence tối thiểu tương ứng là $0.2223 + 0.30 \times 0.7777 \approx 0.46$ đối với luật Approved và $0.7777 + 0.30 \times 0.2223 \approx 0.84$ đối với luật Rejected, khớp với vùng phân bố của các luật ở Hình 4.16. Như vậy ràng buộc là đồng bộ về mặt thống kê giữa hai lớp.

Đề án thu được 1,530 luật, gồm 169 luật dẫn tới Approved và 1,361 luật dẫn tới Rejected; số luật Rejected nhiều gấp khoảng tám lần, phản ánh sự mất cân bằng của dữ liệu.

Bảng 4.18. Ràng buộc khai phá và số luật lớp thu được

Chỉ tiêu	Giá trị
Support tối thiểu	0.02
Hệ số chắc chắn tối thiểu	0.30
Số điều kiện tối đa ở vế trái	3
Luật dẫn tới Approved	169
Luật dẫn tới Rejected	1,361
Tổng số luật	1,530

4.4.3. Luật minh họa

Bảng 4.19 trình bày năm luật có lift cao nhất ở mỗi lớp. Ở lớp Approved, các luật mạnh nhất đều chứa điều kiện:

loan_percent_income_band=>=30% và person_home_ownership=RENT,

với confidence 1.00 và lift 4.50, bằng đúng giá trị tối đa 1/P(Approved) = 1/0.2223 ≈ 4.50; nghĩa là mọi hồ sơ thỏa vế trái trong tập huấn luyện đều được duyệt. Ở lớp Rejected, luật mạnh nhất là:

previous_loan_defaults_on_file=Yes → Rejected

với support 0.51, confidence 1.00 và lift 1.29, bằng giá trị tối đa 1/0.7777 ≈ 1.29; bốn luật còn lại là các luật cụ thể hóa của luật này (thêm một điều kiện về điểm tín dụng hoặc thu nhập) với cùng confidence và lift, nên không mang thêm thông tin và cần được loại bỏ ở bước phân loại. Do lift bị chặn theo lớp, lift chỉ so sánh trực tiếp được giữa các luật cùng lớp.

Các luật Approved có lift cao nhất mô tả những hồ sơ có khoản vay vượt 30% thu nhập; đây chính là nhóm có rủi ro cao theo tri thức ngành, nhất quán với kết quả của Truy vấn 4 (mục 4.3.5). Như vậy, một luật có thể đúng về mặt thống kê nhưng không đúng về mặt nghiệp vụ. Vấn đề được xử lý ở mục 4.6.

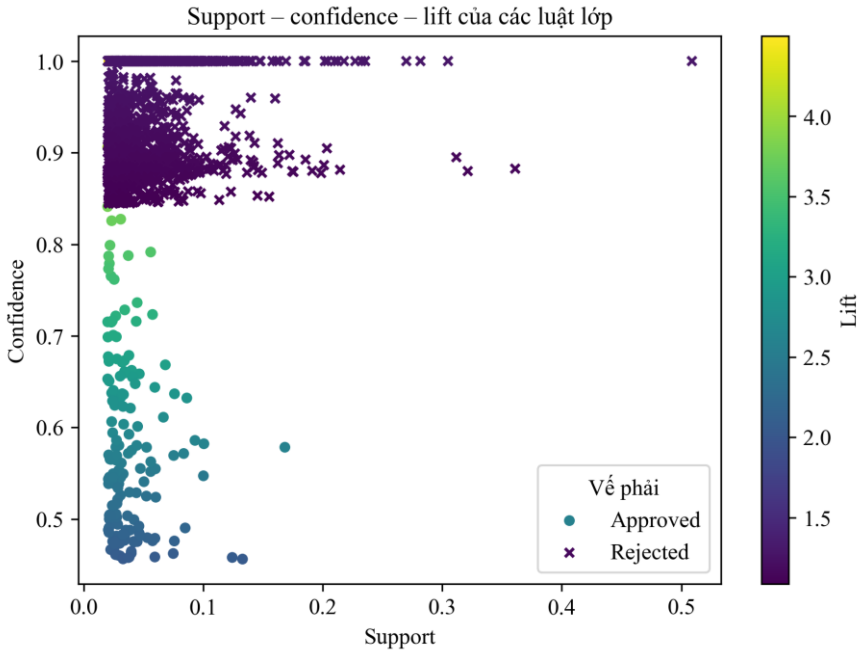
Bảng 4.19. Ví dụ minh họa – năm luật có lift cao nhất ở mỗi lớp

Luật	Support	Confidence	Lift	Hệ số chắc chắn

loan_percent_income_band=>=30% AND person_home_ownership=RENT → Approved	0.04	1.00	4.50	1.00
credit_score_band=Fair AND loan_percent_income_band=>=30% AND person_home_ownership=RENT → Approved	0.02	1.00	4.50	1.00
loan_percent_income_band=>=30% AND person_home_ownership=RENT AND person_income_band=30-60k → Approved	0.02	1.00	4.50	1.00
loan_amnt_band=10-20k AND loan_percent_income_band=>=30% AND person_home_ownership=RENT → Approved	0.02	1.00	4.50	1.00
loan_percent_income_band=>=30% AND person_gender=male AND person_home_ownership=RENT → Approved	0.02	1.00	4.50	1.00
previous_loan_defaults_on_file=Yes → Rejected	0.51	1.00	1.29	1.00
credit_score_band=Fair AND previous_loan_defaults_on_file=Yes → Rejected	0.30	1.00	1.29	1.00
credit_score_band=Good AND previous_loan_defaults_on_file=Yes → Rejected	0.10	1.00	1.29	1.00

credit_score_band=Poor AND previous_loan_defaults_on_file=Yes → Rejected	0.10	1.00	1.29	1.00
person_income_band=30-60k AND previous_loan_defaults_on_file=Yes → Rejected	0.16	1.00	1.29	1.00

Hình 4.16 biểu diễn đồng thời support, confidence và lift của các luật. Các luật Rejected tập trung ở vùng confidence cao (từ khoảng 0.85) với lift thấp và support trải đến 0.51; các luật Approved nằm ở vùng confidence thấp hơn (từ khoảng 0.46), support chủ yếu dưới 0.1 và lift cao hơn. Điều này cho thấy support và confidence cao của luật Rejected chủ yếu phản ánh xác suất nền của lớp đa số, nên lift và hệ số chắc chắn là các tiêu chí phù hợp hơn để đánh giá luật.



Hình 4.16. Phân bố support, confidence và lift của các luật lớp

4.5. Kết quả phân loại dựa trên luật kết hợp (Associative Classification)

Đề án chuyển 1,530 luật thành bộ phân loại bằng ba thuật toán phân loại dựa trên luật kết hợp: CBA (Classification Based on Associations), CMAR (Classification based on Multiple Association Rules) và CPAR (Classification based on Predictive Association Rules). Cả ba làm việc trên cùng một không gian luật từ Apriori (mục 4.5.4) và được so sánh trên tập kiểm định (8,998 hồ sơ, trong đó 2,000 hồ sơ Approved), để

tập kiểm tra được dành cho đánh giá cuối cùng ở mục 4.7. CBA xếp luật theo confidence, rồi support, rồi số điều kiện ít hơn; chọn luật nào phân loại đúng ít nhất một hồ sơ còn lại, cắt danh sách tại điểm có tổng số lỗi nhỏ nhất và dự đoán theo luật khớp đầu tiên. CMAR bỏ luật cụ thể khi đã có luật tổng quát hơn xếp hạng cao hơn, giữ luật tương quan dương có ý nghĩa (χ^2 lớn hơn 3.841 và lift lớn hơn 1), áp dụng database coverage với δ bằng 4, rồi dự đoán bằng cách cộng weighted χ^2 của các luật khớp theo từng lớp. CPAR xây từng luật bằng cách thêm điều kiện có FOIL gain lớn nhất, giảm trọng số các hồ sơ dương đã được phủ xuống còn 2/3, xếp hạng luật bằng độ chính xác Laplace và dự đoán bằng trung bình độ chính xác Laplace của tối đa 5 luật tốt nhất mỗi lớp mà hồ sơ khớp. Trong đề án, CPAR được cài đặt ở dạng đơn giản hóa (mỗi bước chỉ chọn một điều kiện tốt nhất, không tách nhánh như bản gốc) và CMAR không được cài đặt cây lưu trữ luật phân loại (CR-tree); vì vậy, các kết luận về hai thuật toán này gắn với cấu hình cài đặt đã dùng và không mặc nhiên áp dụng cho các phiên bản đầy đủ.

4.5.1. Tiêu chí điểm F0.5 và quy trình chọn hai bước

Tiêu chí chọn là điểm F0.5 của lớp Approved. Điểm F0.5 là trường hợp $\beta = 0.5$ của thước đo F-beta, $F_\beta = (1 + \beta^2) \times \text{Precision} \times \text{Recall} / (\beta^2 \times \text{Precision} + \text{Recall})$, trong đó precision có trọng số lớn hơn recall. Lựa chọn này xuất phát từ bối cảnh tín dụng: duyệt nhầm một hồ sơ rủi ro (dương tính giả) gây tổn thất trực tiếp và thường lớn hơn chi phí bỏ sót một hồ sơ tốt (âm tính giả). Độ chính xác tổng thể không được dùng vì lớp Approved chỉ chiếm 22.23%; điểm F1 không được dùng vì coi precision và recall có trọng số bằng nhau.

Quy trình chọn gồm hai bước (Bảng 4.20). Bước 1 so sánh CBA và CMAR: CBA đạt điểm F0.5 bằng 74.29, CMAR đạt 70.00, nên CBA được chọn. Bước 2 so sánh CBA với CPAR: CPAR đạt điểm F0.5 bằng 75.74, cao hơn CBA, nên CPAR được chọn. Lưu ý CMAR có recall cao nhất (85.85%) và điểm F1 cao nhất (75.21) nhưng precision thấp nhất (66.91%); nếu chọn theo điểm F1 thì CMAR sẽ được chọn. Kết quả chọn vì vậy phụ thuộc vào giả định về chi phí sai số, không chỉ phụ thuộc vào thuật toán.

Bảng 4.20. So sánh CBA, CMAR và CPAR trên tập kiểm định

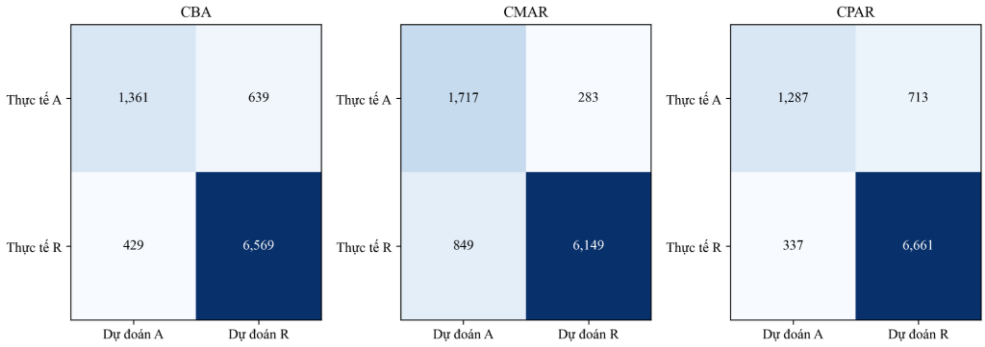
Thuật toán	Số luật cuối	Điểm F0.5	Precision	Recall	Điểm F1	Accuracy	Dương tính thật	Âm tính giả	Dương tính giả	Âm tính thật
CBA	156	74.29	76.03	68.05	71.82	88.13	1,361	639	429	6,569
CMAR	504	70.00	66.91	85.85	75.21	87.42	1,717	283	849	6,149
CPAR	108	75.74	79.25	64.35	71.03	88.33	1,287	713	337	6,661

Ghi chú: bước 1: CBA thắng CMAR; bước 2: CBA so với CPAR, chọn theo điểm F0.5.

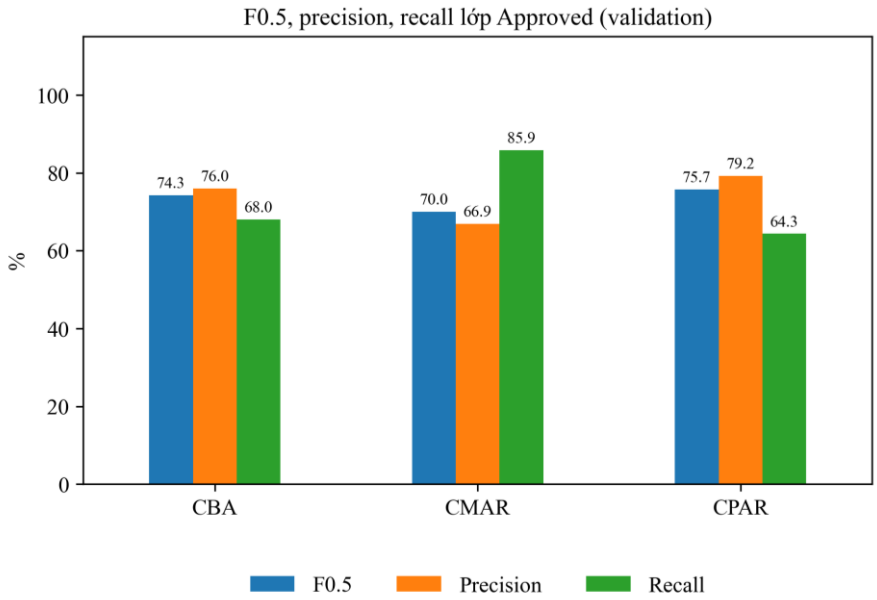
So với baseline luôn dự đoán Rejected (độ chính xác tổng thể 77.77%), cả ba thuật toán đều đạt độ chính xác tổng thể trên 87%, nghĩa là chúng nhận diện được một phần đáng kể của lớp Approved.

4.5.2. Xu hướng dự đoán của từng thuật toán qua ma trận nhầm lẫn

Ma trận nhầm lẫn (Hình 4.17) cho thấy ba thuật toán có xu hướng dự đoán khác nhau. Số hồ sơ được dự đoán là Approved (tổng số dương tính thật và dương tính giả ở Bảng 4.20) là 1,790 với CBA, 2,566 với CMAR và 1,624 với CPAR, so với 2,000 hồ sơ Approved thực tế. CMAR có xu hướng dự đoán lớp Approved rộng: dự đoán Approved nhiều hơn thực tế, nhận diện đúng 1,717 hồ sơ Approved (recall 85.85%) nhưng duyệt nhầm 849 hồ sơ Rejected. CPAR có xu hướng thận trọng nhất: dự đoán Approved ít hơn thực tế, chỉ duyệt nhầm 337 hồ sơ nhưng bỏ sót 713 hồ sơ Approved (recall 64.35%). CBA nằm giữa hai thái cực này. Hình 4.18so sánh điểm F0.5, precision và recall của ba thuật toán, minh họa sự đánh đổi giữa precision và recall.



Hình 4.17. Ma trận nhầm lẫn của CBA, CMAR và CPAR trên tập kiểm định (A: Approved, R: Rejected)



Hình 4.18. So sánh điểm F0.5, precision và recall của CBA, CMAR, CPAR

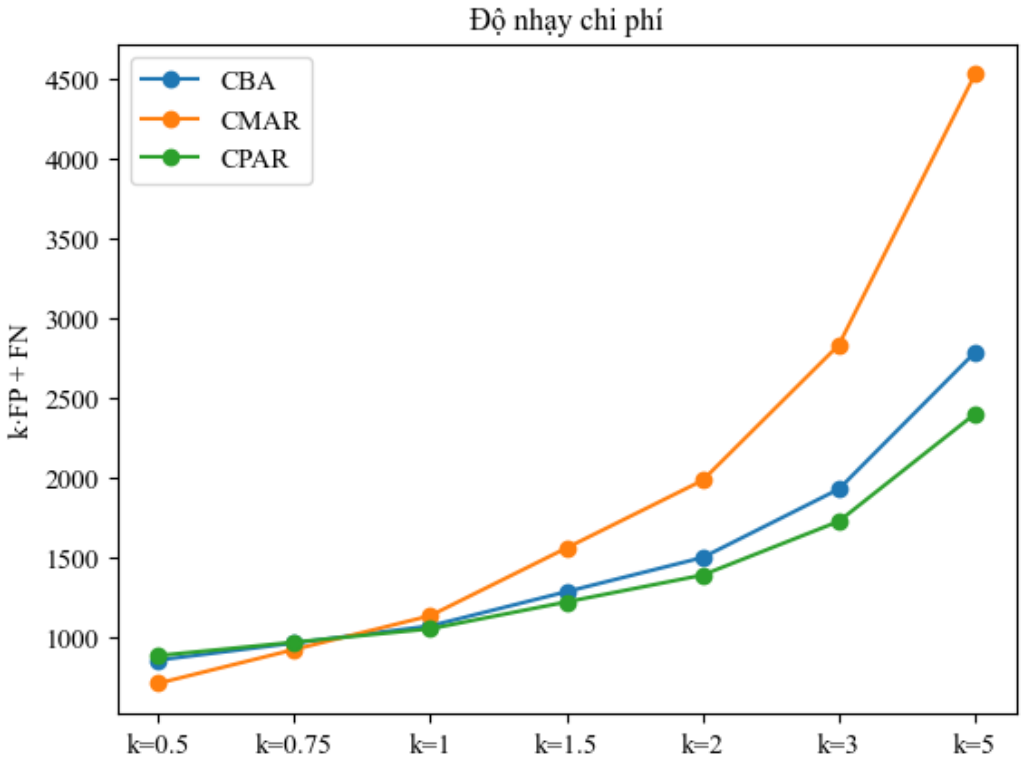
4.5.3. Phân tích độ nhạy chi phí

Để kiểm tra kết quả chọn có bền vững khi chi phí sai số thay đổi, đề án áp dụng mô hình chi phí bằng k nhân số dương tính giả cộng số âm tính giả, với k lần lượt bằng 0.5; 0.75; 1; 1.5; 2; 3 và 5, trong đó k là tỉ lệ chi phí duyệt nhầm so với bỏ sót (Bảng 4.21, Hình 4.19). CPAR có chi phí thấp nhất ở mọi giá trị k từ 1 trở lên; khi k bằng 0.5 và 0.75, tức duyệt nhầm rẻ hơn bỏ sót, CMAR có chi phí thấp nhất. Chênh lệch giữa CPAR và CBA tăng theo k, từ 18 đơn vị ở k = 1 (1,050 so với 1,068) lên 386 đơn vị ở k = 5 (2,398 so với 2,784). CMAR có chi phí cao nhất ở mọi giá trị k từ 1 trở lên do số hồ sơ duyệt nhầm lớn. Từ số dương tính giả và âm tính giả ở Bảng 4.20, CPAR chỉ kém CMAR khi k nhỏ hơn 0.84 và kém CBA khi k nhỏ hơn 0.80 (nghiệm của phương trình chi phí bằng nhau), phù hợp với kết quả ở k bằng 0.5 và 0.75. Giả định duyệt nhầm rẻ

hơn bỏ sót không phù hợp với bối cảnh tín dụng và với khẩu vị thận trọng của đề án, nên kết quả chọn CPAR không phụ thuộc vào một giá trị k cụ thể trong miền hợp lý.

Bảng 4.21. Phân tích độ nhạy chi phí (chi phí = k × số dương tính giả + số âm tính giả, tập kiểm định)

Tỉ lệ k	CBA	CMAR	CPAR	Thắng
k = 0.5	853.5	707.5	881.5	CMAR
k = 0.75	960.75	919.75	965.75	CMAR
k = 1	1,068.0	1,132.0	1,050.0	CPAR
k = 1.5	1,282.5	1,556.5	1,218.5	CPAR
k = 2	1,497.0	1,981.0	1,387.0	CPAR
k = 3	1,926.0	2,830.0	1,724.0	CPAR
k = 5	2,784.0	4,528.0	2,398.0	CPAR



Hình 4.19. Độ nhạy chi phí của CBA, CMAR và CPAR theo tỉ lệ k

4.5.4. So sánh công bằng: cùng không gian luật

Để bảo đảm khác biệt giữa ba thuật toán đến từ cơ chế chọn và áp dụng luật chứ không đến từ nguồn luật, đề án kiểm chứng rằng 100% luật cuối của mỗi thuật toán thuộc tập 1,530 luật Apriori: 156/156 của CBA, 504/504 của CMAR và 108/108 của

CPAR (Bảng 4.22). Như vậy so sánh ở Bảng 4.20 là so sánh trên cùng một không gian luật.

Bảng 4.22. Kiểm chứng ba thuật toán dùng chung không gian luật Apriori

Thuật toán	Số luật cuối	Thuộc tập luật Apriori	Tổng số luật Apriori
CBA	156	156	1,530
CMAR	504	504	1,530
CPAR	108	108	1,530

4.6. Tích hợp tri thức ngành vào lựa chọn luật

4.6.1. Vấn đề: luật đúng về thống kê chưa chắc đúng về nghiệp vụ

Các luật Approved mạnh nhất ở mục 4.4.3 mô tả những hồ sơ có khoản vay vượt 30% thu nhập, và Truy vấn 4 (mục 4.3.5) cho thấy hồ sơ vi phạm năng lực trả nợ được duyệt với tỉ lệ 85.5–100%. Điều này chỉ ra rằng các tiêu chí thống kê (support, confidence, lift, hệ số chắc chắn) chỉ phản ánh những gì xảy ra trong dữ liệu lịch sử, kể cả khi quyết định lịch sử trái với nguyên tắc cho vay. Một luật có thể mạnh về mặt thống kê nhưng không nên đưa vào hệ thống hỗ trợ quyết định vì nó mã hóa một quyết định không phù hợp.

4.6.2. Tri thức ngành và khung nhìn chính sách v_policy

Đề án mã hóa hai nguyên tắc cho vay thận trọng thành tiêu chí vi phạm chính sách: thu nhập tối thiểu (thu nhập dưới 25,000) và gánh nặng nợ tối đa (khoản vay vượt 40% thu nhập). Hai ngưỡng này là giả định nghiệp vụ do nhóm đặt chứ không học từ dữ liệu: mức 25,000 xấp xỉ chuẩn nghèo của Mỹ cho hộ ba người, còn mức 40% thu nhập năm được coi là khoản vay quá sức. Hai điều kiện được cài đặt trong khung nhìn chính sách v_policy của kho dữ liệu (Bảng 4.9), nơi mỗi hồ sơ có một cột đánh dấu vi phạm hoặc không vi phạm.

4.6.3. Cơ chế lọc luật

Với mỗi luật ứng viên, đề án dịch vế trái thành một mệnh đề điều kiện trong ngôn ngữ truy vấn có cấu trúc, chạy trên khung nhìn v_policy để xác định tập hồ sơ mà luật phủ và tỉ lệ hồ sơ vi phạm chính sách trong tập đó. Luật bị loại nếu có hơn 10% hồ sơ

được phủ là vi phạm; ngưỡng 10% do đề án chọn xấp xỉ gấp đôi tỉ lệ vi phạm chung của toàn bộ dữ liệu (4.32%), tức luật bị loại khi tập trung vào hồ sơ vi phạm nhiều hơn mặt bằng chung . Ngoài bộ lọc chính sách, mỗi phương pháp chọn ba luật theo bốn điều kiện: vế phải là Approved; vế trái có ít nhất hai điều kiện, vì luật một điều kiện chỉ lặp lại một cột gốc; tỉ lệ hồ sơ vi phạm không quá 10%; và ít chồng lấn với các luật đã chọn (hệ số Jaccard dưới 0.5). Thứ hạng dùng độ đo gốc của từng thuật toán (confidence với CBA, độ chính xác Laplace với CPAR); với CBA, nếu tập luật cuối không đủ luật hợp lệ thì lấy tiếp từ tập luật Apriori theo thứ hạng chung. Việc đặt cơ chế trong kho dữ liệu có ba lợi ích: định nghĩa chính sách nằm ở một nơi duy nhất nên mọi thuật toán dùng chung một tiêu chí; phép kiểm tra là truy vấn trên dữ liệu đầy đủ nên có thể kiểm toán và tái sử dụng khi chính sách thay đổi; và việc lọc tách khỏi thuật toán khai phá nên không làm thay đổi các độ đo thống kê của luật. Về thuật ngữ, đây là lọc luật dựa trên tri thức miền (domain-knowledge-based rule filtering) áp dụng sau khai phá, không phải ràng buộc được đưa vào trong quá trình khai phá.

4.6.4. Tác dụng của bộ lọc

Bộ lọc có tác động rõ rệt: CBA loại 20 trong 24 luật ứng viên vì vi phạm chính sách (và loại thêm 1 luật vì chồng lấn), còn CPAR loại 5 trong 8 luật ứng viên. Một số luật bị loại dù rất mạnh về mặt thống kê, chẳng hạn luật loan_percent_income_band=>=30% AND person_home_ownership=RENT → Approved, có confidence 1.00 nhưng 23.3% hồ sơ được phủ vi phạm chính sách. Kết quả minh họa vấn đề ở mục 4.6.1: nếu chỉ chọn theo confidence hoặc lift, các luật như vậy sẽ được chọn.

4.6.5. Ba luật được chọn và độ phủ

Mỗi phương pháp giữ ba luật đạt yêu cầu (Bảng 4.23): CBA xếp hạng theo confidence, CPAR theo độ chính xác Laplace. Tỉ lệ hồ sơ vi phạm của sáu luật được chọn từ 2.62% đến 9.10%, đều dưới ngưỡng 10%. Cả sáu luật đều có điều kiện

$$previous_loan_defaults_on_file = No$$

và luật rule_1 của hai phương pháp là cùng một luật (loan_int_rate_band=>=16% AND person_home_ownership=RENT AND previous_loan_defaults_on_file=No → Approved).

Bảng 4.23. Các luật được chọn làm thuộc tính mới

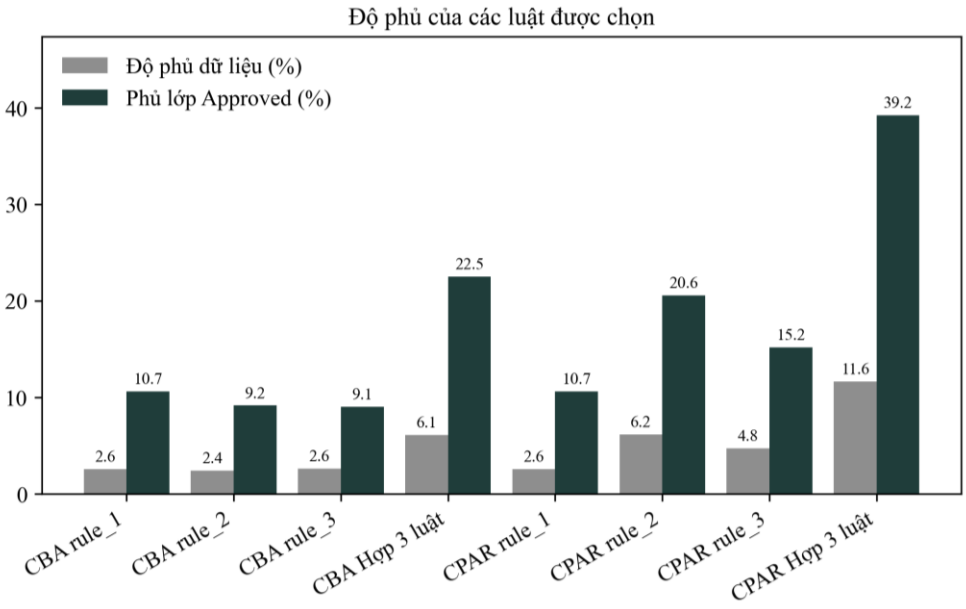
Phương pháp	Thuộc tính	Luật	Độ đo xếp hạng	% vi phạm chính sách
CBA	rule_1	loan_int_rate_band=>=16% AND person_home_ownership=RENT AND previous_loan_defaults_on_file=No → Approved	confidence	7.15
CBA	rule_2	credit_score_band=Fair AND loan_int_rate_band=>=16% AND previous_loan_defaults_on_file=No → Approved	confidence	5.68
CBA	rule_3	loan_int_rate_band=13-16% AND loan_percent_income_band=20-30% AND previous_loan_defaults_on_file=No → Approved	confidence	9.10
CPAR	rule_1	loan_int_rate_band=>=16% AND person_home_ownership=RENT AND previous_loan_defaults_on_file=No → Approved	laplace	7.15
CPAR	rule_2	loan_amnt_band=10-20k AND person_income_band=30-60k AND previous_loan_defaults_on_file=No → Approved	laplace	4.20
CPAR	rule_3	loan_int_rate_band=13-16% AND person_income_band=30-60k AND previous_loan_defaults_on_file=No → Approved	laplace	2.62

Ghi chú: luật bị loại nếu hơn 10% hồ sơ được phủ vi phạm.

Độ phủ của các luật trên toàn bộ dữ liệu được trình bày ở Bảng 4.24 và Hình 4.20. Ba luật của CBA có confidence cao hơn (0.92; 0.84; 0.76) nhưng độ phủ hẹp: hợp ba luật phủ 6.11% dữ liệu và 22.54% hồ sơ Approved. Ba luật của CPAR có confidence thấp hơn (0.92; 0.74; 0.71) nhưng độ phủ rộng hơn: hợp ba luật phủ 11.65% dữ liệu và 39.24% hồ sơ Approved. Như vậy CBA ưu tiên độ chính xác của từng luật, còn CPAR cân bằng hơn giữa độ chính xác và độ phủ, phù hợp với kết quả CPAR được chọn ở mục 4.5. Tuy nhiên, ngay cả hợp ba luật tốt nhất cũng chỉ phủ chưa đến 40% hồ sơ Approved, nên bộ ba luật không thay thế được một mô hình phân loại đầy đủ.

Bảng 4.24. Độ phủ của ba luật mỗi phương pháp trên toàn bộ dữ liệu

Phương pháp	Luật	Độ phủ (%)	Support (%)	Confidence	Phủ lớp Approved (%)
CBA	rule_1	2.58	2.37	0.92	10.65
CBA	rule_2	2.43	2.04	0.84	9.18
CBA	rule_3	2.64	2.01	0.76	9.06
CBA	Hợp ba luật	6.11	5.01	0.82	22.54
CPAR	rule_1	2.58	2.37	0.92	10.65
CPAR	rule_2	6.20	4.57	0.74	20.58
CPAR	rule_3	4.76	3.38	0.71	15.20
CPAR	Hợp ba luật	11.65	8.72	0.75	39.24



Hình 4.20. Độ phủ dữ liệu và độ phủ lớp Approved của các luật được chọn

4.7. Kết quả phân loại với thuộc tính sinh từ luật

4.7.1. Thiết kế thực nghiệm

Để kiểm tra việc đưa thông tin từ luật vào mô hình có cải thiện dự đoán hay không, đề án so sánh ba bộ dữ liệu: Bộ dữ liệu 1 (bộ dữ liệu gốc); Bộ dữ liệu 2 (bộ dữ liệu gốc cộng ba thuộc tính nhị phân sinh từ ba luật CBA đã chọn); Bộ dữ liệu 3 (bộ dữ liệu gốc cộng ba thuộc tính nhị phân sinh từ ba luật CPAR đã chọn). Mỗi thuộc tính mới nhận giá trị 1 nếu hồ sơ thỏa vế trái của luật và 0 trong trường hợp ngược lại. Trên mỗi bộ dữ liệu, đề án huấn luyện ba mô hình là Logistic Regression, Random Forest và Gradient Boosting, rồi đánh giá một lần trên tập kiểm tra với Approved là lớp dương. Cả ba mô hình dùng cùng siêu tham số cho mọi bộ dữ liệu (Logistic Regression với tối đa 2,000 vòng lặp; Random Forest với 300 cây và số mẫu tối thiểu mỗi lá bằng 5; Gradient Boosting với tham số mặc định; hạt giống ngẫu nhiên bằng 42). Đề án không dùng trọng số lớp cân bằng vì cách này đẩy mô hình duyệt nhiều hơn (recall cao, precision thấp), ngược với khẩu vị thận trọng. Tập kiểm tra có baseline luôn dự đoán Rejected đạt độ chính xác tổng thể 77.77% (6,998 chia 8,998).

4.7.2. Kết quả trên tập kiểm tra

Mọi tổ hợp đạt độ chính xác tổng thể từ 89.41% đến 90.73%, vượt xa baseline 77.77% (Bảng 4.25). Kết quả tốt nhất là Random Forest trên Bộ dữ liệu 1 với điểm F0.5 bằng 80.08, precision 81.21%, recall 75.85%, điểm F1 bằng 78.44 và độ chính xác tổng thể 90.73%. Precision 81.21% nghĩa là khoảng 18.8% hồ sơ được dự đoán Approved là hồ sơ bị duyệt nhầm. Trong mỗi bộ dữ liệu, thứ tự giữa các mô hình nhất quán: Random Forest và Gradient Boosting có điểm F0.5 cao hơn Logistic Regression khoảng 3 điểm phần trăm (Random Forest 79.87–80.08; Gradient Boosting 79.47–79.87; Logistic Regression 76.88–77.09). Ma trận nhầm lẫn tương ứng ở Bảng 4.26 và Hình 4.23; Hình 4.21 và Hình 4.22so sánh điểm F0.5 và precision giữa chín tổ hợp.

Bảng 4.25. Kết quả phân loại trên tập kiểm tra (lớp Approved)

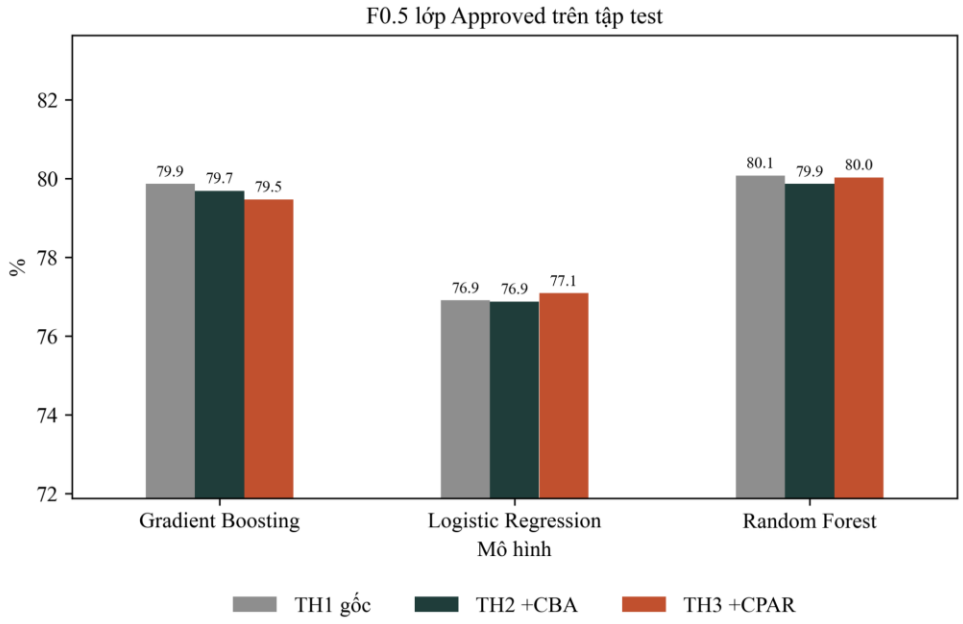
Bộ dữ liệu	Mô hình	Điểm F0.5	Precision	Recall	Điểm F1	Accuracy
Bộ dữ liệu 1 (gốc)	Logistic Regression	76.91	77.95	73.00	75.39	89.41

Bộ dữ liệu 1 (gốc)	Random Forest	80.08	81.21	75.85	78.44	90.73
Bộ dữ liệu 1 (gốc)	Gradient Boosting	79.87	81.23	74.85	77.91	90.56
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Logistic Regression	76.88	77.68	73.80	75.69	89.46
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Random Forest	79.87	81.00	75.65	78.23	90.64
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Gradient Boosting	79.69	81.13	74.40	77.62	90.46
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Logistic Regression	77.09	78.29	72.65	75.36	89.44
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Random Forest	80.03	81.26	75.45	78.25	90.68
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Gradient Boosting	79.47	80.94	74.10	77.37	90.36

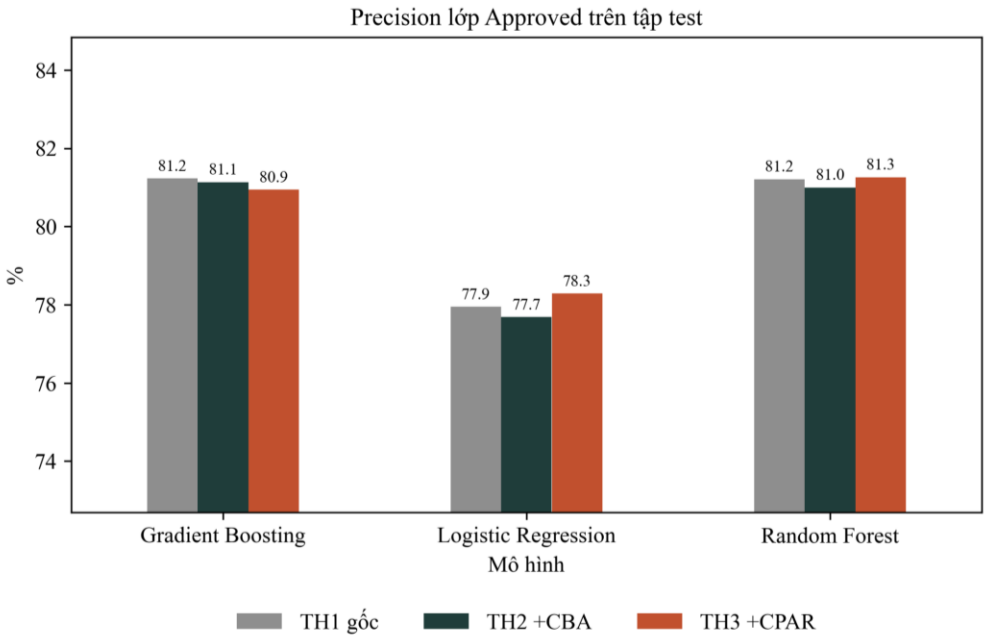
Bảng 4.26. Ma trận nhầm lẫn trên tập kiểm tra

Bộ dữ liệu	**Mô hình**	**Dương tính thật**	**Âm tính giả**	**Dương tính giả**	**Âm tính thật**
Bộ dữ liệu 1 (gốc)	Logistic Regression	1,460	540	413	6,585
Bộ dữ liệu 1 (gốc)	Random Forest	1,517	483	351	6,647
Bộ dữ liệu 1 (gốc)	Gradient Boosting	1,497	503	346	6,652

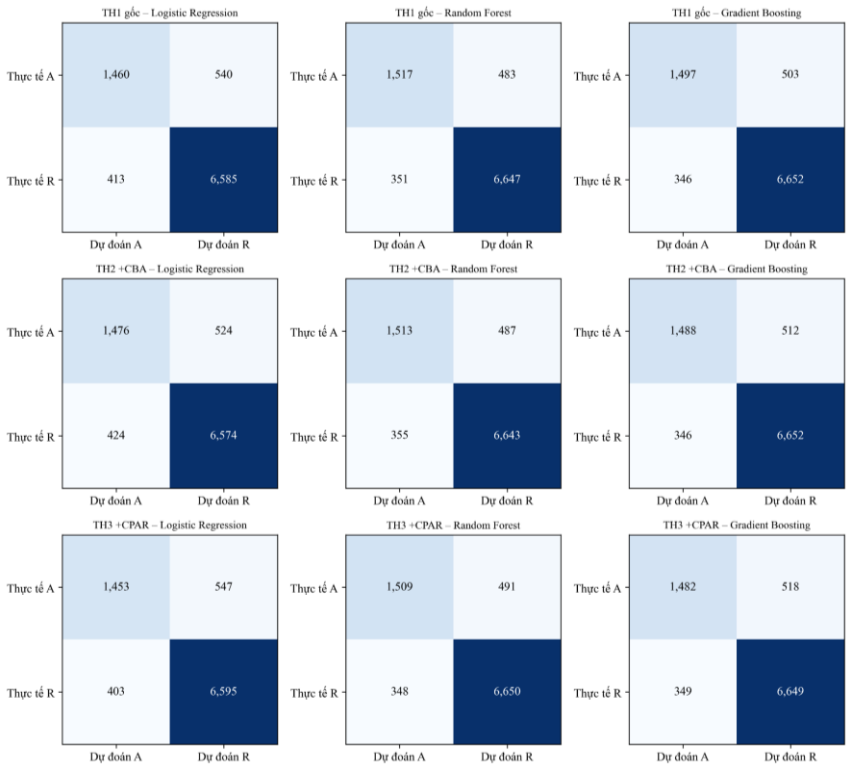
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Logistic Regression	1,476	524	424	6,574
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Random Forest	1,513	487	355	6,643
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Gradient Boosting	1,488	512	346	6,652
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Logistic Regression	1,453	547	403	6,595
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Random Forest	1,509	491	348	6,650
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Gradient Boosting	1,482	518	349	6,649



Hình 4.21. Điểm F0.5 lớp Approved trên tập kiểm tra theo bộ dữ liệu và mô hình



Hình 4.22. Precision lớp Approved trên tập kiểm tra theo bộ dữ liệu và mô hình



Hình 4.23. Ma trận nhầm lẫn của chín tổ hợp bộ dữ liệu và mô hình trên tập kiểm tra (A: Approved, R: Rejected)

4.7.3. Ảnh hưởng của thuộc tính sinh từ luật

Thuộc tính sinh từ luật gần như không làm thay đổi kết quả. So với Bộ dữ liệu 1, chênh lệch điểm F0.5 chỉ nằm trong khoảng −0.39 đến +0.18 điểm phần trăm (Bảng 4.27): mức cải thiện lớn nhất là ở Logistic Regression với Bộ dữ liệu 3 (+0.18 điểm; số

dương tính giả giảm 10 hồ sơ) và mức suy giảm lớn nhất là ở Gradient Boosting với Bộ dữ liệu 3 (−0.39 điểm). Với mô hình tốt nhất (Random Forest), chênh lệch điểm F0.5 là −0.21 ở Bộ dữ liệu 2 và −0.05 ở Bộ dữ liệu 3. Các chênh lệch này nhỏ hơn nhiều so với khác biệt giữa các mô hình (khoảng 3 điểm giữa Logistic Regression với hai mô hình còn lại); hơn nữa, vì kết quả đến từ một lần chia tập duy nhất, không có cơ sở thống kê để coi chênh lệch dưới 0.5 điểm là có ý nghĩa. Do đó có thể kết luận thuộc tính từ ba luật không cải thiện hiệu năng dự đoán trong thực nghiệm này.

Bảng 4.27. Chênh lệch so với Bộ dữ liệu 1 (điểm phần trăm; dương tính giả tính theo số hồ sơ)

Bộ dữ liệu	Mô hình	Chênh lệch điểm F0.5	Chênh lệch precision	Chênh lệch recall	Chênh lệch dương tính giả
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Logistic Regression	−0.03	−0.27	0.80	11
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Random Forest	−0.21	−0.21	−0.20	4
Bộ dữ liệu 2 (gốc cộng ba luật CBA)	Gradient Boosting	−0.17	−0.09	−0.45	0
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Logistic Regression	0.18	0.34	−0.35	−10
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Random Forest	−0.05	0.05	−0.40	−3
Bộ dữ liệu 3 (gốc cộng ba luật CPAR)	Gradient Boosting	−0.39	−0.29	−0.75	3

4.7.4. Ba nguyên nhân

Có ba nguyên nhân hợp lý cho kết quả trên. Thứ nhất, thông tin trong ba thuộc tính mới đã có sẵn trong các cột gốc, vì mỗi luật chỉ là một tổ hợp điều kiện trên các cột đó, nên mô hình không nhận thêm thông tin. Thứ hai, Random Forest và Gradient Boosting tự học các tổ hợp điều kiện qua các phép chia của cây, nên đã nắm bắt các tương tác mà luật biểu diễn tường minh; ngay cả Logistic Regression, mô hình tuyến tính có thể hưởng lợi nhiều nhất từ các thuộc tính tương tác, cũng chỉ cải thiện tối đa 0.18 điểm. Thứ ba, các luật mạnh nhất đã bị loại ở mục 4.6 do vi phạm chính sách, nên các luật còn lại có confidence thấp hơn (0.71–0.92) và độ phủ hẹp (tối đa 39.24% hồ sơ Approved), kém khả năng bổ sung thông tin. Ba nguyên nhân này chưa được kiểm chứng bằng thực nghiệm đối chứng, chẳng hạn, chạy lại với các luật chưa lọc chính sách.

Ngoài ra, điểm F0.5 của Random Forest trên tập kiểm tra (80.08) cao hơn điểm F0.5 của CPAR trên tập kiểm định (75.74), nhưng hai giá trị được tính trên hai tập khác nhau và CPAR chưa được đánh giá trên tập kiểm tra, nên chưa thể kết luận trực tiếp về chênh lệch giữa mô hình hộp đen và bộ phân loại dựa trên luật.

4.8. Tổng hợp kết quả thực nghiệm

Bảng 4.28. Tổng hợp theo từng phần: làm gì, chọn gì, vì sao, kết quả chính

Phần	Làm gì	Chọn gì	Vì sao	Kết quả chính
4.1 Phân tích thăm dò dữ liệu	Phân tích phân phối và khả năng phân biệt hai lớp	Không dùng độ chính xác tổng thể; khai phá tổ hợp thuộc tính	Lớp mất cân bằng 77.77%/22.23%; nhiều biến cho kết quả ngược kỳ vọng	Từng vỡ nợ thì 100% bị từ chối
4.2 Tiền xử lý	Làm sạch, xử lý đa cộng tuyến, rời rạc hóa, chia tập	Chỉ loại giá trị phi lý; giữ tuổi; ngưỡng nghiệp vụ; chia 60/20/20	Quy tắc khoảng tứ phân vị loại nhầm hồ sơ hợp lệ; hệ số tương quan từ 0.8 trở lên; luật dễ diễn giải; cần tập kiểm định	44,990 hồ sơ; Cramér's V lớn nhất 0.36

4.3 Kho dữ liệu	Mô hình hình sao, truy vấn đa chiều, bốn truy vấn nghiệp vụ	Một bảng sự kiện, sáu bảng chiều, hai khung nhìn	Phục vụ truy vấn đa chiều và kiểm tra chính sách	Hồ sơ vi phạm vẫn được duyệt 85.5–100%
4.4 Luật kết hợp	So sánh Apriori và FP-Growth; đặt ràng buộc	Apriori; support từ 2%, hệ số chắc chắn từ 0.30, tối đa 3 điều kiện	Cùng 10,478 tập mục thường xuyên, Apriori nhanh hơn; hệ số chắc chắn chuẩn hóa theo lớp	1,530 luật (169 Approved, 1,361 Rejected)
4.5 Phân loại dựa trên luật kết hợp	So sánh CBA, CMAR, CPAR trên tập kiểm định	CPAR	Điểm F0.5 ưu tiên precision; CPAR có chi phí thấp nhất khi k từ 1 trở lên	Điểm F0.5: CPAR 75.74; CBA 74.29; CMAR 70.00
4.6 Lọc luật theo tri thức ngành	Lọc luật qua khung nhìn chính sách	Loại luật có hơn 10% hồ sơ được phủ vi phạm	Luật đúng về thống kê chưa chắc đúng về nghiệp vụ	CBA loại 20/24, CPAR loại 5/8 luật ứng viên
4.7 Phân loại với thuộc tính sinh từ luật	Ba bộ dữ liệu, ba mô hình, đánh giá trên tập kiểm tra	Random Forest trên Bộ dữ liệu 1	Điểm F0.5 cao nhất	Điểm F0.5 = 80.08; thuộc tính mới làm điểm F0.5 thay đổi từ −0.39 đến +0.18
4.9 Minh họa ứng dụng	Xây dựng ứng dụng xét duyệt trực tuyến	Hai lớp: luật chuyên gia, rồi mô hình CPAR	Quy tắc tuyệt đối nên nằm ngoài mô hình học; người thẩm định cần thấy luật khớp	Nhập một hồ sơ, nhận kết quả và tối đa 10 luật khớp

Bảng 4.29. Các điểm đưa tri thức ngành vào đề án

Điểm	Vị trí	Tác dụng

Rời rạc hóa bằng ngưỡng nghiệp vụ	4.2.3	Luật diễn giải được và không phụ thuộc phân phối của tập kiểm tra
Truy vấn xử lý phân tích trực tuyến gắn với bộ phận nghiệp vụ	4.3.5	Phát hiện hồ sơ vi phạm năng lực trả nợ vẫn được duyệt
Chọn mô hình bằng điểm F0.5 và phân tích độ nhạy chi phí	4.5	Ưu tiên precision vì duyệt nhầm gây tổn thất lớn hơn bỏ sót
Lọc luật theo chính sách	4.6	Loại các luật đúng về thống kê nhưng trái nguyên tắc cho vay
Luật chuyên gia ở lớp đầu của ứng dụng	4.9	Từ chối ngay hồ sơ từng vỡ nợ hoặc vi phạm năng lực trả nợ; duyệt hồ sơ an toàn

Tổng hợp lại, quy trình đã phát hiện các quan hệ mà phân tích đơn biến khó nhận diện: lịch sử vỡ nợ gần như quyết định kết quả Rejected, trong khi các biến theo kỳ vọng nghiệp vụ như điểm tín dụng, tỉ lệ vay trên thu nhập và thu nhập không phân biệt theo chiều hướng kỳ vọng. Trong ba thuật toán phân loại dựa trên luật kết hợp, CPAR được chọn theo điểm F0.5 và bền vững theo phân tích độ nhạy chi phí khi duyệt nhầm tốn kém hơn hoặc bằng bỏ sót (k từ 1 trở lên). Tuy nhiên, việc đưa thuộc tính sinh từ luật vào các mô hình phân loại truyền thống chưa làm tăng hiệu năng: điểm F0.5 tốt nhất vẫn thuộc về Random Forest trên bộ dữ liệu gốc. Vì vậy, đóng góp của khai phá luật kết hợp trong đề án không nằm ở việc nâng độ chính xác dự đoán mà ở hai điểm: khả năng diễn giải (luật cho biết tổ hợp điều kiện nào đi cùng kết quả duyệt) và khả năng kiểm soát chính sách (khung nhìn chính sách phát hiện và loại các luật học từ quyết định lịch sử không phù hợp). Hai điểm này là cơ sở cho các kết luận, hạn chế và khuyến nghị ở Chương 5.

4.9. Minh họa ứng dụng: hệ thống xét duyệt hai lớp

Để minh họa cách dùng các kết quả trên, đề án xây dựng một ứng dụng web minh họa cho phép nhập một hồ sơ vay và xem kết quả xét duyệt. Ứng dụng quyết định theo hai lớp. Lớp thứ nhất là luật chuyên gia, áp dụng theo thứ tự: hồ sơ từng vỡ nợ bị từ chối; hồ sơ vi phạm năng lực trả nợ (thu nhập dưới 25,000 hoặc khoản vay vượt 40% thu nhập) bị từ chối; hồ sơ an toàn (thu nhập từ 100,000, khoản vay không quá 10% thu

nhập và điểm tín dụng từ 580) được duyệt (U.S. Bank, 2025) ; hồ sơ chưa từng vỡ nợ, trong hạn mức vay, có kinh nghiệm làm việc từ 2 năm và lịch sử tín dụng không quá 4 năm được duyệt. Lớp thứ hai là mô hình học từ dữ liệu: các hồ sơ còn lại được thuật toán thắng ở mục 4.5, tức CPAR, dự đoán. Ứng dụng đồng thời hiển thị tối đa 10 luật khớp với hồ sơ, kèm confidence, lift và thứ hạng của luật, nên người thẩm định có thể kiểm tra căn cứ của dự đoán.

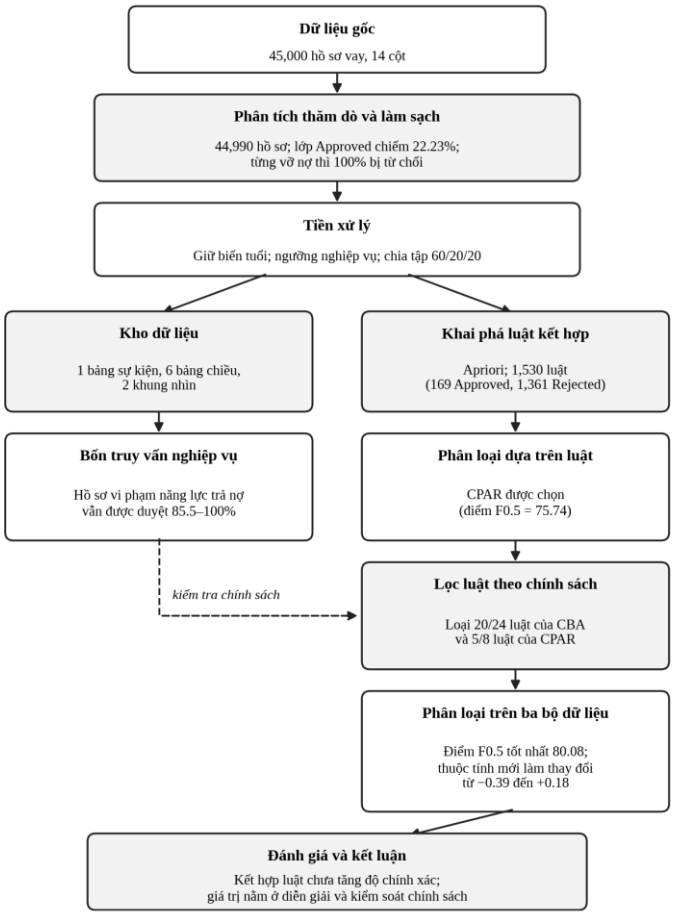
Thiết kế hai lớp này hiện thực hóa các khuyến nghị ở Chương 5: các quy tắc tuyệt đối (từng vỡ nợ, vi phạm chính sách) nằm ở lớp luật chuyên gia, còn mô hình chỉ xử lý vùng chưa rõ ràng. Các ngưỡng của hồ sơ an toàn là giả định của nhóm, chưa được hiệu chỉnh bằng dữ liệu thực.

CHƯƠNG 5. CHƯƠNG 5. KẾT LUẬN VÀ KHUYẾN NGHỊ

Chương này khép lại câu hỏi nghiên cứu xuyên suốt đề án: việc kết hợp luật vào bài toán phân loại duyệt vay có làm tăng độ chính xác dự đoán hay không. Kết quả cho thấy việc kết hợp luật chưa làm tăng độ chính xác; giá trị của khai phá luật kết hợp nằm ở khả năng diễn giải và khả năng kiểm soát chính sách nhờ tri thức ngành. Chương gồm bốn phần: kết quả đạt được (mục 5.1), hàm ý quản trị và khuyến nghị nghiệp vụ (mục 5.2), hạn chế (mục 5.3) và hướng phát triển (mục 5.4).

5.1. Kết quả đạt được

Đề án đã xây dựng một quy trình khép kín từ dữ liệu thô đến mô hình phân loại trên bộ dữ liệu 45,000 hồ sơ vay Hình 5.1). Sau khi được làm sạch và tiền xử lý, dữ liệu đi theo hai nhánh: nhánh kho dữ liệu phục vụ truy vấn đa chiều và kiểm tra chính sách; nhánh khai phá luật kết hợp, phân loại dựa trên luật, chọn ba luật làm thuộc tính mới và phân loại trên ba bộ dữ liệu. Hai nhánh gặp nhau ở bước lọc luật theo chính sách, nơi kho dữ liệu kiểm soát các luật do thuật toán khai phá sinh ra. Đề án cũng xây dựng một ứng dụng xét duyệt minh hoạ hai lớp (luật chuyên gia, rồi mô hình CPAR) để minh họa cách dùng các kết quả này (mục 4.9).



Hình 5.1. Tóm tắt quy trình nghiên cứu và các kết quả chính

Bảng 5.1 đối chiếu từng mục tiêu với kết quả. Hệ mục tiêu gồm năm mục tiêu (a) đến (e) như ở mục 1.3, và mục tiêu (d) về phân loại bao gồm cả việc tích hợp tri thức ngành vào lựa chọn luật và kết hợp thuộc tính sinh từ luật vào phân loại.

Bảng 5.1. Đối chiếu kết quả với mục tiêu nghiên cứu

Mục tiêu	Kết quả đạt được	Mức độ
(a) Phân tích đặc điểm dữ liệu, làm sạch và tiền xử lý	Dữ liệu từ 45,000 còn 44,990 hồ sơ; lớp mất cân bằng (77.77% Rejected, 22.23% Approved); xử lý đa cộng tuyến bằng cách giữ biến tuổi; rời rạc hóa bằng ngưỡng nghiệp vụ; chia 60/20/20	Đạt
(b) Xây dựng kho dữ liệu theo mô hình hình sao	Một bảng sự kiện (44,990 dòng), sáu bảng chiều, hai khung nhìn; phép cắt lát, phép gộp cấp, phép khối và bốn truy vấn nghiệp vụ	Đạt, chưa có chiều thời gian
(c) Khai phá luật kết hợp	10,478 tập mục thường xuyên; 1,530 luật (169 Approved, 1,361 Rejected); ràng buộc theo hệ số chắc chắn	Đạt

(d) Xây dựng và đánh giá mô hình phân loại dựa trên luật kết hợp, gồm tích hợp tri thức ngành và thuộc tính sinh từ luật	So sánh CBA, CMAR và CPAR trên tập kiểm định, CPAR được chọn (điểm F0.5 bằng 75.74); lọc luật qua khung nhìn chính sách (loại 20/24 luật ứng viên của CBA và 5/8 của CPAR; ba luật còn lại phủ 22.54% và 39.24% hồ sơ Approved); thêm thuộc tính sinh từ luật vào ba mô hình: điểm F0.5 tốt nhất 80.08 (Random Forest, bộ dữ liệu gốc), thay đổi từ -0.39 đến +0.18	Đạt, nhưng thuộc tính từ luật không cải thiện độ chính xác
(e) Đề xuất nhận định và khuyến nghị nghiệp vụ	Sáu khuyến nghị ở mục 5.2; ứng dụng xét duyệt hai lớp minh họa ở mục 4.9	Đạt, mang tính tham khảo

Các phát hiện cốt lõi của đề tài như sau.

1. Lịch sử vỡ nợ là rào cản tuyệt đối, còn chưa từng vỡ nợ chỉ là điều kiện cần. Toàn bộ 22,855 hồ sơ từng vỡ nợ bị từ chối, trong khi nhóm chưa từng vỡ nợ vẫn có 54.8% hồ sơ bị từ chối.
2. Tổ hợp đa biến có sức dự báo mạnh, nhưng các tổ hợp mạnh nhất lại vi phạm chính sách. Các luật Approved có lift cao nhất (4.50) mô tả những hồ sơ thuộc nhóm tỉ lệ vay trên thu nhập từ 30% trở lên, trong đó 23.3% hồ sơ được phủ vượt ngưỡng 40% và đã bị loại ở bước lọc theo chính sách.
3. Mục đích vay và hình thức sở hữu nhà phân hóa rõ, còn giới tính và học vấn gần như không. Tỉ lệ duyệt theo mục đích vay dao động từ 14.4% đến 30.3%; nhóm sở hữu hoàn toàn và nhóm đang thế chấp có tỉ lệ duyệt thấp hơn nhiều so với nhóm thuê nhà; trong khi tỉ lệ duyệt của nữ và nam chỉ chênh nhau khoảng 0.1 điểm phần trăm (22.30% so với 22.20%) và khoản vay bình quân gần như không đổi theo học vấn (9,543–9,931).
4. Dữ liệu lịch sử chứa quyết định trái nguyên tắc năng lực trả nợ, nên tri thức ngành phải kiểm soát dữ liệu. Hồ sơ vi phạm năng lực trả nợ được duyệt với tỉ lệ 85.5–100%, so với 26.50–63.60% ở hồ sơ không vi phạm.
5. Với khẩu vị rủi ro thận trọng, CPAR (Classification based on Predictive Association Rules) là thuật toán tốt nhất, còn CMAR (Classification based on Multiple Association Rules) có xu hướng duyệt rộng nhất. CPAR đạt điểm F0.5 cao nhất (75.74 so với 74.29 của CBA, Classification Based on Associations, và 70.00 của CMAR) và có chi phí thấp nhất khi k từ 1 trở lên (khi k bằng 0.5 và 0.75, CMAR có chi phí thấp nhất); CMAR duyệt nhầm 849 hồ sơ, so với 337 hồ sơ của CPAR.
6. Thuộc tính sinh từ luật chưa cải thiện độ chính xác. Điểm F0.5 chỉ thay đổi trong khoảng từ -0.39 đến +0.18 điểm phần trăm, và điểm tốt nhất (80.08) vẫn thuộc về Random Forest trên bộ dữ liệu gốc. Có ba nguyên nhân: thông tin của luật đã

có sẵn trong các cột gốc; Random Forest và Gradient Boosting tự học các tổ hợp điều kiện; và các luật mạnh nhất đã bị loại ở bước lọc theo chính sách.

Đóng góp của đề tài gồm ba điểm. Thứ nhất, quy trình đi từ kho dữ liệu, qua luật kết hợp, đến phân loại, trong đó kho dữ liệu kiểm soát luật thông qua khung nhìn chính sách. Thứ hai, ràng buộc khai phá được chuẩn hóa theo lớp bằng hệ số chắc chắn, khắc phục thiên lệch của ngưỡng confidence cố định trên dữ liệu mất cân bằng. Thứ ba, tiêu chí đánh giá theo khẩu vị rủi ro, gồm điểm F0.5 và phân tích độ nhạy chi phí. Từ đó, câu trả lời cho câu hỏi nghiên cứu là: kết hợp luật chưa làm tăng độ chính xác, nhưng giúp diễn giải kết quả xét duyệt và kiểm soát chính sách nhờ tri thức ngành.

5.2. Hàm ý quản trị và khuyến nghị nghiệp vụ

Từ các kết quả trên, đề án rút ra sáu hàm ý quản trị và khuyến nghị nghiệp vụ (Bảng 5.2). Vì được rút ra từ một bộ dữ liệu công khai, các khuyến nghị chỉ mang tính tham khảo, phù hợp với phạm vi nghiên cứu (không triển khai vào hệ thống vận hành thực tế).

Bảng 5.2. Hàm ý quản trị và khuyến nghị nghiệp vụ

Khuyến nghị	Căn cứ từ kết quả	Hàm ý
Xây dựng phễu từ chối tự động theo lịch sử vỡ nợ	Toàn bộ 22,855 hồ sơ từng vỡ nợ đều bị từ chối (mục 4.1.4)	Rút ngắn thời gian thẩm định; cần kiểm chứng trên dữ liệu thật vì quan hệ tuyệt đối có thể chỉ tồn tại trong tập dữ liệu này
Kiểm toán quyết định lịch sử trước khi dùng để huấn luyện mô hình	Hồ sơ vi phạm năng lực trả nợ được duyệt 85.5–100% (mục 4.3.5)	Tránh để mô hình học lại các quyết định trái nguyên tắc cho vay
Quản lý chính sách như dữ liệu, thông qua khung nhìn chính sách v_policy	Bộ lọc loại 20/24 luật ứng viên của CBA và 5/8 của CPAR (mục 4.6)	Tập trung định nghĩa chính sách ở một nơi và kiểm toán được; ngăn mô hình tự điều chỉnh theo các quyết định lệch chính sách
Giữ con người trong vòng quyết định (human-in-the-loop)	Mô hình tốt nhất có precision 81.21%, tức khoảng 18.8% hồ sơ được dự đoán Approved là duyệt nhầm (mục 4.7.2)	Mô hình là trợ lý sàng lọc; chuyên viên thẩm định quyết định cuối cùng; ứng dụng minh họa hiển thị các luật khớp để người thẩm định kiểm tra căn cứ (mục 4.9)

Chọn tiêu chí đánh giá mô hình theo khẩu vị rủi ro	Điểm F0.5 và phân tích độ nhạy chi phí cùng chọn CPAR (mục 4.5)	Khẩu vị thận trọng ưu tiên precision; khi khẩu vị thay đổi thì tiêu chí phải thay đổi
Giám sát danh mục bằng bảng điều khiển xây dựng từ kho dữ liệu	Hai mục đích y tế và hợp nhất nợ chiếm 46.26% dư nợ đã duyệt; nhóm kinh doanh mạo hiểm có sở hữu nhà hoàn toàn chỉ được duyệt 3.90% (mục 4.3.5)	Theo dõi cơ cấu dư nợ, các phân khúc bất thường và tỉ lệ hồ sơ vi phạm chính sách

Sáu khuyến nghị thống nhất ở một nguyên tắc: mô hình đóng vai trò hỗ trợ sàng lọc, còn chính sách và con người giữ vai trò quyết định.

5.3. Hạn chế của nghiên cứu

Nghiên cứu có năm hạn chế cần lưu ý khi diễn giải kết quả.

1. **Dữ liệu.** Đây là dữ liệu thứ cấp và có dấu hiệu mang tính tổng hợp; nhãn là quyết định xét duyệt chứ không phải kết quả nợ xấu, nên đề tài không đánh giá được rủi ro tín dụng thực tế.
2. **Đánh giá.** Dữ liệu chỉ được chia một lần với hạt giống ngẫu nhiên 42 và chưa kiểm định chéo, nên các chênh lệch dưới 0.5 điểm phần trăm (như ở mục 4.7.3) chưa đủ cơ sở thống kê.
3. **Ngưỡng chính sách.** Hai tiêu chí chính sách (thu nhập tối thiểu 25,000 và khoản vay tối đa 40% thu nhập) và ngưỡng loại luật (10% hồ sơ được phủ vi phạm) là giả định của nhóm (mức 25,000 xấp xỉ chuẩn nghèo của Mỹ cho hộ ba người); các ngưỡng hồ sơ an toàn của ứng dụng minh họa (thu nhập từ 100,000, khoản vay không quá 10% thu nhập, điểm tín dụng từ 580) cũng là giả định của nhóm; tất cả chưa được hiệu chỉnh bằng dữ liệu thực.
4. **Cài đặt thuật toán.** Đề án cài đặt CPAR ở dạng đơn giản hóa (mỗi bước chỉ chọn một điều kiện tốt nhất, không tách nhánh như bản gốc) và không cài đặt cây lưu trữ luật phân loại (CR-tree) của CMAR. Việc rời rạc hóa làm mất một phần thông tin của các biến liên tục; ngưỡng nghiệp vụ cố định chưa được phân tích độ nhạy và tạo ra các nhóm không đều (nhóm VeryGood chỉ chiếm 0.20%, nhóm Fair chiếm 59.58%, nhóm lãi suất từ 16% trở lên chiếm 5.21%), nên nhóm VeryGood không thể đạt ngưỡng support 2% để xuất hiện trong luật.
5. **Phạm vi.** Kho dữ liệu mang tính tĩnh, chưa có chiều thời gian; đề tài chưa phân tích công bằng tín dụng đối với các biến nhạy cảm như giới tính và học vấn.

5.4. Hướng phát triển

Từ các hạn chế trên, đề tài đề xuất bốn hướng phát triển.

1. Định lượng “cái giá của tuân thủ” bằng cách chạy biến thể tắt bộ lọc chính sách và so sánh hiệu năng với biến thể có lọc.
2. Sử dụng dữ liệu thực có nhãn nợ xấu, và hiệu chỉnh các ngưỡng chính sách theo dữ liệu đó.
3. Áp dụng kiểm định chéo K tập (K-Fold) hoặc lặp lại với nhiều hạt giống ngẫu nhiên, thước đo diện tích dưới đường cong precision–recall, mô hình XGBoost, và điều chỉnh ngưỡng xác suất theo khẩu vị rủi ro.
4. Bổ sung chiều thời gian cho kho dữ liệu cùng quy trình trích xuất, biến đổi và nạp dữ liệu; phân loại khách hàng; phân tích công bằng tín dụng.

BẢNG ĐÁNH GIÁ MỨC ĐỘ HOÀN THÀNH NHIỆM VỤ CỦA TỪNG THÀNH VIÊN

STT	Họ và tên	MSSV	Phân công nhiệm vụ	Mức độ hoàn thành
1	Lê Tuyết Ngọc	526102180492	Thực hiện toàn bộ phần kỹ thuật trên notebook: phân tích thăm dò dữ liệu, tiền xử lý, kho dữ liệu, khai phá luật kết hợp, phân loại dựa trên luật. Xuất số liệu, hình, sơ đồ cho cả nhóm; rà soát số liệu các chương.	100%
2	Trần Lý Phương Hoa	526102180008	Soạn Chương 1 – Giới thiệu vấn đề nghiên cứu. Tổng hợp slide phản biện.	100%
3	Quách Yến Vy	526102180017	Soạn Chương 2 – Lược khảo cơ sở lý thuyết và các nghiên cứu trước. Lập danh mục tài liệu tham khảo.	100%
4	Lê Nguyễn Bảo Ngọc	526102180491	Soạn Chương 3 – Phương pháp nghiên cứu. Phối hợp với thành viên 1 về cách xử lý biến và thuật toán.	100%
5	Nguyễn Trịnh Hoàng Ngân	526102180012	Soạn Chương 4 và Chương 5. Tổng hợp bản hoàn chỉnh: gộp các chương, tài liệu tham khảo, phụ lục, danh mục từ viết tắt.	100%

DANH MỤC TÀI LIỆU THAM KHẢO

Abellán, J., & Castellano, J. G. (2017). A comparative study on base classifiers in ensemble methods for credit scoring. *Expert Systems with Applications, 73*, 1–10. https://doi.org/10.1016/j.eswa.2016.12.020

Agrawal, R., Imieliński, T., & Swami, A. (1993). Mining association rules between sets of items in large databases. *ACM SIGMOD Record, 22*(2), 207–216. https://doi.org/10.1145/170035.170072

Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules in large databases. In *Proceedings of the 20th International Conference on Very Large Data Bases* (pp. 487–499). Morgan Kaufmann.

Bankrate. (2026). *Personal loan weekly rates*. https://www.bankrate.com/personal-loans/personal-loan-weekly-rates

Baesens, B., Van Gestel, T., Viaene, S., Stepanova, M., Suykens, J., & Vanthienen, J. (2003). Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society, 54*(6), 627–635. https://doi.org/10.1057/palgrave.jors.2601545

Bergsma, W. (2013). A bias-correction for Cramér's V and Tschuprow's T. *Journal of the Korean Statistical Society, 42*(3), 323–328. https://doi.org/10.1016/j.jkss.2012.10.002

Berzal, F., Blanco, I., Sánchez, D., & Vila, M. A. (2002). Measuring the accuracy and interest of association rules: A new framework. *Intelligent Data Analysis, 6*(3), 221–235. https://doi.org/10.3233/IDA-2002-6303

Chase. (n.d.). *Credit score ranges and what they mean*. https://www.chase.com/personal/credit-cards/education/credit-score/credit-score-ranges-and-what-they-mean

Cornell Law School, Legal Information Institute. (n.d.). *Debt-to-income ratio*. https://law.cornell.edu/index.php/wex/debt-to-income_ratio

Cramér, H. (1946). *Mathematical methods of statistics*. Princeton University Press.

Dallas Fed. (2020). https://www.dallasfed.org/research/economics/2020/0324

Dormann, C. F., Elith, J., Bacher, S., Buchmann, C., Carl, G., Carré, G., García Marquéz, J. R., Gruber, B., Lafourcade, B., Leitão, P. J., Münkemüller, T., McClean, C., Osborne, P. E., Reineking, B., Schröder, B., Skidmore, A. K., Zurell, D., & Lautenbach, S. (2013). Collinearity: A review of methods to deal with it and a simulation study evaluating their

performance. *Ecography, 36*(1), 27–46. https://doi.org/10.1111/j.1600-0587.2012.07348.x

Elkan, C. (2001). The foundations of cost-sensitive learning. In *Proceedings of the Seventeenth International Joint Conference on Artificial Intelligence (IJCAI-01)* (pp. 973–978). Morgan Kaufmann. https://www.ijcai.org/Proceedings/01/Papers/143.pdf

Experian. (n.d.). *What is a good credit score?* https://www.experian.com/blogs/ask-experian/credit-education/score-basics/what-is-a-good-credit-score/

Federal Reserve Board. (2026). *Consumer credit – G.19*. https://www.federalreserve.gov/releases/g19/current/

García, S., Luengo, J., Sáez, J. A., López, V., & Herrera, F. (2013). A survey of discretization techniques: Taxonomy and empirical analysis in supervised learning. *IEEE Transactions on Knowledge and Data Engineering, 25*(4), 734–750. https://doi.org/10.1109/TKDE.2012.35

Gray, J., Chaudhuri, S., Bosworth, A., Layman, A., Reichart, D., Venkatrao, M., Pellow, F., & Pirahesh, H. (1997). Data cube: A relational aggregation operator generalizing group-by, cross-tab, and sub-totals. *Data Mining and Knowledge Discovery, 1*(1), 29–53.

Han, J., Kamber, M., & Pei, J. (2011). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Han, J., Pei, J., & Yin, Y. (2000). Mining frequent patterns without candidate generation. *ACM SIGMOD Record, 29*(2), 1–12. https://doi.org/10.1145/335191.335372

Hand, D. J., & Henley, W. E. (1997). Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A (Statistics in Society), 160*(3), 523–541. https://doi.org/10.1111/j.1467-985X.1997.00078.x

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263–1284. https://doi.org/10.1109/TKDE.2008.239

Hoàng, Y. H., Huỳnh, T. C., & Đoàn, A. T. H. (2026, August 27). Ứng dụng học máy trong phân loại rủi ro tín dụng khách hàng cá nhân tại các ngân hàng thương mại Việt Nam. *Thời báo Ngân hàng*. https://thoibaonganhang.vn/ung-dung-hoc-may-trong-phan-loai-rui-ro-tin-dung-khach-hang-ca-nhan-tai-cac-ngan-hang-thuong-mai-viet-nam-187826.html

Hota, L., Jain, P. K., & Kumar, A. (2025). A comparative performance assessment for prediction of loan approval in financial sector. *Procedia Computer Science, 258*, 298–307. https://doi.org/10.1016/j.procs.2025.04.267

Inmon, W. H. (2005). *Building the data warehouse* (4th ed.). Wiley.

Khandani, A. E., Kim, A. J., & Lo, A. W. (2010). Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance, 34*(11), 2767–2787. https://doi.org/10.1016/j.jbankfin.2010.06.001

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Wiley.

Lessmann, S., Baesens, B., Seow, H.-V., & Thomas, L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research, 247*(1), 124–136. https://doi.org/10.1016/j.ejor.2015.05.030

Li, W., Han, J., & Pei, J. (2001). CMAR: Accurate and efficient classification based on multiple class-association rules. In *Proceedings of the 2001 IEEE International Conference on Data Mining* (pp. 369–376). IEEE. https://doi.org/10.1109/ICDM.2001.989541

Liu, B., Hsu, W., & Ma, Y. (1998). Integrating classification and association rule mining. In *Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining* (pp. 80–86). AAAI Press. https://cdn.aaai.org/KDD/1998/KDD98-012.pdf

Liu, H., Hussain, F., Tan, C. L., & Dash, M. (2002). Discretization: An enabling technique. *Data Mining and Knowledge Discovery, 6*(4), 393–423. https://doi.org/10.1023/A:1016304305535

Microsoft. (n.d.). *GROUP BY (Transact-SQL)*. Microsoft Learn. https://learn.microsoft.com/en-us/sql/t-sql/queries/select-group-by-transact-sql

Ng, R. T., Lakshmanan, L. V. S., Pang, A., & Han, J. (1998). Exploratory mining and pruning optimizations of constrained association rules. *SIGMOD Record, 27*(2), 13–24. https://doi.org/10.1145/276305.276307

Peterdy, K. (2019, October 7). *5 Cs of credit*. Corporate Finance Institute. https://corporatefinanceinstitute.com/resources/commercial-lending/5-cs-of-credit/

Sen, A., & Sinha, A. P. (2005). A comparison of data warehousing methodologies. *Communications of the ACM, 48*(3), 79–84. https://doi.org/10.1145/1047671.1047673

Shortliffe, E. H., & Buchanan, B. G. (1975). A model of inexact reasoning in medicine. *Mathematical Biosciences, 23*(3–4), 351–379. https://doi.org/10.1016/0025-5564(75)90047-4

Siddiqi, N. (2006). *Credit risk scorecards: Developing and implementing intelligent credit scoring*. Wiley.

Sinap, V. (2024). A comparative study of loan approval prediction using machine learning methods. *Gazi Üniversitesi Fen Bilimleri Dergisi Part C: Tasarım ve Teknoloji, 12*(2), 644–663. https://doi.org/10.29109/gujsc.1455978

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management, 45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Thabtah, F. (2007). A review of associative classification mining. *The Knowledge Engineering Review, 22*(1), 37–65. https://doi.org/10.1017/S0269888907001026

Uddin, N., Ahamed, M. K. U., Uddin, M. A., Islam, M. M., Talukder, M. A., & Aryal, S. (2023). An ensemble machine learning based bank loan approval predictions system with a smart application. *International Journal of Cognitive Computing in Engineering, 4*, 327–339. https://doi.org/10.1016/j.ijcce.2023.09.001

U.S. Bank. (2025, July 22). *What is a good credit score?* https://www.usbank.com/credit-cards/credit-card-insider/building-credit/what-is-a-good-credit-score.html

van Rijsbergen, C. J. (1979). *Information retrieval* (2nd ed.). Butterworths.

Yin, X., & Han, J. (2003). CPAR: Classification based on predictive association rules. In *Proceedings of the 2003 SIAM International Conference on Data Mining* (pp. 331–335). Society for Industrial and Applied Mathematics. https://doi.org/10.1137/1.9781611972733.40

KẾT QUẢ KIỂM TRA ĐẠO VĂN

ADM - Final Project - Kiem tra dao van

ORIGINALITY REPORT

13%	11%	6%	%
SIMILARITY INDEX	INTERNET SOURCES	PUBLICATIONS	STUDENT PAPERS

PRIMARY SOURCES

1	rstudio-pubs-static.s3.amazonaws.com Internet Source	1%
2	tailieu.vn Internet Source	1%
3	www.ctu.edu.vn Internet Source	1%
4	www.slideshare.net Internet Source	<1%
5	doc.huit.edu.vn Internet Source	<1%
6	text.123docz.net Internet Source	<1%
7	123docz.net Internet Source	<1%
8	vjs.ac.vn Internet Source	<1%
9	Hanoi National University of Education Publication	<1%
10	text.xemtailieu.net Internet Source	<1%
11	www.zbook.vn Internet Source	<1%
12	123doc.org Internet Source	<1%
13	tailieu.tv Internet Source	<1%
14	www.tailieudaihoc.com Internet Source	<1%
15	luanvan.net.vn Internet Source	<1%